

Algoritmo genético paralelo para la clasificación de subtipos de cáncer

Claudia María León Hiraes, Martín Agúndez Amador, Eduardo Cazares Olvera, Jorge Enrique Luna Taylor

Departamento de Sistemas y Computación, Instituto Tecnológico de La Paz,

Boulevard Forjadores No. 4720, La Paz, B.C.S., México;

cleon13019@itlp.edu.mx, magundez@uabcs.mx, eolvera@itlp.edu.mx, eluna@itlp.edu.mx

Resumen

En este artículo presentamos una versión paralela de un algoritmo para la clasificación de subtipos de cáncer usando GPGPU (Computo de Propósito General en Unidades de Procesamiento Gráfico). El método de clasificación se basa en el análisis de datos de expresión genética de los pacientes, a través de máquinas de soporte vectorial en combinación con un algoritmo genético implementados en CUDA C. Los resultados de los experimentos muestran que la versión paralela redujo 27 veces el tiempo de ejecución respecto a la implementación secuencial programada en la CPU.

Palabras clave: máquinas de soporte vectorial, expresión genética, CUDA, algoritmos genéticos, clasificación de cáncer.

I. INTRODUCCIÓN

A pesar de los avances tecnológicos, el cáncer sigue siendo un problema de salud muy importante en la población y de gran interés para la comunidad científica. En el tratamiento de esta enfermedad, es de suma importancia poder clasificar correctamente el subtipo de cáncer que padece un paciente, ya que de esto depende en gran medida la correcta elección del tratamiento a seguir, lo que se refleja directamente en la esperanza y calidad de vida del paciente. Desde hace algunos años se han propuesto diferentes técnicas para la clasificación y diagnóstico de subtipos de cáncer basadas en el análisis de expresión genética de las células tumorales [1].

Gracias a herramientas como los microarreglos de ADN es posible medir la expresión del genoma completo de los pacientes, y generar las matrices de datos con las cuales trabajan este tipo de algoritmos de clasificación. Las matrices de datos de expresión genética están compuestas por m filas que corresponden a un grupo de pacientes, y por n columnas que corresponden a los genes. Cada celda de una matriz de expresión, identificada con los subíndices (i, j) , es un valor real que corresponde el nivel de expresión del gen j del paciente i .

El objetivo de analizar estas matrices de datos es identificar el subconjunto de genes que permitan realizar

la mejor clasificación de un tipo de cáncer en particular. Esta es una labor muy compleja dado el número extremadamente grande de combinaciones de genes que hay que evaluar para lograr tal objetivo. Una alternativa para afrontar este tipo de problemas es la utilización de técnicas de programación heurísticas. En los últimos años la comunidad científica ha mostrado un interés creciente en los Algoritmos Genéticos (AG), cuya técnica ha sido inspirada en la teoría de la evolución de las especies. Estos algoritmos se basan en la observación de los mecanismos de selección que utiliza la naturaleza, de acuerdo a los cuales los individuos más aptos de una población son los que sobreviven al adaptarse más fácilmente a los cambios que se producen en su entorno. Los AG fueron desarrollados por John H. Holland a principios de los años 60, motivado por resolver problemas de aprendizaje de máquina [2].

Otra técnica que tiene su origen en los trabajos sobre la teoría de aprendizaje máquina son las máquinas de soporte vectorial (MVS), que fueron introducidas en los años 90 por Vapnik y Cortes [3]. Las MVS son una técnica de clasificación que consiste en separar dos o más clases a través de un hiperplano óptimo, cuyo margen de separación que resulta entre las muestras de las clases hacia el hiperplano sea el máximo. Computacionalmente se busca la función del hiperplano óptimo definida por la ecuación (1).

$$w^T \cdot x + b = 0 \quad (1)$$

Anteriormente se han realizado varios esfuerzos para afrontar el problema de clasificación y pronóstico de subtipos de cáncer. Golub et al. [4], presentan un trabajo que utiliza el método de “análisis de vecindario” para la distinción de clases, y agrupan los genes según patrones similares en su expresión genética. Usando los niveles de expresión y el grado de correlación de los genes, aplican un método para asignar a cada gen una puntuación asociada a cada una de las clases, y determinan a que clase pertenece un paciente en base a la suma de las puntuaciones. Los resultados de este método los evaluaron con la técnica “cross-validation”. Para sus experimentos de clasificación utilizaron 50 “genes

informativos” del conjunto de datos de leucemia, logrando un total de 36 predicciones correctas de 38 pacientes. Nasimeh y Russel [5], usan un algoritmo para identificar biclusters basado en un método matemático llamado “matriz de aproximación de rango-1”, el cual es aplicado para reducir el tamaño del conjunto de datos. Cada bicluster es un subconjunto de genes y un subconjunto de pacientes. Los genes en cada bicluster tienen valores de expresión que se correlacionan. Los genes identificados en los biclusters son utilizados para evaluar la clasificación a través de una MVS. Hernández et al. [6], utilizan tres filtros estadísticos para reducir el número de genes usados en la clasificación. Después de aplicar estos filtros el subconjunto de genes obtenidos se pasa a un AG, el cual con ayuda de una MVS realiza la selección final de los genes que se utilizarán en la clasificación.

El método que presentamos en este artículo se basa en un AG cuya función de aptitud se apoya en la implementación de una MVS programada en paralelo, utilizando la tecnología de la GPU con el lenguaje CUDA C. Los resultados obtenidos muestran una reducción del tiempo de ejecución de 27 veces en comparación con la versión secuencial del método.

II. MÉTODO PROPUESTO

El método propuesto consiste en un AG que tiene como objetivo identificar la mejor combinación de genes, cuyos niveles de expresión permitan clasificar de forma correcta el subtipo de cáncer que padece un paciente. Este algoritmo se apoya en una MVS utilizada para evaluar que tan bien clasifica un subconjunto de genes, y es la base para el cálculo de la aptitud de las soluciones potenciales (individuos) del AG. La MVS se implementó de acuerdo al método propuesto por Chang y Lin [8]. En la Figura 1 se muestra el esquema general del método propuesto.

A. Algoritmo Genético

En el AG cada individuo de la población corresponde a un subconjunto de genes, considerado como solución potencial para el problema de clasificación. Para aplicar la MVS, del total de pacientes de la base de datos, se selecciona un subconjunto para entrenamiento y otro subconjunto para las pruebas. Para almacenar los datos de expresión de los pacientes se creó una estructura de datos, que además del número de genes a utilizar para la clasificación, considera el número de bloques e hilos a ejecutar en la GPU (Figura 2). La población está formada por N individuos, donde el valor de N se determina por el número de hilos que se solicitan para ser ejecutados por la GPU.

1) Inicialización de la población

La entrada para el algoritmo genético es una matriz de datos de expresión genética, con un subconjunto de pacientes y un subconjunto de genes, que resultan después de aplicar algún filtro estadístico.

Cada individuo de la población se crea seleccionando de forma aleatoria 10 genes diferentes. Los datos de expresión de los genes de cada paciente, así como la clase del subtipo de cáncer a la que pertenece, se almacenan en la estructura de datos presentada en la Figura 2.

2) Función de Aptitud

Una vez creada la población inicial se realiza el cálculo de la aptitud de cada individuo. Este cálculo consiste en contabilizar el número de errores al intentar clasificar con la MVS el subtipo de cáncer de los pacientes. La MVS se entrena con los valores de expresión de los genes que conforman al individuo.




Figura 1. Esquema general del método propuesto.




Figura 2. Estructura de datos del AG. A) definición de la estructura para almacenar los datos de un paciente. B) Arreglo con los datos de los pacientes de entrenamiento. C) Arreglo con los datos de los pacientes de prueba.

El Algoritmo 1 muestra el pseudocódigo de la función de aptitud. Como se puede observar este método se apoya en el Algoritmo 3, que implementa la MVS. Una vez que se reciben por parte de la MVS los resultados de la clasificación de los pacientes de prueba (Línea 4), se ejecuta un ciclo (Línea 5 a 12), donde se comparan los resultados de la clasificación con las clases reales a las que pertenecen los pacientes. Con cada paciente mal clasificado el valor de la aptitud se incrementa, es decir, el valor de la aptitud óptima es igual a cero, ya que buscamos la combinación de genes que clasifique correctamente a todos los pacientes de prueba.

3) Selección

Para el proceso de selección se utiliza el método de torneo binario, el cual consiste en comparar dos individuos y seleccionar el que tiene mejor aptitud. Al inicio de este proceso se revuelve la población aleatoriamente, y se seleccionan para competir el individuo que se encuentra en la $i - \text{ésima}$ posición dentro de la población, y el individuo que encuentra en la $i - \text{ésima}$ posición después de la mitad de la población. En el Algoritmo 2 se muestra el pseudocódigo de este método.

4) Cruza

Para realizar la cruce se seleccionan dos individuos considerados como padres, de los cuales se generan dos individuos nuevos considerados como hijos. Para formar al hijo 1 se recorre la mitad de los genes del padre 1 y se copian al hijo, después se recorren los genes del padre 2 y se agregan al hijo aquellos genes que no se pasaron previamente del padre 1, hasta llegar al número de genes totales que debe tener dicho hijo. Este proceso se repite para formar el hijo 2 iniciando ahora con el padre 2. En la Figura 3 se muestra un ejemplo de la cruce de dos individuos.

Algoritmo 1. Cálculo de la aptitud de un individuo

Entrada: Subíndice de los genes y pacientes de los individuos, matriz de expresión de genes.
Salida: Valor de aptitud de cada individuo.

1. se extraen los valores de expresión del individuo a partir de la matriz de datos.
2. copia los datos del individuo del host al device
3. llama al Algoritmo 3
4. copia los resultados de la clasificación del device al host
5. **recorre** con i los individuos
6. individuo[i] $\rightarrow$ aptitud=0
7. **recorre** con j las pruebas
8. **si** pruebas_resultado $\neq$ pruebas_método
9. Individuo[i] $\rightarrow$ aptitud++
10. **fin si**
11. **fin recorre**
12. **fin recorre**

Algoritmo 2. Selección

Entrada: Población actual

Salida: Población modificada con los individuos de mejor aptitud

1. se revuelven los individuos de la población
2. **recorrer** con i la mitad de los individuos
3. **si** individuo[i].aptitud < individuo[i +mitad].aptitud
4. nueva_población.individuo[i]=individuo[i].copia
5. **si no**
6. nueva_población.individuo[i]=individuo[i +mitad].copia
7. **fin si**
8. **fin recorre**
9. se repite de 1 a 8 para llenar la segunda mitad de la población nueva
10. se asume la nueva población como la población actual

1	2	3	4	7	9	Padre 1
5	3	7	8	11	6	Padre 2
1	2	3	5	7	8	Hijo 1
5	3	7	1	2	4	Hijo 2

Figura 3. Ejemplo de cruce de dos individuos.

5) Mutación

El proceso de mutación consiste en recorrer toda la población, y para cada individuo se elige con cierto porcentaje de probabilidad si será mutado o no. Para mutar un individuo se elige de forma aleatoria uno de sus genes, y se sustituye por otro gen de la matriz de expresión elegido también de forma aleatoria.

Este proceso de seleccionar los mejores individuos cruzarlos y mutarlos, se repite un cierto número predefinido de generaciones, esperando que cada nueva generación mejore en promedio su aptitud con respecto a las generaciones anteriores. La salida del AG es un arreglo con los datos de cada individuo, incluyendo los genes seleccionados, el valor de su aptitud y el promedio de la aptitud de toda la población.

B. Máquina de Soporte Vectorial

La MVS es la parte central del cálculo de la función de aptitud del AG. El método seleccionado para implementar la MVS es el presentado por Hsieh et al. [8], el cual es un algoritmo sencillo y de rápida convergencia, nombrado como “*Método Dual de Descenso Coordinado de Larga Escala para MVS Lineales*”.

El Algoritmo 3 muestra el pseudocódigo de la MVS, dónde: α representa los vectores de soporte, w es el vector normal al hiperplano, y es la clase a la que pertenece cada paciente, x es un vector con los valores de expresión de los genes del paciente, $U = C, D = \{(x_1, y_1), \dots, (x_n, y_n)\}$.

C. Implementación paralela de la MVS

En CUDA una función llamada desde la CPU (Host), y que se ejecuta en la GPU (device), es llamada kernel. Cada kernel se ejecuta mediante un arreglo de hilos (threads), donde todos los hilos ejecutan el mismo código, y cada uno tiene un identificador (ID) que se utiliza para direccionar la memoria asociada a su proceso. La unidad básica de operación en CUDA es el hilo, y están organizados en bloques (Blocks).

Para llamar a un kernel se utiliza la siguiente sintaxis:

`nombre<<<bloques, hilos>>>();`

Para implementar la función de aptitud del AG utilizamos un kernel nombrado “*entrenamiento_mvs*”, basado en el Algoritmo 3. Los datos de los pacientes de entrenamiento se almacenaron en una estructura de datos lineal para poder ser enviados al kernel. Esta estructura, como se muestra en la Figura 4, contiene la clase a la que pertenece cada paciente, y el valor de expresión de los genes seleccionados. Para el caso de los pacientes de prueba solo cambia el parámetro NUM_MUESTRAS por NUM_PRUEBAS, que determina la cantidad de pacientes para probar la MVS. La Figura 5 muestra una

representación de la ejecución simultánea de la función de aptitud en la GPU.

Algoritmo 3. Método Dual de descenso coordinado de larga escala para MVS lineales.

Entrada: Individuos para entrenamiento.

Salida: Vector w .

1. dado α y el correspondiente $w = \sum_i y_i \alpha_i x_i$
2. **mientras** α no sea óptimo
3. **recorre** con i los pacientes
4. $G = y_i w^T x_i - 1 + D_{ii} \alpha_i$

$$PG = \begin{cases} \min(G, 0) \text{ si } \alpha_i = 0, \\ \max(G, 0) \text{ si } \alpha_i = U, \\ G \text{ si } 0 < \alpha_i < U \end{cases}$$

6. Si $|PG| \neq 0$
 $\alpha'_i \leftarrow \alpha_i$
 $\alpha_i \leftarrow \min(\max(\alpha_i - \frac{G}{Q'_{ii}}, 0), U)$
 $w \leftarrow w + (\alpha_i - \alpha'_i) y_i x_i$




Figura 4. Representación de la estructura de datos enviada al kernel.




Figura 5. Representación de la ejecución en paralelo de la función de aptitud en la GPU.

El kernel “*entrenamiento_mvs*” se divide en dos partes. Primero se ejecuta el Algoritmo 3 que se utiliza para entrenar la MVS, posteriormente se evalúa que tan eficaz resulta la clasificación. El proceso de entrenamiento encuentra el hiperplano óptimo que separa

a ambas clases con el máximo margen m (Figura 6). Encontrar el hiperplano óptimo es equivalente a minimizar la norma del vector w normal al hiperplano. En cada iteración del Algoritmo 3 se disminuye el valor de la norma de w . La condición de parada del algoritmo es que la diferencia del valor de la norma de la iteración actual con respecto a la iteración anterior sea menor que un valor épsilon preestablecido. El cálculo de la norma de un vector v se muestra en la ecuación 2.

$$\|v\| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2} \quad (2)$$

Las muestras (pacientes) de cada clase que resultan en los límites del margen se denominan vectores de soporte, y cumplen con la característica de que tienen un valor α asociado diferente de cero.

Una vez que concluye el algoritmo de entrenamiento se clasifican los pacientes de prueba utilizando la ecuación (1), donde x representa los valores de expresión de los genes de los pacientes de prueba, y el parámetro b se calcula con la ecuación 3.

$$b = \frac{1}{N_{vs}} \sum_{i=1}^{N_{vs}} (y_{vs} - w * x_{vs}) \quad (3)$$

Dónde vs representa al conjunto de las muestras que resultaron ser vectores de soporte, N_{vs} es el número total de vectores de soporte, y_{vs} es la clase de los pacientes (-1 o 1) que resultaron ser vectores de soporte, y x_{vs} son vectores con los valores de expresión de los genes de dichos pacientes.

El resultado de esta clasificación de los pacientes de prueba se almacena en un arreglo lineal y se copia del device al host.

III. EXPERIMENTOS Y RESULTADOS

Una vez que se verificó que el algoritmo identifica buenos subconjuntos de genes para la clasificación, los experimentos se enfocaron en medir el tiempo de ejecución del método paralelo propuesto y compararlo con los tiempos del método secuencial.

Se realizaron dos pruebas en las cuales se utilizaron 400 y 1000 generaciones del AG, respectivamente. En la Tabla I se muestran los parámetros para las pruebas realizadas con el AG. La Tabla II muestra los parámetros utilizados en el Algoritmo 3.

La base de datos que se utilizó para los experimentos es una matriz de expresión genética de pacientes diagnosticados con leucemia, que consta de 72 pacientes y 7129 genes.

Los experimentos se desarrollaron en un equipo de cómputo con las siguientes características:

- Tarjeta gráfica: GeForce GTX670

- Procesador: i5 3.0 GHz

- Memoria RAM: 4 GB

- Sistema Operativo: Linux Mint 17

En la Tabla III y Figura 8 se muestran los resultados de la comparación de los tiempos de ejecución.




Figura 6. Hiperplano de separación óptimo.

TABLA I. PARÁMETROS UTILIZADOS EN LOS EXPERIMENTOS

Parámetro	Prueba 1	Prueba 2
Generaciones	400	1000
Bloques	100	100
Hilos	10	10
Individuos	1000	1000
Número de genes por individuo	10	10
Pacientes para el AG	57	57
Pacientes de entrenamiento	20	20
Pacientes de prueba	37	37

TABLA II. PARÁMETROS DEL ALGORITMO 3

Parámetro	Valor
C (parámetro de penalización)	1000
TID	0
Épsilon	0.0001
U	C

TABLA III. RESULTADOS OBTENIDOS

Método	Tiempo	
	Segundos	Minutos
Secuencial-400	113.2303	1.88
Secuencial-1000	280.0745	4.66
CUDA-400	4.2006	0.07
CUDA-1000	10.1030	0.16




Figura 8. Comparación del tiempo de ejecución

IV. CONCLUSIONES

En este artículo presentamos un algoritmo genético paralelo para la clasificación de subtipos de cáncer. El algoritmo realiza el cálculo de la aptitud de los individuos utilizando un clasificador que se basa en máquinas de soporte vectorial.

El método propuesto disminuyó en más de 20 veces el tiempo de ejecución del método secuencial, lo cual permitirá realizar experimentos con más bases de datos de cáncer, incluso de mayor tamaño, en tiempos mucho más accesibles.

Como trabajo futuro se propone evaluar la eficiencia del algoritmo en cuanto al porcentaje de éxito en la clasificación con diferentes bases de datos cáncer.

REFERENCIAS

- [1] Ying Lu y Jiawei Han, "Cancer Classification Using Gene Expression Data", *Journal Systems*, vol. 28, no. 4, 2003, pp. 243-268.
- [2] Coello Coello Carlos, A. "Introducción a los Algoritmos Genéticos", *soluciones Avanzadas. Tecnologías de Información y Estrategias de Negocios*, Año 3, No.17, Enero de 1995, pp. 5-11.
- [3] Corinna Cortes y Vladimir Vapnik, "support-vector Networks", 1995, 273-297.
- [4] T. R. Golub, D. K. Slonim, P. Tamayo, C. Huard, M. Gaasenbeek, J. P. Mesirov, H. Coller, M. L. Loh, J. R. Downing, M. A. Caligiuri, C. D. Bloomfield and E. S. Lander "Molecular Classification of Cancer: Class Discovery and Class Prediction by Gene Expression Monitoring" *Science*, vol. 286, 1999, pp. 531-537.

- [5] Nasimeh Asgarian y Russell Greiner, "Using Rank-Biclusters to Classify Microarray Data", *Bioinformatics*, vol. 00, 2007, pp. 1-10.
- [6] Hernández Montiel L. A., Bonilla Huerta E. y Morales Caporal R., "A multiple-filter-GA-SVM method for dimension reduction y clasificación de DNA-microarray data", *Revista Mexicana de Ingeniería Biomédica*, vol. 32, no. 1, 2011, pp. 32-39.
- [7] Chih-Chung Chang and Chih-Jen Lin, "LIBSVM: a library for support vector machines." *ACM Transactions on Intelligent Systems and Technology*, 2:27:1—27:27, 2011.
- [8] Cho-Jui Hsieh, Kai-Wei Chang, Chih-Jen Lin, S. Sathiya Keerthi and Sellamanickam Sundararajan. "A Dual Coordinate Descent Method for Large-scale Linear SVM," *ACM Proceedings of the 25th international conference on Machine learning*, 408-415, 2008.
- [9] I. S. Jacobs and C. P. Bean, "Fine particles, thin films and exchange anisotropy," in *Magnetism*, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271-350.