

Resumen

El desarrollo de nuevas tecnologías como los microarreglos de ADN ha impulsado el avance de ramas como la bioinformática, la cual juega un papel central en las investigaciones de biología molecular. Desde hace algunos años los experimentos con microarreglos han producido grandes cantidades de datos relacionados con la expresión de genes. El reto ahora es descubrir información útil a partir del análisis de estos datos. En el análisis de expresión de genes el biclustering se ha consolidado como una de las técnicas más importantes como primer paso en el descubrimiento de nuevo conocimiento. El objetivo del biclustering es identificar grupos de genes y conjunto de condiciones experimentales, donde los genes presentan altos niveles de correlación para dicho conjunto de condiciones.

En esta investigación se presenta el análisis de algunos métodos sobresalientes del biclustering, y se propone un nuevo método basado en la combinación de las mejores características detectadas de métodos recientes. Se realizaron evaluaciones de las nuevas propuestas, y se compararon con los métodos analizados, obteniéndose resultados muy competitivos.

Índice general

1. Introducción	8
1.1. Antecedentes	8
1.2. Objetivos	9
1.2.1. General	9
1.2.2. Específicos	9
1.3. Organización de la tesis	10
2. Planteamiento del problema	11
2.1. Expresión genética	11
2.2. Microarreglos de ADN	12
2.3. Biclusters	14
2.4. Análisis de expresión genética	15
2.5. Biomarcador	16
2.6. Significancia estadística y p-valor	17
2.7. Definición formal del problema biclustering	19
2.8. Trabajo previo realizado	20
2.8.1. An Improved Biclustering Method for Analyzing Gene Expression Profiles [14]	20
2.8.2. A Systematic Comparison and Evaluation of Biclustering Methods for Gene Expression Data [23]	22
2.8.3. Biclustering of Expression Data [9]	25
2.8.4. Pattern-driven neighborhood search for biclustering of microarray data [2] . .	28
2.8.4.1. Método	29
2.8.4.2. Función de evaluación ASR	31
2.8.4.3. Presentación de la configuración	32
2.8.4.4. Solución Inicial	32
2.8.4.5. Vecindario y su exploración	32

2.8.5. Biclustering of Gene Expression Data by Correlation-Based Scatter Search.	
[20].	35
2.8.5.1. Descripción del algoritmo	35
2.8.5.2. Fase de inicialización	38
2.8.5.3. Evaluación del bicluster: Función de aptitud	38
2.8.5.4. Método de mejora	39
2.8.5.5. Construcción del conjunto de referencia	40
2.8.5.6. Método de combinación y actualización del conjunto de referencia .	40
3. Metodología propuesta	42
3.1. Algoritmo MOGA	42
3.2. Fase de inicialización	49
3.3. Cálculo de correlación promedio	50
3.4. Función de aptitud modificada	54
4. Experimentos y Resultados	55
4.1. Pruebas con MSR	55
4.2. Pruebas con correlación	60
4.3. Pruebas con la función de correlación modificada.	70
5. Conclusiones y trabajo futuro.	74
5.1. Sumario	74
5.2. Conclusiones	75
5.3. Trabajo futuro	75
Bibliografía	76

Índice de figuras

2.1.1. Esquema general de trabajo con microarreglos de ADN.	13
2.2.1. Análisis por microarreglos de los niveles de expresión genética utilizando la técnica de “Spotted glass slide”.	14
2.4.1. Técnicas de cuantificación de los niveles de expresión genómica.	16
2.8.1. Representación de los datos para el algoritmo FLOC.	20
2.8.2. Diagrama de flujo del algoritmo FLOC.	21
2.8.3. Espacio de búsqueda en PDNS.	30
2.8.4. Ejemplo de operador de movimiento sobre filas.	34
2.8.5. Ejemplo de operador de movimiento sobre columnas.	35
3.1.1. Representación de un Biclustero. A) Cadena binaria que representa al Biclustero de la Figura C. B) Matriz de datos de expresión de genes. C) Biclustero compuesto por los valores de expresión seleccionados (valores sombreados), de la matriz de la Figura B.	43
3.1.2. Ejemplo de la cruce de dos biclusteros.	47
3.1.3. Ejemplo de mutación de un biclustero.	48
3.2.1. Ejemplo semilla	50
3.2.2. Salto que toma el valor de k	50
3.2.3. Valores para la inicialización en un rango de $k = 0$ hasta $k = 8$ ($0 < k < 8$).	51
3.3.1. Ejemplo de correlación. En el inciso A se muestra la correlación positiva y en el inciso B la correlación nula.	51
3.3.2. Ejemplo de correlación negativa, correlación nula (aproximada a cero) y correlación positiva (aproximada a 1).	53
3.4.1. Correlación negativa	54
4.1.1. MOGA con MSR 75 y 100	56
4.1.2. Comparación del Algoritmo MOGA trabajando con MSR con umbral de 75	56
4.1.3. Comparación del Algoritmo MOGA trabajando con MSR con umbral de 100	57

4.1.4. Bicluster con mínimo 10 de sus genes, y por lo menos el 50 % de sus genes, relacionados con una función o proceso biológico.	59
4.1.5. Mejores 4 bicluster del algoritmo con un MSR=75 corresponden a los biclusters sombreados de la Figura 4.3	59
4.2.1. Comparación con la función de correlación.	60
4.2.2. Comparación entre MOGA con variación del 0.90 y 0.95 bajo las restricciones fuertes.	61
4.2.3. Función de correlación para restricciones fuertes.	61
4.2.4. Gráficas de comparación mejores bicluster con formula de correlación y variación de 0.90	62
4.2.5. Comparación mejores bicluster con formula de correlación y variación de 0.95	63
4.2.6. MOGA con variación de 0.97 bajo las restricciones fuertes.	64
4.2.7. Gráfica de los Mejores bicluster para correlación de 0.97	65
4.2.8. MOGA con variación de 0.98 bajo las restricciones fuertes.	66
4.2.9. Gráfica de los mejores bicluster para correlación de 0.98 con inicio de diversificación.	67
4.2.10. MOGA con variación de 0.98 con inicialización original del método.	68
4.2.11. Gráfica de los mejores bicluster para variación de 0.98.	69
4.2.12. Comparación gráfica de diferentes valores para variaciones con correlación.	70
4.3.1. Gráfica del comportamiento de los genes de un bicluster descubierto por el algoritmo, que presentan comportamiento de espejo.	71
4.3.2. Genes con comportamiento de espejo descubiertos por el algoritmo, asociados al procesamiento de rRNA.	72
4.3.3. Genes con comportamiento de espejo descubiertos por el algoritmo, asociados a la función de regulación de la transcripción del RNA polimerasa promotor II.	72
4.3.4. Genes con comportamiento de espejo, descubiertos por el algoritmo, asociados a la función de inicio traslacional.	73

Índice de algoritmos

2.1.	Método de Cheng y Church, [9]. Módulo Principal	26
2.2.	Método de Cheng y Church, [9]. Eliminación de filas y/o columnas.	27
2.3.	Método de Cheng y Church, [9]. Eliminación múltiple de filas y/o columnas.	27
2.4.	Método de Cheng y Church, [9]. Inserción de filas y/o columnas.	28
2.5.	Método de Ayadi et al, [2]. Procedimiento general de PDNS.	31
2.6.	Método Scatter Search. Nepomuceno et al, [20].	37
2.7.	Método de mejora. Nepomuceno et al, [20].	40
3.1.	Genético Multi-Objetivo Biclustering	45
3.2.	Cálculo de Frentes de Pareto	46
3.3.	Cálculo de Correlación promedio por bicluster	52

Lista de Tablas

4.2. Resultados de la prueba para MSR con la restricción fuerte.	57
4.1. Resultados de la prueba para MSR con umbral de 75	57
4.3. Mejores bicluster del algoritmo con un MSR=75	58
4.4. Comparación con la función de correlación.	60
4.5. Comparación mejores bicluster con formula de correlación y variación de 0.95	63
4.6. Valores de correlación con diferentes niveles de variación.	70
4.7. Biclusters significativos biológicamente cuyos genes presentan comportamiento en espejo.	71

Capítulo 1

Introducción

1.1. Antecedentes

Conforme pasan los años los científicos se van abriendo paso en las diferentes ramas del conocimiento. Un área de gran importancia para el desarrollo humano es sin duda la biología. Con el avance tecnológico han surgido nuevas soluciones a problemas de salud antes inimaginables. Estos avances han permitido desarrollar nuevas herramientas tanto para el diagnóstico como para el tratamiento de diferentes enfermedades.

Hoy en día la tecnología ha permitido obtener información muy relevante contenida dentro de las células, por ejemplo, se puede conocer la composición genética de los organismos, e incluso identificar qué genes se expresan en un momento y condición dada. El análisis del comportamiento de los genes es una herramienta muy valiosa como parte del análisis clínico de un paciente.

Con el apoyo de la computación se ha logrado un importante impulso en diferentes áreas de la ciencia. Dentro de la biología, por ejemplo, ha permitido la obtención, almacenamiento y el análisis de grandes volúmenes de datos biológicos y generado información muy útil dentro del área médica [26].

Como resultado de la combinación de las ciencias computacionales y biológicas, surgió un área muy interesante, la bioinformática. Según el NIH (Institutos Nacionales de Salud de los Estados Unidos), Bioinformática es la investigación, desarrollo y aplicación de herramientas computacionales y aproximaciones, para la expansión del uso de datos biológicos, médicos, conductuales o de salud, incluyendo aquellas herramientas que sirvan para adquirir, almacenar, organizar, analizar o visualizar tales datos.

El reciente nacimiento de esta ciencia interdisciplinar encargada de buscar soluciones informáticas a determinados problemas biológicos, surge como una solución ante la necesidad de búsqueda de conocimiento a través del análisis de grandes volúmenes de datos biológicos[3].

Dentro de la biología experimental, los microarreglos de ADN se han consolidado como una tecnología que ha revolucionado el estudio de expresión de miles de genes de forma simultánea. Los microarreglos también conocidos como biochip o DNA chip, se fundamentan en la hibridación molecular y obtienen como resultado una matriz de puntos en el que la lectura de presencia o ausencia de un color se identifica con el gen expresado o no, respectivamente. De este modo se puede obtener la huella genética o cuadro genómico de una muestra bajo estudio [8]. Como resultado de los experimentos con microarreglos de ADN, se obtienen grandes matrices de datos con información sobre el nivel de expresión de miles de genes sobre decenas o cientos de condiciones experimentales.

Uno de los objetivos del análisis de expresión de genes es el descubrimiento de nuevos biomarcadores. La identificación y análisis de biomarcadores nos permite diagnosticar una enfermedad, la susceptibilidad de padecerla, detectar la exposición a un organismo patógeno o conocer la respuesta a un determinado tratamiento farmacológico.

Dentro de la bioinformática el biclustering se ha consolidado como una de las técnicas más importantes en el análisis de datos de expresión genética. El objetivo del biclustering es identificar grupos de genes los cuales presentan patrones de comportamiento similar bajo un subconjunto de condiciones experimentales. A pesar de la existencia de un gran número de algoritmos biclustering, se tienen todavía muchos retos importantes por superar [24]:

- La poca información de inicio para definir el tipo de biclusters específico a buscar.
- La cantidad de ruido que pueden contener las matrices de datos.
- El tiempo computacional debido a los cálculos complejos que suelen requerirse.
- El relleno de los posibles huecos existentes en las entradas de datos.
- La existencia de parámetros de usuario que tienen gran influencia en los resultados finales.
- Los métodos de evaluación de los resultados obtenidos.

1.2. Objetivos

1.2.1. General

Analizar los métodos biclustering actuales con el fin de identificar e implementar oportunidades de mejora sobre al método MOGA.

1.2.2. Específicos

- Establecimiento del marco teórico.

- Analizar y documentar el método MOGA
- Analizar y documentar otros métodos biclustering recientes.
- Diseñar los cambios por aplicar al método MOGA.
- Implementar los cambios propuestos.
- Desarrollar experimentos y evaluar los resultados.

1.3. Organización de la tesis

Este trabajo consta de cinco capítulos organizados de la siguiente manera.

En el capítulo 2 se establece el planteamiento del problema, introduciendo los conceptos relevantes del problema: expresión genética, microarreglos de ADN, biclusters, análisis de expresión genética y significancia estadística y p-valor. Posteriormente se presenta la definición formal del problema y se analiza el trabajo previo realizado.

En el capítulo 3 se muestra con detalle la propuesta que consiste en la adaptación del algoritmo MOGA con dos funciones nuevas, la función de aptitud basada en correlación y la inicialización por diversificación, con el fin de mejorar el análisis de datos de expresión genética. El diseño de este método está enfocado en el descubrimiento de biclusters estadísticamente significativos en base a las anotaciones ontológicas.

En el capítulo 4 se presenta el diseño de los experimentos realizados y los resultados obtenidos, y se muestran gráficas comparativas con otros métodos relevantes encontrados en la literatura.

En el capítulo 5 se exponen las conclusiones de este trabajo, y se presenta una lista de actividades a realizar como trabajo futuro.

Capítulo 2

Planteamiento del problema

2.1. Expresión genética

Se llama Expresión Genética a la transcripción de la información almacenada en un gen para crear una molécula de ácido ribonucleico (ARN). Un gen es un segmento de la cadena ácido desoxirribonucleico (ADN), y el ARN es una especie de copia de ese segmento de ADN, que se utiliza como guía para la creación de una proteína. Cada célula contiene miles o decenas de miles de genes que codifican proteínas, pero en un determinado instante la célula sólo expresa un subconjunto de esos genes para llevar a cabo procesos celulares. Hay varias condicionantes que regulan que genes se expresan en un momento dado:

- Función de la célula en un tejido particular
- Estado de desarrollo del organismo
- Respuesta ante estímulos externos
- Presencia de alguna enfermedad
- Especificidad temporal según la etapa de vida del organismo

El análisis del nivel de expresión de distintos genes frente a diferentes condiciones experimentales es una tarea fundamental que permite el estudio de una gran variedad de problemas biológicos que se plantean en diversos organismos [3].

Los niveles de expresión genética pueden determinarse para diferentes muestras tomadas en instantes de tiempo en múltiples procesos biológicos (diferentes fases de la división celular) o en condiciones diferentes (por ejemplo, muestras de tumores con diagnóstico histopatológico diferente). La información para cada gen corresponde a un vector de alta dimensión representando su perfil de

expresión. Los valores de expresión de los genes individuales muestran la gran varianza biológica dentro de muestras de tejido de la misma clase [18].

La comparación entre distintos perfiles de expresión genética es una herramienta básica para poder responder a un gran número de cuestiones biológicas. De estas cuestiones cabe destacar la identificación de los genes de un organismo que se activan durante un ciclo celular o una producción de proteínas para el exterior. Cobran también mucha importancia las investigaciones realizadas sobre el efecto de las enfermedades en las expresiones genéticas. En los últimos años el estudio basado en datos de expresión ha sido también de gran ayuda en las anotaciones realizadas sobre los genomas secuenciados hasta el momento. Cuando el ADN se secuencia, una de las tareas que cobra más importancia es la de detectar en qué tramos de dicha secuencia podemos encontrar los genes y cuál es la función de éstos.

A la fecha se han desarrollado distintas tecnologías con el fin de obtener, almacenar y analizar esta información. Muchas de estas tecnologías se basaban en obtener los datos de expresión de un sólo gen en determinadas condiciones experimentales. Frente a estas técnicas han aparecido en los últimos años tecnologías que nos permiten obtener los datos de expresión de una gran cantidad de genes de forma simultánea. Esta generación masiva de datos ofrece las siguientes ventajas frente al estudio individual de los genes:

- Un estudio masivo de datos facilita la identificación de genes individuales que son expresados de manera desmesurada en algún estado biológico concreto.
- El análisis simultáneo de un conjunto de genes permite revelar patrones similares de comportamiento en determinadas condiciones experimentales, al igual que encontrar grupos de genes que reaccionen de forma inversa ante determinados estímulos.

Una de las tecnologías más utilizadas hoy en día de generación masiva de datos de expresión es la creación de Microarreglos de ADN(Figura 2.1.1) [24].

2.2. Microarreglos de ADN

El uso de Microarreglos (Ilustrado en la Figura 2.2.1), cuya tecnología surgió del trabajo pionero de un grupo de científicos de Stanford y el NIH, entre otros, ha emergido como una potente técnica para la medición de datos de expresión genética y la comparación de la abundancia relativa de ARN mensajero generado en distintas pruebas biológicas. El Microarreglo, también llamado DNA chip o Biochip, es un soporte sólido construido normalmente en cristal o en membrana de nylon. Existen diversas técnicas para construir estos chips biológicos integrados: fotolitografía, robots piezoeléctricos, uso de haces de fibra óptica, entre otras. Para la creación de un Microarreglo en primer lugar se colocan trozos de ADN conocidos, cuyos niveles de expresión pueden ser cuantificados en una micromatriz del biochip. Después se realizan experimentos bajo una serie de condiciones sobre




Figura 2.1.1: Esquema general de trabajo con microarreglos de ADN.

células de distintos tejidos, extrayendo el ARN mensajero generado por los genes de dichas células. Estas moléculas de ARNm se marcan con fluidos fluorescentes o radiactividad y son transformadas a un tipo especial de ADN (ADNc o ADN complementario), colocándose posteriormente en las micromatrices para comenzar el proceso de hibridación. La hibridación del ADN es el proceso más común para detectar un gen particular o un segmento de un ácido nucleico. El objetivo es crear cadenas dobles de ADN a partir de cadenas simples a sondear (las que fueron colocadas inicialmente en las matrices) y otras cadenas simples marcadas (las obtenidas a partir de los experimentos y que son llamadas sondas). Después del proceso de hibridación se eliminan todas las cadenas que no se han podido unir, mediante lavados (sólo las moléculas que hibridan permanecerán en el biochip), y se procede al revelado mediante un escaner óptico o con microscopía láser confocal. El resultado final es una matriz en la que cada una de las celdas está marcada con un determinado color. Por lo regular las filas corresponden a los genes y las columnas a las condiciones experimentales. El color de cada celda de la matriz representa el grado de expresión genética de dicho gen frente a una determinada condición experimental [24].

El advenimiento de las tecnologías de microarreglos de ADN ha revolucionado el estudio experimental de la expresión genética. Miles de genes son rutinariamente probados en una forma paralela, reportándose los niveles de expresión de su ARNm transcrito. Mediante la repetición de tales experimentos en diferentes condiciones (por ejemplo, pacientes diferentes, tejidos diferentes, o diferentes entornos de células), pueden ser anotados los datos de decenas a cientos de experimentos simultáneamente [15].




Figura 2.2.1: Análisis por microarreglos de los niveles de expresión genética utilizando la técnica de “Spotted glass slide”.

2.3. Biclusters

El análisis de alto nivel de la expresión genética consiste en realizar tareas de minería de datos y aprendizaje automático con el objetivo de extraer conocimiento a partir de la información que nos proporciona un experimento de microarreglo: relaciones entre genes, patrones de comportamiento o, en general, modelos de conocimiento. En el análisis de microarreglos, las técnicas de minería están dirigidas a la identificación de genes con un comportamiento similar dentro de un conjunto de condiciones. Básicamente es un proceso de selección de genes que incluye tareas de filtrado y creación de modelos de comportamiento [8]. El análisis de alto nivel la expresión genética enmarca tareas como:

- Clustering: agrupamiento de genes con un mismo comportamiento de manera global.
- Biclustering: agrupamientos de genes con un mismo comportamiento de manera local.

Las técnicas de Clustering han probado ser de gran utilidad a la hora de comprender la funcionalidad de los genes, su regulación, los procesos celulares y los distintos subtipos de células existentes. Una de las mayores tareas en el análisis de datos de expresión genética es la de descubrir grupos de genes que intervienen en una misma función celular o que están regulados de la misma manera, promoviendo incluso la comprensión de la funcionalidad de ciertos genes de los cuales no existía conocimiento previo [24].

Una matriz de expresión genética es una matriz de $m \times n$, cuyas filas representa los genes, las columnas las condiciones experimentales y el elemento (i, j) -ésimo es un número real que representa el nivel de expresión del gen i bajo la condición experimental j . Cada fila corresponde a los niveles de expresión de un gen particular, a través de todas las condiciones experimentales, y cada columna corresponde a los niveles de expresión de todos los genes bajo una condición experimental específica.

Sea $G = g_1, g_2, \dots, g_m$ y $C = c_1, c_2, \dots, c_n$, representan un conjunto de genes y un conjunto de condiciones experimentales, respectivamente, implicados en una matriz de expresión genética. Un bicluster se define como un subconjunto de genes que exhiben un comportamiento similar en relación a un subconjunto de condiciones experimentales, y viceversa. Así, en la matriz de la expresión genética, un bicluster aparecerá como una submatriz de ella y se representa como un par $A = (I, J)$, donde $I \subseteq G$ y $J \subseteq C$. Las filas y columnas del bicluster no necesitan ser contiguos en la matriz de expresión [10].

2.4. Análisis de expresión genética

La tecnología de microarreglos de ADN ha alcanzado recientemente un papel central en la investigación biológica y biomédica. Permiten el seguimiento de los niveles de transcripción de miles de genes simultáneamente, mientras que la célula se somete a un conjunto de condiciones o procesos específicos. La aplicación de esta tecnología tiene un impacto importante en trabajos como la anotación funcional de los genes, la reconstrucción de la red genética para el diagnóstico de condiciones de la enfermedad y los efectos característicos de tratamiento médico.

Un paso clave en el análisis de datos de expresión genética es la identificación de grupos de genes que exhiben patrones de expresión similares. El agrupamiento de datos de expresión de genes en grupos homogéneos tiene un papel decisivo en la anotación funcional, clasificación de tejido y motivos de identificación [27].

Uno de las técnicas importantes utilizadas para el análisis de expresión ha sido el Clustering, el cual consiste en identificar grupos de genes que presentan patrones de comportamiento similar. Sin embargo, este proceso presenta algunas limitaciones. En primer lugar, el Clustering se basa en la suposición de que los genes relacionados se comportan de manera similar bajo todas las condiciones experimentales. Este supuesto es razonable cuando el conjunto de datos contiene algunas condiciones de un experimento único, enfocado, pero no se sostiene para grandes conjuntos de datos que contienen cientos de condiciones heterogéneas de muchos experimentos. En segundo lugar, una solución de clústeres es a menudo una partición de los genes en conjuntos disjuntos, lo que implica una asociación de cada gen con una sola función biológica o proceso, que puede ser una simplificación excesiva del sistema biológico.

Para superar los inconvenientes del Clustering, se pretende identificar grupos de genes que exhiben comportamientos similares bajo un subconjunto de condiciones. En términos de la matriz de expresión de datos, se busca una submatriz "homogénea" cuyas filas y columnas corresponden a subconjuntos de todos los genes y todas las condiciones, respectivamente. A estas submatrices se les denomina biclusters, y al proceso de detección de éstas se le denomina biclustering [28].

Para poder analizar datos de expresión genética de forma automática con la ayuda de métodos computacionales, es necesario poder contar con dichos datos en formato electrónico. Existen diversas

técnicas que cuantifican el nivel de expresión de los genes en estudio, permitiendo de esta manera el poder almacenarlos y tratarlos de forma automática. Entre ellas se encuentran técnicas basadas en secuenciamiento ESTs (marcadores de secuencia expresada), la técnica SAGE (análisis serial de expresión de genes), basada en el principio de que un segmento corto de ADN permite identificar un único gen transcrito; y la tecnología de microarreglo, la más utilizada actualmente para el análisis de datos de expresión genética. La Figura 2.4.1 presenta cómo es posible la utilización de éstas tres técnicas, a partir de un solo experimento biológico [3].




Figura 2.4.1: Técnicas de cuantificación de los niveles de expresión genómica.

2.5. Biomarcador

En 1999 el NIH definió el término biomarcador como «una característica objetivamente mensurable y evaluable como indicadora de un proceso biológico ordinario, de un proceso patogénico o como respuesta a una intervención terapéutica». Podemos hablar, por tanto, de biomarcadores de diagnóstico, predisposición, exposición, pronóstico, respuesta y predicción de la eficacia terapéutica, utilizando para ello una enorme variedad de indicadores cuantificables cuya utilidad no sólo se limita al campo de la clínica convencional sino que se extiende también al descubrimiento y desarrollo de nuevos medicamentos. La investigación en el campo de los biomarcadores está experimentando un desarrollo exponencial. El término biomarcador está relacionado fuertemente con áreas como la bioquímica, biología molecular, farmacología, oncología, química y la genética. Existe una revista especializada denominada Biomarkers con un alto índice de impacto, y anualmente se

celebran numerosos congresos sobre esta temática como el *Biomarkers World Congress* y el *The Annual Biomarkers Congress* [21].

2.6. Significancia estadística y p-valor

En el trabajo de Boyle et al., 2004[6], presentan una descripción del software GO::TermFinder, el cual se utiliza para acceder a la información del Gene Ontology (GO), y evaluar la significancia estadística (nombrada también como enriquecimiento significativo), de cada anotación GO en relación a una lista de genes.

El Gene Ontology (GO) Consortium [1], provee un vocabulario controlado para describir Procesos Biológicos, Funciones Moleculares y Componentes Celulares, que son estructurados como grafos acíclicos dirigidos (DAGs). Los genes o productos de los genes, pueden anotarse (i.e. relacionarse), a uno o más nodos GO, y en base al grafo, un gen anotado a un nodo dado, también está anotado a todos los ancestros de tal nodo.

Cálculo de la significancia estadística

Para determinar si un término GO se relaciona con una lista específica de genes, con una frecuencia mayor, que aquella que podría ser esperada por probabilidad, GO::TermFinder calcula el llamado *p-valor*, en base a la distribución hipergeométrica (Ecuación 2.6.1):

$$p = 1 - \sum_{i=0}^{k-1} \frac{\binom{M}{i} \binom{N-M}{n-i}}{\binom{N}{n}} \quad (2.6.1)$$

donde:

N es el número total de genes, ya sean seleccionados los del microarrays, o los de la anotación GO

M es el número de genes anotados al nodo de interés (directa o indirectamente)

n es el número de genes de la lista de interés (bicluster)

k es el número de genes de esa lista, los cuales están anotados a ese nodo de interés

El *p-valor* representa la probabilidad de ver k o más genes, de una muestra de n , anotados a un nodo, dado que existen M genes anotados a ese nodo, de un total de N . Un *p-valor* es considerado significativo, si este, es menor que un valor α elegido para el experimento. El valor α especifica el nivel aceptado de certeza, al cual un resultado es considerado estadísticamente significativo, cuando éste, en realidad, es solamente el resultado de la casualidad. Por ejemplo, la elección de un valor α de 0.05, en un experimento, representa que existe una probabilidad de 1 en 20 que una hipótesis nula considerada verdadera, pueda parecer significativa por casualidad.

Corrección de hipótesis múltiple

Cuando múltiples hipótesis son probadas, cada una tiene una probabilidad de ser falsamente determinada como significativa. Si son probadas 10 hipótesis y el valor α es 0.05, entonces la probabilidad de encontrar al menos una hipótesis como significativa, debido a la suerte, es igual a 0.4 (lo cual es $1 - 0.95^{10}$).

La corrección para hipótesis múltiple intenta mantener la probabilidad de encontrar falsamente alguna hipótesis significativa según el valor α . El método de corrección más común para hipótesis múltiple, es la corrección de Bonferroni, donde el valor de α es simplemente dividido por el número de pruebas, y la probabilidad promedio de encontrar algún falso positivo se mantiene igual que en un único experimento. La corrección de Bonferroni asume que las pruebas son independientes, y es usualmente considerado un ajuste conservativo. En nuestro caso, las hipótesis (nodos GO) no son independientes, debido a que los nodos en sí mismos están estructurados en un DAG, y por lo tanto no está claro si un ajuste de Bonferroni puede ser apropiado. Para determinar esto, implementaron una corrección basada en simulación con GO::TermFinder. Para cada simulación fueron tomados aleatoriamente, de la lista de genes de toda la anotación, el mismo número de genes que en los datos reales, y se calcularon normalmente los p -valores. Los ajustes de los p -valores de los datos reales, fueron calculados en base a la proporción del número de nodos con un p -valor tan bueno o mejor que el p -valor de los datos reales, entre las 1000 simulaciones de hipótesis nulas, donde la hipótesis nula establece que una lista elegida aleatoriamente de genes podría no ser significativamente anotada para algunos nodos GO. Comparando el ajuste en base a las simulaciones, determinaron que el ajuste de Bonferroni es más liberal que conservativo. Tanto la simulación como Bonferroni son provistas como opciones de corrección de múltiple hipótesis, sin embargo, mientras el ajuste basado en simulación es más preciso, éste toma un tiempo mucho mayor de ejecución.

Tasa de descubrimiento falso

Una situación que se presenta con las correcciones clásicas de hipótesis múltiple, es que intentan controlar al máximo el error del tipo I (un falso positivo). Esto puede ser muy restrictivo, y resultar en la pérdida de falsos negativos. Una metodología alternativa es calcular la tasa de descubrimiento falso (FDR), la cual es la proporción esperada de hipótesis nulas verdaderas rechazadas entre el número total de hipótesis nulas rechazadas, es decir, es la proporción de hipótesis consideradas como significativas, que no son realmente significativas. Basado en 50 simulaciones, GO::TermFinder calcula el FDR para cada hipótesis de los datos reales, como el número promedio de nodos por simulación, que tienen un p -valor tan bueno o mejor que p -valor real del nodo, dividido por el número de nodos en los datos reales que tienen un p -valor tan bueno o mejor que ese p -valor.

Visualización de resultados

El GO::TermFinder incluye el módulo GO::View para visualizar el resultado del análisis de enriquecimiento de términos GO en relación a un conjunto de genes. Este módulo es configurable tal que tanto los nodos de salida, como los genes anotados a esos nodos, pueden ser ligados a URLs. Adicionalmente, los colores de los nodos en sí mismos, están basado en los p – valores calculados, de tal manera que la atención está dirigida a los nodos más significativos. Así, la salida puede ser fácil e intuitivamente vista y explorada en un navegador web.

2.7. Definición formal del problema biclustering

Madeira y Oliveria [16] presentan un planteamiento formal del problema del biclustering. Como datos de entrada se tiene una matriz de n por m , donde el elemento a_{ij} representa el nivel de expresión del gen i bajo la condición j . Generalizando, se considera la matriz de datos A , con un conjunto de filas X y un conjunto de columnas Y , donde el elemento a_{ij} corresponde a un valor que representa la relación entre la fila i y la columna j . Un bicluster es un subconjunto de filas que presentan un comportamiento similar a través de un subconjunto de columnas, y viceversa. El bicluster $A_{IJ} = (I, J)$ es un subconjunto de filas y un subconjunto de columnas, donde $I \subseteq X$ y $J \subseteq Y$. El problema específico tratado por los algoritmos de biclustering se define como: dada una matriz de datos A , se requiere identificar un conjunto de biclusters $B_k = (I_k, J_k)$, tal que cada bicluster B_k satisfaga alguna característica de homogeneidad. Las características exactas de homogeneidad de los biclusters varían de acuerdo al planteamiento del problema.

Entre los biclusters interesantes a buscar se encuentran aquellos que presentan valores con patrones de evolución coherente, por ejemplo, patrones basados en un modelo aditivo. Bajo este modelo un bicluster perfecto con valores coherentes es definido como un subconjunto de filas y subconjunto de columnas, cuyos valores a_{ij} se pueden predecir con la Ecuación 2.7.1:

$$a_{ij} = \mu + \alpha_i + \beta_j, \quad (2.7.1)$$

donde μ es el valor típico dentro del bicluster, α_i es el ajuste para la fila $i \in I$, y β_j es el ajuste para la columna $j \in J$. Otros biclusters pueden presentar patrones basados en un modelo multiplicativo para predecir a_{ij} (Ecuación 2.7.2):

$$a_{ij} = \mu' \times \alpha'_i \times \beta'_j, \quad (2.7.2)$$

donde cada elemento a_{ij} se puede predecir como un producto entre el valor típico dentro del bicluster (μ'), el ajuste para la fila i (α'_i), y el ajuste para la columna j (β'_j).

Los algoritmos que buscan biclusters con evolución coherente agrupan los elementos que presen-

tan un comportamiento similar, sin importar el valor exacto de estos elementos. En el caso de datos de expresión de genes se buscan biclusters donde un subconjunto de genes se encuentran sobre o sub expresados a través de un subconjunto de condiciones, sin tomar en cuenta el valor de expresión exacto dentro de la matriz de datos [16].

2.8. Trabajo previo realizado

A continuación se presenta el análisis de cuatro trabajos relacionados con el biclustering reconocidos en la literatura, que a continuación se detallan.

2.8.1. An Improved Biclustering Method for Analyzing Gene Expression Profiles [14]

Presentan un nuevo algoritmo probabilístico llamado FLOC, el cual encuentra eficazmente al k bicluster con menor MSR. Los datos son representados en forma de una matriz como se muestra en la figura 2.8.1 donde las filas corresponden a los genes y las columnas a las condiciones.

	conditions				
	1	2	3	4	5
1	4392	284	4108		228
2	401	281	120	275	298
3	318	280	37	277	215
4	401	292	109	580	238
5	2857	285		271	226
6	228	290	48	285	224
7	538	272	266	277	236
8	322	288	41	278	219
9	312		40	273	232
10	329	296	33	274	228

Figura 2.8.1: Representación de los datos para el algoritmo FLOC.

FLOC inicia de con un conjunto de semillas (biclusters iniciales) y lleva a cabo un proceso iterativo para mejorar la calidad global del bicluster. En cada iteración cada fila y columna es movida entre el bicluster para generar un mejor bicluster en términos de menor MSR. El mejor bicluster obtenido durante cada iteración servirá como bicluster inicial para la siguiente, el algoritmo termina cuando la iteración actual deja de mejorar la calidad del conjunto.

El algoritmo FLOC tiene dos fases (figura2.8.2). En la primera fase, k biclusters iniciales son construidos. El parámetro p es utilizado para controlar el tamaño del bicluster. Por cada bicluster

inicial un interruptor aleatorio es empelado para determinar si una fila o columna debe ser incluida. Cada bicluster inicial se espera que contenga $M \times p$ filas y $N \times p$ columnas. Donde M es el número de condiciones y N es el número de genes. Si el porcentaje de valores especificado en un cluster inicial cae por debajo del umbral α , entonces se mantiene la creación de nuevos clusters hasta que el porcentaje de valores especificado en todas las columnas y filas satisface el umbral α .

La segunda fase es un proceso iterativo que mejora la calidad del bicluster continuamente. Durante cada iteración, cada fila y cada columna son examinadas para determinar su mejor acción hacia la reducción del MSR. Estas acciones son entonces ejecutadas sucesivamente para mejorar el bicluster.




Figura 2.8.2: Diagrama de flujo del algoritmo FLOC.

Una acción es definida con respecto a una fila (o columna) y un bicluster. Hay k acciones asociadas a cada fila (o columna), una para cada bicluster. Para una determinada fila (o columna) x y un bicluster c , la acción $Accion(x, c)$ es definida como el cambio de agrupación de x con respecto a c . Esta acción es definida únicamente en una etapa. Si x ya es incluida en c , entonces $Accion(x, c)$ representa la extracción de x del bicluster c , de otra manera, $Accion(x, c)$ denota la suma de x al bicluster c .

Puesto que hay k biclusters, el número de acciones potenciales asociadas con la fila (o columna) x es k . Entre estas acciones, se requiere identificar la que genera una mayor mejora.

Inclusión de filas invertidas. Es interesante descubrir los genes que son co-regulados, pero reciben regulación opuesta. Sus patrones esencialmente presetan imágenes espejo. El algoritmo

FLOC encuentra este tipo de patrones para permitir biclusters que contienen filas invertidas. La razón es que si una fila forma imagen espejo del conjunto restante de filas en un bicluster, la inversa de esta fila (obtenido por aumentar el inverso aditivo a cada una de las entradas de la fila) debe obedecer las mismas regulaciones que el conjunto restante de filas del bicluster.

El algoritmo FLOC puede extenderse a descubrir este tipo de patrones por introducir 3 nuevas acciones para cada fila x con respecto a un bicluster c .

1. Insertar el inverso de x en c si x no participa en c .
2. Eliminar el inverso de x de c si el inverso de x esta actualmente en c .
3. invertir x en c si cualquier x o la inversa de x están actualmente en c .

En cualquier momento durante el biclustering una fila puede tener dos posibles acciones con respecto a un cluster y un total de $2k$ acciones son evaluados por cada fila de las cuales el mejor es seleccionado y ejecutado durante el proceso. Junto al conjunto enriquecido de acciones el resto del algoritmo FLOC permanece intacto así como también su complejidad computacional.

2.8.2. A Systematic Comparison and Evaluation of Biclustering Methods for Gene Expression Data [23]

En general, es difícil la evaluación de los algoritmos biclustering, ya que como problema de optimización, depende fuertemente del escenario bajo consideración, y por lo tanto, varía para diferentes trabajos. Sin embargo, consideran, que dentro del contexto del análisis de datos de expresión genética, el mérito biológico, es el primer criterio de evaluación.

En su trabajo, [23], presentan una evaluación y comparación sistemática, de algunos de los algoritmos biclustering más sobresalientes que había a la fecha. Los algoritmos seleccionados son: CC [9], Samba [28], OPSM [4], ISA [13, 12] y xMotif [19].

Además, proponen un método nuevo, nombrado Bimax, cuyo modelo de datos asume, solamente, dos posibles niveles de expresión por gen: cambio del nivel, y sin cambio, con respecto a un experimento control. Este método también se consideró, en el estudio comparativo.

Metodología de comparación En general, una comparación justa de los métodos biclustering es una tarea difícil, dado que cada método puede utilizar una formulación diferente del problema, y trabajar bien en ciertos escenarios, y fallar en otros. Sin embargo, propusieron diferentes escenarios, que reflejan la base general de la mayoría de los estudios biclustering disponibles. Estos escenarios, incluyeron conjuntos de datos de expresión de genes reales, y conjuntos de datos sintéticos.

Evaluación usando datos sintéticos Utilizaron un modelo artificial para generar datos de expresión genética sintéticos, similar a uno propuesto por [13]. En este modelo, los biclusters representan módulos de transcripción, y son definidos como:

Un conjunto G de genes, regulados por un conjunto de factores de transcripción común, y un conjunto C de condiciones, en las cuales estos factores de transcripción son activos.

Manejaron dos escenarios basados en los datos sintéticos. En el primero, incluyeron 10 módulos de transcripción (biclusters), no traslapados, cada uno de 10 genes y 5 condiciones. Este primer escenario se utilizó para estudiar el efecto del ruido sobre el rendimiento de los métodos biclustering. En el segundo escenario, cada gen puede ser regulado por d factores de transcripción, y en cada condición hasta d factores de transcripción pueden ser activos. Como consecuencia, se tienen 10 biclusters traslapados, donde d es el indicador del grado de solapamiento; en total, se consideraron nueve diferentes niveles con $d = 0, 1, \dots, 8$. Además, para cada escenario, incluyeron dos tipos de biclusters: *i*) biclusters con valores constantes, y *ii*) biclusters con valores bajo un modelo aditivo.

Para evaluar el rendimiento de los métodos, definieron M_1 y M_2 como dos conjuntos de biclusters. El puntaje de M_1 con respecto a M_2 , es dado por la función:

$$S_G^*(M_1, M_2) = \frac{1}{|M_1|} \sum_{(G_1, C_1) \in M_1} \max_{(G_2, C_2) \in M_2} \frac{|G_1 \cap G_2|}{|G_1 \cup G_2|} \quad (2.8.1)$$

Denotando M_{opt} , al conjunto de biclusters implantados, y M , a los biclusters encontrados por un algoritmo; la función $S_G^*(M, M_{opt})$, refleja en que grado, los biclusters encontrados representan a los verdaderos biclusters, en la dimensión del gen. A este valor, lo nombran como *relevancia promedio bicluster*. La función $S_G^*(M_{opt}, M)$, representa el promedio de módulos que son recuperados por el algoritmo.

Evaluación utilizando datos reales Para la evaluación con datos reales, utilizaron información sobre funciones y procesos biológicos, almacenada por el Gene Ontology (GO) Consortium [29]. Siguiendo la idea propuesta en [28], estudiaron si los grupos de genes descubiertos por los diferentes algoritmos, muestran un enriquecimiento significativo, con respecto a una anotación específica del Gene Ontology (GO). Evaluaron los biclusters, calculando el puntaje de enriquecimiento funcional hipergeométrico según [5], ajustando los resultados de múltiples pruebas, utilizando el procedimiento de Westfall y Young [30]. El análisis se realizó para los datos de expresión genética, del organismo modelo *Yeast Saccharomyces Cerevisiae*. Este conjunto de datos fue tomado de (*Gasch:2000*) y contiene una colección de 2993 genes, bajo 173 condiciones de estrés diferentes.

Además de las anotaciones GO, utilizaron mapas de procesos metabólicos, y datos de interacción proteína-proteína. La información de los procesos metabólicos, así como de la interacción de proteínas, la modelaron en término de un grafo no dirigido, donde un nodo representa una proteína, y una arista representa una reacción común, en la que las dos proteínas conectadas participan, y

respectivamente, una medida de interacción entre las dos proteínas conectadas.

Para verificar si un bicluster dado (G, C) , concuerda con el grafo metabólico, respectivamente, con el grafo de interacción proteínica, consideraron dos puntajes: *i*) la proporción de pares de genes, en G , para los cuales no existen caminos conectados en el grafo, y *ii*) la longitud promedio del camino, entre pares de genes en G , para los cuales existe tal camino. Se puede esperar que ambos valores, sean significativamente menores, para genes en G , que para genes elegidos aleatoriamente. Para realizar esta comparación, utilizaron 1000 grupos de genes del mismo tamaño que G , elegidos al azar. El mapa de procesos metabólicos utilizado, es el que describe el principal proceso biosintético, al nivel de reacciones enzimáticas, para el organismo modelo *Arabidopsis Thaliana* [31]. El conjunto de datos de expresión de genes, utilizado para la comparación con el mapa de vías metabólicas, lo tomaron de The European Arabidopsis Stock Centre [7], y comprende 69 condiciones experimentales y una selección de 734 genes. Para analizar la correspondencia de biclusters, con los datos de interacción proteína-proteína, utilizaron de nuevo los datos de expresión de genes de la *Yeast Saccharomyces Cerevisiae*. Este conjunto de datos de expresión, lo obtuvieron de una combinación de (Gasch:2000), y [25], resultando en 11498 interacciones para 3665 genes.

Experimentos y resultados obtenidos Utilizaron los datos artificiales para investigar la capacidad de los algoritmos, para recuperar grupos de genes conocidos, además de estudiar aspectos como el ruido y el traslape de grupos. El ruido lo imitaron agregando valores aleatorios a cada celda de la matriz original, estos valores los tomaron de una distribución normal. El nivel de ruido, es decir, la desviación estándar α , lo incrementaron sistemáticamente, y por cada valor de ruido, se generaron 10 matrices diferentes de datos de la matriz original E . El rendimiento de cada algoritmo, lo promediaron sobre las 10 matrices de entrada.

En cuanto a los experimentos con datos reales, la relevancia biológica de los biclusters obtenidos, la evaluaron con respecto a las anotaciones GO, los mapas de procesos metabólicos, y los datos de interacción proteína-proteína. La relevancia biológica de los biclusters, con respecto al mapa de procesos metabólicos, y con respecto a la red de interacción proteína-proteína, la basaron en el grado de conectividad dentro del grafo, de los genes asociados en un bicluster.

Conclusiones Como resultado de su investigación, concluyen que existen diferencias significativas entre los cinco métodos evaluados. Respecto al conjunto de datos reales, ISA, Samba y OPSM, obtuvieron resultados similares, mejores que los demás métodos. Para estos tres métodos, una gran proporción de los biclusters encontrados, son funcionalmente enriquecidos, y muestran una fuerte correspondencia con los procesos biológicos. En cuanto a los datos sintéticos, Samba es más robusto cuando se incrementa la complejidad regulatoria (traslape), pero más sensitivo al ruido que ISA. Mientras que Samba e ISA, encuentran múltiples biclusters, tanto con valores constantes y aditivos, OPSM identifica un solo bicluster a la vez, con mejores resultados con valores aditivos. Los otros

dos algoritmos, CC y xMotif, tienden a generar grandes biclusters que seguido representan grupos de genes con niveles de expresión sin cambios, y por lo tanto, no necesariamente contienen patrones de interés en términos de co-regulación. En consecuencia, los puntajes para CC y xMotif, son significativamente más bajos que para los demás métodos considerados. El método Bimax logró buenos resultados. Esto se puede deber al tipo de evaluación propuesta por los propios autores. Sin embargo, este método se puede utilizar como pre-procesamiento, para lograr un primer conjunto de biclusters, para posteriormente, aplicar sobre éstos, un método que logre conjuntos con más calidad.

2.8.3. Biclustering of Expression Data [9]

Cheng y Church[9], fueron los primeros en introducir el concepto de bicluster, dentro del contexto del análisis de datos de expresión de genes. Lo definieron como un subconjunto de genes y subconjunto de condiciones con alta similitud. La similitud la consideran como una medida de la coherencia entre los genes y condiciones dentro del bicluster. Como medida de esta coherencia, proponen el cálculo del *residuo cuadrado promedio* (MSR), de los valores dentro del bicluster, el cual definieron con la siguiente ecuación:

$$H(I, J) = \frac{1}{|I||J|} \sum_{i \in I, j \in J} (a_{ij} - a_{iJ} - a_{IJ} + a_{IJ})^2, \quad (2.8.2)$$

donde

$$a_{iJ} = \frac{1}{|J|} \sum_{j \in J} a_{ij}, \quad (2.8.3)$$

$$a_{IJ} = \frac{1}{|I|} \sum_{i \in I} a_{ij}, \quad (2.8.4)$$

y

$$a_{IJ} = \frac{1}{|I||J|} \sum_{i \in I, j \in J} a_{ij} \quad (2.8.5)$$

El MSR, representa la varianza del conjunto de todos los elementos del bicluster, más la varianza promedio de las filas y la varianza promedio de las columnas. El objetivo de su método, es encontrar los biclusters con los valores más bajos de MSR, y a su vez, con el mayor número de elementos posible. Dentro de estos biclusters, descartaron aquellos con datos constantes, ya que no presentan una fluctuación en el nivel de expresión, y los consideran poco interesantes o triviales. Para rechazar los biclusters triviales, se basaron en el cálculo de la *varianza de fila*.

$$V(I, J) = \frac{1}{|J|} \sum_{j \in J} (a_{ij} - a_{IJ})^2 \quad (2.8.6)$$

En su método, nombran a una matriz A_{IJ} de A , como δ -*bicluster*, si $H(I, J) \leq \delta$ para algún valor dado $\delta \geq 0$. La constante δ , representa el valor máximo aceptable de MSR de un bicluster, para ser considerado como salida.

Algoritmo

El algoritmo de [9], conocido también como *CC*, se basa en una estrategia de optimización voraz, que intenta minimizar el valor MSR de los biclusters, a la vez que intenta maximizar el número de genes y condiciones dentro de estos. La búsqueda de cada bicluster, parte de la matriz A de entrada, en la cual sustituyen los valores nulos por valores tomados de forma aleatoria, entre un rango de valores que cubre, a su vez, el rango de valores de los datos que no son nulos. A este proceso de sustitución, le sigue un proceso de eliminación de múltiples filas y columnas que intenta reducir el valor MSR, seguido por un proceso que intenta agregar filas y columnas, manteniendo la submatriz con un valor MSR menor o igual que el obtenido en el proceso anterior. El algoritmo está dividido en cuatro módulos. El módulo principal (Algoritmo 2.1), recibe como entrada la matriz A , y devuelve como salida un número dado, n , de δ -*biclusters*. Este módulo, se apoya en los módulos de eliminación (Algoritmos 2.2 y 2.3), y de inserción (Algoritmo 2.4), de filas y columnas.

Algoritmo 2.1 Método de Cheng y Church, [9]. Módulo Principal

Entrada: Una matriz A de números reales, con posibles valores perdidos; un valor $\alpha \geq 1$ como parámetro para múltiple eliminación; un valor $\delta \geq 0$ como máximo valor aceptable MSR; y n , el número de δ -*biclusters* a encontrar.

Salida: n δ -*biclusters* en A .

Inicialización: Se reemplazan los elementos nulos en A , por valores aleatorios tomados de un rango de valores que cubren el rango de valores no nulos. Se genera A' como una copia de A .

Iteración n veces:

1. Aplica el algoritmo 2.3 sobre A' , δ y α . (Si el tamaño de la fila (columna) es más pequeño que 100, no ejecuta la eliminación múltiple). La matriz generada después de este paso se nombra como B .
 2. (Paso 5 del algoritmo 2.3) Aplica el algoritmo 2.2 sobre B y δ . La matriz después de este paso se nombra como C .
 3. Aplica el algoritmo 2.4 sobre A y C , y el resultado es la matriz (bicluster) D .
 4. Reporta D , y reemplaza los elementos A' que están también en D , con número aleatorios.
-

Algoritmo 2.2 Método de Cheng y Church, [9]. Eliminación de filas y/o columnas.

Entrada: Una matriz A de números reales, y un valor $\delta \geq 0$ como máximo valor aceptable MSR.

Salida: Un δ - *biclusters* A_{IJ} , submatriz de A , con un conjunto I de filas, y un conjunto J de columnas, con un valor de MSR no mayor que δ .

Inicialización: I y J se inicializan con el conjunto de genes y condiciones, respectivamente, de A . Es decir, $A_{IJ} = A$.

Iteración:

1. Calcula a_{iJ} para toda $i \in I$, a_{Ij} para toda $j \in J$, a_{IJ} y $H(I, J)$. Si $H(I, J) \leq \delta$ retorna A_{IJ} .
 2. Encuentra la fila $i \in I$ con el mayor $d(i) = \frac{1}{|J|} \sum_{j \in J} (a_{ij} - a_{iJ} - a_{Ij} + a_{IJ})^2$, y la columna $j \in J$ con el valor más grande de $d(j) = \frac{1}{|I|} \sum_{i \in I} (a_{ij} - a_{iJ} - a_{Ij} + a_{IJ})^2$. Elimina la fila o columna que tenga el valor más grande de d , actualizando I o J , según corresponda.
-

Algoritmo 2.3 Método de Cheng y Church, [9]. Eliminación múltiple de filas y/o columnas.

Entrada: Una matriz A de números reales, y un valor $\delta \geq 0$ como máximo valor aceptable MSR, y un valor $\alpha > 1$, como factor del MSR en la eliminación múltiple.

Salida: Un δ - *biclusters* A_{IJ} , submatriz de A , con un conjunto I de filas, y un conjunto J de columnas, con un valor de MSR no mayor que δ .

Inicialización: I y J se inicializan con el conjunto de genes y condiciones, respectivamente, de A . Es decir, $A_{IJ} = A$.

Iteración:

1. Calcula a_{iJ} para toda $i \in I$, a_{Ij} para toda $j \in J$, a_{IJ} y $H(I, J)$. Si $H(I, J) \leq \delta$ retorna A_{IJ} .
 2. Elimina las filas $i \in I$ con $\frac{1}{|J|} \sum_{j \in J} (a_{ij} - a_{iJ} - a_{Ij} + a_{IJ})^2 > \alpha H(I, J)$.
 3. Recalcula a_{Ij} , a_{IJ} y $H(I, J)$.
 4. Elimina las columnas $j \in J$ con $\frac{1}{|I|} \sum_{i \in I} (a_{ij} - a_{iJ} - a_{Ij} + a_{IJ})^2 > \alpha H(I, J)$.
 5. Si no se eliminó alguna fila o columna, se ejecuta el algoritmo 2.2
-

Algoritmo 2.4 Método de Cheng y Church, [9]. Inserción de filas y/o columnas.

Entrada: Una matriz A de números reales, I y J representando un δ -*bicluster*.

Salida: I' y J' , tal que $I \subset I'$ y $J \subset J'$, con la propiedad que $H(I', J') \leq H(I, J)$.

Inicialización: I y J se inicializan con el conjunto de genes y condiciones, respectivamente, de A . Es decir, $A_{IJ} = A$.

Iteración:

1. Calcula a_{iJ} para toda i , a_{IJ} para toda j , a_{IJ} y $H(I, J)$.
 2. Agrega las columnas $j \notin J$ con $\frac{1}{|I|} \sum_{i \in I} (a_{ij} - a_{iJ} - a_{IJ} + a_{IJ})^2 \leq H(I, J)$.
 3. Recalcula a_{iJ} , a_{IJ} y $H(I, J)$.
 4. Agrega las filas $i \notin I$ con $\frac{1}{|J|} \sum_{j \in J} (a_{ij} - a_{iJ} - a_{IJ} + a_{IJ})^2 \leq H(I, J)$.
 5. Para cada fila i que no está en I , agrega su inversa si $\frac{1}{|J|} \sum_{j \in J} (-a_{ij} + a_{iJ} - a_{IJ} + a_{IJ})^2 \leq H(I, J)$.
 6. Si no se agregó alguna fila o columna, retorna I y J finales, como I' y J' .
-

El método de [9], se evaluó en conjunto con otros cinco métodos, en el trabajo [23]. Para esta evaluación se utilizaron diferentes escenarios con datos ficticios y datos reales. A pesar de que este método no arrojó los mejores resultados, se ha seguido utilizado ampliamente como referencia en una gran variedad de trabajos, principalmente para evaluar y comparar nuevos métodos. Además, el cálculo del MSR, que proponen para medir la coherencia que presentan los datos dentro de un bicluster, se ha utilizado como base en varios métodos, ya sea como valor a optimizar en los algoritmos, o como medida de comparación entre los métodos.

2.8.4. Pattern-driven neighborhood search for biclustering of microarray data [2]

Desde el punto de vista computacional, los algoritmos biclustering son problemas de búsqueda combinatoria que pueden ser tratado a través de métodos de optimización.

En el trabajo de [2] presentan un algoritmo biclustering apoyado en un modelo estocástico de búsqueda local. Partiendo de un primer bicluster, el método propuesto mejora progresivamente la calidad del bicluster ajustando algunos genes y condiciones. Los ajustes se basan en la calidad de cada gen y el estado con respecto al bicluster inicial y la matriz de datos. El rendimiento del método fue evaluado con dos conjuntos de datos bien conocidos, *Yeast cell cycle* y *Saccharomyces cerevisiae*. El método propuesto fue comparado con seis métodos que son: CC [9], Samba [28], ISA [13, 12], Bimax [22], OPSM [4], RMSBE [32].

2.8.4.1. Método

El método inicia con un preprocesamiento para transformar la matriz de datos de entrada M a una matriz M' . Este paso tiene como objetivo destacar la trayectoria del patrón de genes. Dentro de la matriz M' cada fila representa el patrón de trayectoria de un gen bajo todas las condiciones, mientras que cada columna representa el patrón de trayectoria de todos los genes en un par de condiciones particulares.

La matriz M' se construye progresivamente a través de la combinación de pares de columnas (condiciones) de la matriz de datos de entrada M . Considerando que M tiene n filas y m columnas, el número de columnas resultantes de M' al tomarlas por pares es $m(m-1)/2$. M' es definida como sigue:

$$M'[i, l] = \{1 \text{ si } M[i, k] < M[i, q]\}$$

$$\text{con } i \in [1..n], l \in [1..j''], k \in [1..m-1], q \in [2..m] \text{ y } q \geq k+1.$$

PDNS usa M' como su espacio de búsqueda, la Figura 2.8.3 muestra un ejemplo ilustrativo. PDNS puede ser considerado como un procedimiento iterativo de búsqueda local. Alterna entre dos componentes básicos: un procedimiento de mejora *descendente* y un operador de *perturbación*. El algoritmo usa el procedimiento de *descendente* para descubrir óptimos locales, y el operador de *perturbación* para desplazar la búsqueda a un nuevo punto de partida en una región de búsqueda inexplorada. La clave de la originalidad de PDNS consiste en el uso de un bicluster patrón así como en su espacio de búsqueda y su definición de vecindario.

El bicluster patrón es una presentación característica de un bicluster. Es usado para evaluar genes y condiciones. Esta presentación es definida por la matriz de comportamiento del bicluster, los patrones de trayectoria de los genes bajo todas las combinaciones de condiciones del bicluster.

A partir de un bicluster inicial, PDNS usa la estrategia descendente para explorar el vecindario basado en el patrón, y pasa a una mejor solución en cada iteración.

Por medio del bicluster patrón se definen un conjunto de reglas que permiten calificar la bondad de un gen y una condición. Usando estas reglas el algoritmo iterativamente reemplaza genes y condiciones malos por buenos dentro del bicluster actual, con lo cual se mejora progresivamente la calidad del bicluster bajo consideración. Este procedimiento iterativo de mejora se detiene cuando el último bicluster alcanza un umbral fijo de calidad de acuerdo con la función de evaluación ASR, o cuando un número fijo Y de interacciones es alcanzado. En este momento PDNS activa una fase de *perturbación* por sustitución al azar de 10 % de los genes y condiciones de los mejores biclusters encontrados hasta el momento. Este bicluster perturbado es usado como un nuevo punto de partida para la siguiente ronda de la búsqueda descendente. El algoritmo termina cuando el mejor bicluster no mejora para un número fijo z de perturbaciones.




Figura 2.8.3: Espacio de búsqueda en PDNS.

El procedimiento general de PDNS es descrito por el Algoritmo 2.5.

Algoritmo 2.5 Método de Ayadi et al, [2]. Procedimiento general de PDNS.

Entrada: Una matriz inicial M , bicluster inicial B_0 , umbrales de calidad: α, β , umbral_ASR, Número máximo de iteraciones Y, Z

Salida: El mejor bicluster B^*

Inicialización: Se crea la matriz de comportamiento M' de M .

Se crea la submatriz de comportamiento $\bar{M}'$ para B_0 .

$B^* \leftarrow B_0$ /*registro del mejor bicluster que se ha encontrado*/

$s \leftarrow \bar{M}'$ /*Conjunto de la solución inicial*/

Repetir hasta que B^* no se actualice después de un numero Z de perturbaciones.

Repetir hasta que $ASR(B^*) \geq umbral_ASR$ o alcance el máximo numero de interacciones Y .

1. Construir el bicluster patrón P de s .
 2. $s' \leftarrow s \oplus MV_g(\alpha)$ /*Aplicar a la fila(gen) el operador de movida*/
 3. Actualizar el patrón P
 4. $s \leftarrow s' \oplus MV_c(\beta)$ /*Aplicar a la columna(condición) el operador de movida*/
 5. Reconstruir el bicluster B de s
 6. Si $ASR(B) > ASR(B^*)$ entonces
 - a) $B^* \leftarrow B$ /*Actualiza el mejor bicluster que se ha encontrado*/
 7. Genera una nueva solución s para perturbar aleatoriamente el 10 % de la mejor solución registrada.
-

2.8.4.2. Función de evaluación ASR

Existen muchas funciones de evaluación de bicluster, una de las mas populares es el residuo promedio cuadrado (MSR) [9], sin embargo el MSR es deficiente para evaluar correctamente la calidad de cierto tipo de biclusters de modelos multiplicativos. PDNS utiliza la función ASR (*Average Spearman's Rho*), la cual evita el inconveniente del MSR.

Sea (I', J') un bicluster en una matriz de datos $M(I, J)$, la función de evaluación ASR se define como:

$$ASR(I', J') = 2max \left\{ \frac{\sum_{i \in I'} \sum_{j \in J' \atop j \geq i+1} p_{ij}}{|I'|(|I'|-1)}, \frac{\sum_{K \in J'} \sum_{l \in J' \atop l \geq k+1} p_{kl}}{|J'|(|J'|-1)} \right\}$$

Donde:

$p_{ij}(i \neq j)$ es la correlación de Spearman asociado con la fila de índices i y j en el bicluster (I', J')

$p_{kl}(k \neq l)$ es el rango de correlación de Spearman asociado con la columna de índices k y l en el bicluster (I', J')

De acuerdo con esta definición, $ASR(I', J')$ pertenece a $[-1..1]$. Un valor alto de ASR cerca de 1 (respecto a -1) indica que los genes / condiciones del bicluster están fuertemente correlacionados.

2.8.4.3. Presentación de la configuración

Dado un bicluster $B = (I', J')$, se codifica el bicluster en su matriz de comportamiento $s = (I', K)$, la cual es la submatriz de M' incluyendo solo el conjunto de genes en I' y todas las combinaciones en los pares de condiciones en J' . s tiene las mismas filas que B , y su número k de columnas es igual a $|J'|(|J'| - 1)$.

2.8.4.4. Solución Inicial

PDNS necesita un bicluster inicial para comenzar su búsqueda, el cual puede ser proporcionado por cualquier método. Por ejemplo puede ser creado de forma aleatoria, con el riesgo de iniciar con una solución de muy baja calidad. Una estrategia más interesante es emplear un algoritmo voráz rápido para obtener un bicluster de calidad razonable. Cada bicluster inicial es codificado dentro de su matriz de comportamiento antes de ser mejorado por PDNS.

2.8.4.5. Vecindario y su exploración

El vecindario es uno de los elementos críticos de un algoritmo de búsqueda local, el cual puede ser definido por un operador de movimiento. Dada una solución s , mv es el operador de movimiento que se aplica a s , de tal manera que cada aplicación de mv transforma a s en una nueva solución s' . Esto es denotado por: $s' \leftarrow s \oplus mv$.

Para PDNS se elaboraron dos diseños de operadores de movimiento para filas (genes) y para columnas (combinación de pares de condiciones) de una determinada solución. Ambos operadores se basan en la operación general eliminación/agregación, la cual remueve algunos elementos y agrega nuevos en la solución determinada. La cuestión fundamental aquí es el criterio que se emplea para

determinar los elementos que se eliminan y se agregan, el cual esta basado en los patrones de conducta.

El primer operador de movimiento, denotado por mv_g realiza cambios por traslado de un número de filas (genes) del bicluster y añade otros genes para obtener una mejor coherencia en el bicluster. Siendo $s = (I', K)$ una solución, se extrae de la matriz de comportamiento M' la submatriz asociada $\bar{M}'$. Sea R y C respectivamente el índice de filas y columnas de $\bar{M}'$. Se construye el bicluster patrón p de s , lo cual es definido por un vector indexado por C . $p[j]$, $j \in C$, tomando el valor dominante $k \in \{1, 0, -1\}$ tal que k tiene la mayor columna i de $\bar{M}'$. La Figura 2.8.4 muestra un ejemplo del operador de movimiento.

Posteriormente se define la calidad de cada gen g_i , $i \in R$ de la solución s , como el porcentaje de correspondencia entre el patrón de comportamiento de g y el patrón de comportamiento P del bicluster s , utilizandose α como un umbral fijo de calidad de los genes. Se define D como el conjunto de genes de s tal que su calidad no alcanza el umbral fijado por α . Se define G como el conjunto de genes de s tal que su calidad sobrepasa el umbral de calidad de α . De acuerdo a lo anterior el primer operador de movimiento mv_g remueve de s todos los genes contenidos en D y agrega un número de genes seleccionado de G .

La Figura 2.8.4 muestra un ejemplo donde el gen g_4 es eliminado y el buen gen g_{10} es agregado. g_4 es considerado no conveniente dado que su patrón de comportamiento tiene una baja correspondencia con el patrón de comportamiento del bicluster (solo 50% la cual es inferior al umbral de calidad $\alpha = 70\%$). Así mismo g_{10} es considerado conveniente dado que su calidad (83%) es mas alta que el umbral α . Este reemplazo aumenta la coherencia del bicluster resultante. El número de biclusters eliminados puede diferir del número de genes agregados. Este operador de movimiento no cambia las columnas de la solución.

El segundo operador de movimiento es denotado por mv_c el cual realiza cambios por extracción de un número de columnas (condiciones combinadas), y añade otras columnas con el fin de obtener un bicluster más coherente. Similar al primer operador de movimiento, mv_c usa un umbral de calidad β para cada columna. Cuando el operador mv_c detecta una condición no conveniente en el bicluster actual, se verifica si el valor dominante de cada condición tiene el mismo valor correspondiente al valor en el bicluster patrón, si es diferente, esta condición es considerada mala y se remueve del bicluster actual.

Para agregar una condición más conveniente, se selecciona una condición bajo el mismo subconjunto de genes de la matriz de comportamiento M' que tenga un valor mas alto que el umbral β . Este operador de movimiento no realiza cambios en las filas de la solución. Figura 2.8.5. El número de columnas eliminadas puede diferir del número de columnas agregadas en cada aplicación de este operador de movimiento.

PDNS aplica sus dos operadores de movimiento para llegar a un óptimo local de s (con un valor de ASR superior que el umbral fijo $umbral_ASR$). Esta solución s es compuesta por un grupo de

genes y columnas, cada columna representa el patrón de trayectoria de dos condiciones a través del grupo de genes. Entre las combinaciones de condiciones en s , algunas condiciones pueden ser combinadas con solo otras pocas condiciones. Durante el proceso de decodificación (transformando s en un bicluster B), se mantienen solo condiciones que son combinadas con al menos otras 50 % de las seleccionadas.




Figura 2.8.4: Ejemplo de operador de movimiento sobre filas.




Figura 2.8.5: Ejemplo de operador de movimiento sobre columnas.

2.8.5. Biclustering of Gene Expression Data by Correlation-Based Scatter Search. [20].

En [20] se presenta un método biclustering basado en la técnica de optimización Scatter Search (SS). Además se apoya en un algoritmo de diversificación para generar las soluciones iniciales. Incluye un método de mejora con la finalidad de explotar la variedad en las soluciones proporcionada por el método de generación y combinación. Utiliza la correlación lineal entre dos genes como parte de la función de aptitud de los biclusters, lo cual considera la identificación de patrones de desplazamiento y escala.

2.8.5.1. Descripción del algoritmo

Scatter Search es una optimización metaheurística que ha sido utilizado recientemente en problemas combinatorios y de optimización no lineal. Utiliza estrategias de diversificación e intensificación de la búsqueda con el fin de evitar óptimos locales, y tratar de encontrar soluciones de mejor calidad que otras heurísticas evolutivas.

Básicamente, el proceso de optimización consiste en la evolución de un conjunto llamado “conjunto de referencia”. Este conjunto se construye inicialmente con las mejores soluciones de la población, de acuerdo al valor de su función de adaptabilidad y un valor de dispersión de la población respecto a la mejor solución previa. Este conjunto se actualiza mediante un método de combinación y un método de mejora hasta que no haya cambios significativos. Cuando el conjunto de referencia es estable (es decir después de aplicar los métodos de combinación y de mejora), contiene las mismas soluciones que el conjunto de referencia de la iteración anterior y a continuación es reconstruido de nuevo. De tal manera que la construcción del conjunto de referencia se basa en calidad y diversidad, pero su actualización solo esta guiada por la calidad. La diversidad se introduce en el proceso evolutivo cuando la población inicial se genera y principalmente, cuando el conjunto de referencia se reconstruye en cada paso. La intensificación de la búsqueda se logra por el método de mejora donde la solución es perfeccionada para sacar provecho al conocimiento del problema.

A continuación se presenta el pseudocódigo de SS Algoritmo2.6.

Algoritmo 2.6 Método Scatter Search. Nepomuceno et al, [20].

Entrada: Microarreglo M , Numero de biclusters a ser encontrados $numBi$, máximo numero de interacciones $numIter$, tamaño de la población inicial y tamaño S de el conjunto de referencia.

Salida: Conjunto $Results$ con $numBi$ biclusters

Inicialización: $num \leftarrow 0, Results \leftarrow \emptyset$

Mientras ($num < numBi$) **haz**

1. Inicializa población P
2. $P \leftarrow$ Método de mejora (P)
 - a) //Construcción del conjunto de referencia
3. $R_1 \leftarrow S/2$ mejor bicluster de P (de acuerdo a la función de adaptabilidad)
4. $R_2 \leftarrow S/2$ Los bicluster mas dispersos respecto a R_1 de $\frac{P}{R_1}$ (de acuerdo a la distancia)
5. $RefSet \leftarrow (R_1 \cup R_2)$
6. $P \leftarrow P \setminus RefSet$
 - a) //Inicialización
7. $stable \leftarrow FALSO, i \leftarrow 0$
8. Mientras ($i < numIter$) haz
 - a) Mientras ($Nostable$) haz
 - 1) $A \leftarrow RefSet$
 - 2) $B \leftarrow$ Método de combinación ($RefSet$)
 - 3) $B \leftarrow$ Método de mejora (B)
 - 4) $RefSet \leftarrow S$ Mejor bicluster de $RefSet \cup B$
 - 5) Si ($A = RefSet$) entonces
 - a' $stable \leftarrow Verdadero$
 - b) //Reconstrucción del conjunto de referencia
 - c) $R_1 \leftarrow S/2$ mejor bicluster de $RefSet$
 - d) $R_2 \leftarrow S/2$ Los bicluster mas dispersos de $\frac{P}{R_1}$
 - e) $RefSet \leftarrow (R_1 \cup R_2)$
 - f) $P \leftarrow P \setminus RefSet$
 - g) $i \leftarrow i + 1$
9. //Almacenamiento en $Results$
10. $Results \leftarrow$ el mejor bicluster de $RefSet$
11. $num \leftarrow num + 1$

2.8.5.2. Fase de inicialización

La matriz de datos de entrada es un conjunto de valores reales, compuesta de N filas (genes) y L columnas (condiciones). Cada elemento de la matriz (i, j) , representa el nivel de expresión del gen i bajo la condición j .

Un bicluster B es una submatriz de la matriz M compuesta de $n \leq N$ filas, y $l \leq L$ columnas. Los biclusters son codificados por cadenas binarias de longitud $N + L$. Cada uno de los primeros N bits de la cadena binaria es relacionado a los genes y los restantes L bits representan las condiciones.

La población inicial se genera con soluciones tan diversas como sea posible a través de un método de generación de diversificación. Este método toma una cadena binaria, x_i con $i = 1, \dots, n$ donde n es el número de bits, y a partir de una solución semilla genera la solución x'_i siguiendo la regla:

$$x'_{i+kh} = 1 - x_{i+kh} \quad (2.8.7)$$

$$\text{para } k = 0, 1, 2, 3, \dots, \lfloor n/h \rfloor$$

Donde $\lfloor n/h \rfloor$ es el entero mas grande menor o igual que n/h y h es un entero menor que $n/5$. Todos los bits restantes de x' son iguales que x .

Después de generar todas las posibles soluciones con la semilla, si se necesitan más soluciones el método de generación de diversificación es aplicado otra vez usando la última solución como nueva semilla.

2.8.5.3. Evaluación del bicluster: Función de aptitud

Dos genes muestran patrón de desplazamiento y de escalamiento entre sí, si se les describe con:

$$g_Y = \alpha g_X + \beta, \beta \in R \quad (2.8.8)$$

Por lo tanto dos genes con patrones de desplazamiento y de escala son linealmente dependientes y consecuentemente una medida basada en correlación puede ser una buena función de aptitud para descubrir biclusters con esos patrones.

El coeficiente de correlación entre dos variables X y Y mide el grado de dependencia lineal entre ellas y es definido por:

$$p(X, Y) = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_i^n (x_i - \bar{x})(y_i - \bar{y})}{n \sigma_X \sigma_Y} \quad (2.8.9)$$

Donde $cov(X, Y)$ es la covarianza de la variable X y Y , $\bar{x}$ y $\bar{y}$ son la medida de los valores de la variable x y y , σ_X y σ_Y son la desviación estándar de X y Y respectivamente.

Dado un bicluster B compuesto de N genes, $B = [g_1, \dots, g_N]$, la correlación media de B , $p(B)$ se define de la siguiente manera:

$$p(B) = \frac{1}{\binom{N}{2}} \sum_{i=1}^{N-1} \sum_{j=i+1}^N p(g_i, g_j) \quad (2.8.10)$$

Donde $p(g_i, g_j)$ es el coeficiente de correlación entre el gen i y el gen j . Debido a $p(g_i, g_j) = p(g_j, g_i)$ solo $(N/2)$ elementos pueden ser considerados.

La función de aptitud usada para evaluar la calidad del bicluster se define por:

$$f(B) = (1 - p(B)) + \sigma_g + M_1 \left(\frac{1}{nG} \right) + M_2 \left(\frac{1}{nC} \right) \quad (2.8.11)$$

Donde nG y nC son el número de genes y condiciones de B respectivamente, M_1 y M_2 son factores de penalización para controlar el volumen del bicluster B y σ_p es la desviación estándar de los valores $p(g_i, g_j)$. Los mejores biclusters son aquellos con el valor mas bajo de la función adaptativa.

2.8.5.4. Método de mejora

SS usa el método de mejora cuando la solución tiene que cumplir alguna restricción, o simplemente para mejorarlas a fin de intensificar el proceso de búsqueda.

Este método depende del problema en estudio y usualmente consiste en búsquedas locales. En este trabajo solo son buscados los biclusters con genes correlacionados positivamente. Por lo tanto la propuesta del método de mejora tiene como objetivo la extracción de cualquiera de los genes positivamente correlacionados de la población inicial o de biclusters obtenidos por la combinación del método.

El pseudocódigo del método de mejora se presenta en el algoritmo 2.7.

Algoritmo 2.7 Método de mejora. Nepomuceno et al, [20].

Entrada: Biccluster $B = [g_i, \dots, g_N]$ **Salida:** Biccluster $B' \subseteq B$ tal que $p(g_i, g_j) \geq 0 \forall g_i, g_j \in B'$ **Inicialización:** $i \leftarrow 1, B' \leftarrow \{g_i\}, R \leftarrow \{\}$ **Mientras** ($i < N$) **haz**

1. $j \leftarrow i + 1$
 2. Mientras($j \leq N$) haz
 - a) Si ($p(g_i, g_j) > 0$) entonces
 - 1) Si ($g_j \notin R$) entonces
$$a' \quad B' \leftarrow B' \cup \{g_j\}$$
 - b) En caso contrario
 - 1) $R \leftarrow R \cup \{g_j\}$
 - c) $j \leftarrow j + 1$
 3. $i \leftarrow i + 1$
-

2.8.5.5. Construcción del conjunto de referencia

El conjunto de referencia es inicialmente construido con la mejor solución, según el valor de la función de aptitud y una medida de dispersión del resto de la población. Se utiliza la distancia de hamming para medir la distancia entre los biclusters y calcular su medida de dispersión. El conjunto de referencia se reconstruye con el mejor bicluster del conjunto de referencia actualizado de acuerdo a la función de aptitud y a la solución mas distante respecto a la mejor solución seleccionada previamente.

La población inicial tiene que estar actualizada en el proceso evolutivo por la solución eliminada que ya se ha considerado en la construcción o reconstrucción del conjunto de referencia.

2.8.5.6. Método de combinación y actualización del conjunto de referencia

Se introducen soluciones nuevas en el proceso de búsqueda a través de un método de combinación. Dos soluciones son combinadas mediante un operador de cruce uniforme para generar una solución nueva. Todas las parejas de bicluster son combinadas en el conjunto de referencia, produciendo de esta manera $S * (S - 1)/2$ nuevos biclusters, donde S es el tamaño del conjunto de referencia.

El operador de cruce genera aleatoriamente una mascara, y el hijo es compuesto de valores del primer padre cuando hay un 1 en la mascara y del segundo padre cuando hay un 0.

Después de combinar todos los pares de biclusters, se escoge la nueva solución con la mejor de la unión del conjunto de referencia previo, por lo que la mejor solución conforme al valor de su función de aptitud permanece en el conjunto de referencia.

Capítulo 3

Metodología propuesta

El método propuesto se basa en la adaptación de dos funciones básicas dentro del algoritmo MOGA. MOGA es un algoritmo genético multi-objetivo para el problema del biclustering, desarrollado en el área de Bioinformática del Departamento de Sistemas Computacionales del Instituto Tecnológico de La Paz. Las funciones incorporadas fueron tomadas y adaptadas del trabajo de Nepomuceno et al.[20]. La primera función modificada corresponde a la fase de inicialización de los biclusters, los cuales corresponden a las soluciones potenciales del algoritmo. La segunda función corresponde al cálculo de la aptitud de los biclusters. Estas modificaciones representan un cambio central en el algoritmo e influyen drásticamente en los resultados obtenidos.

A continuación se describe el algoritmo MOGA, y posteriormente se presentan con detalle los dos métodos agregados.

3.1. Algoritmo MOGA

Representación de los biclusters Un bicluster se representa como una cadena binaria, donde los primeros bits corresponden a los genes y los últimos corresponden a las condiciones. Si un bit tiene un valor uno, indica que el gen o condición correspondiente es seleccionado para pertenecer al bicluster. Un bicluster se compone de los valores de expresión de los genes seleccionados bajo las condiciones también seleccionadas. En la Figura 3.1.1A se muestra un ejemplo de la representación binaria de un bicluster. El bicluster correspondiente a esta cadena binaria se muestra en la Figura 3.1.1C, extraído de la matriz de expresión presentada en la Figura 3.1.1B.

Algoritmo genético multi-objetivo El módulo principal (Algoritmo 3.1), inicia creando una población de n biclusters. Cada bicluster se crea seleccionando de forma aleatoria dos genes y dos condiciones de la matriz de expresión, de tal manera que la medida de variación del bicluster no




Figura 3.1.1: Representación de un Biclustero. A) Cadena binaria que representa al Biclustero de la Figura C. B) Matriz de datos de expresión de genes. C) Biclustero compuesto por los valores de expresión seleccionados (valores sombreados), de la matriz de la Figura B.

rebase un umbral establecido (δ), y los valores de expresión para el mismo gen sean diferentes.

Además del umbral de variación δ , se establece un umbral α para el mínimo número de condiciones que deben tener los biclusters resultantes. Como entrada del algoritmo se establece un valor tope para α , sin embargo en un inicio se le asigna un valor de 2, el cual se va incrementando, de acuerdo a como van creciendo los biclusters, hasta llegar al tope establecido. Decimos que un bicluster se encuentra bajo los umbrales si su medida de variación es menor o igual que δ , y su número de condiciones es mayor o igual que α .

Después de la fase de inicialización se calcula el frente de Pareto al que pertenece cada bicluster de la población (Algoritmo 3.2). El cálculo del frente de Pareto se basa en el concepto de *dominancia*. Un bicluster i domina a otro j si se cumple alguna de las siguientes condiciones:

1. El bicluster i se encuentra bajo los umbrales y el bicluster j no.
2. Tanto i como j se encuentran bajo los umbrales, y se cumple una de las siguientes condiciones:
 - a) La medida de variación de i no es mayor que la de j , e i tiene mayor tamaño que j .
 - b) El tamaño de i no es menor que el de j , e i tiene menor medida de variación que j .
3. Ninguno de los dos se encuentra bajo los umbrales, pero i se encuentra más cerca de dichos umbrales que j .

Para que un bicluster pertenezca al frente de Pareto uno, no debe ser dominado por algún otro bicluster de la población. Una vez que son identificados los biclusters del frente uno, éstos se descartan para la identificación de los biclusters del segundo frente. Este proceso se repite hasta que no se encuentran biclusters no dominados.

Algoritmo 3.1 Genético Multi-Objetivo Biclustering

Entrada: matriz M de expresión de genes , umbral δ de variación, tope τ para el umbral de condiciones.

Salida: conjunto de n biclusters optimizados

1. establece $\alpha = 2$
 2. genera población inicial de n biclusters con *variación* por debajo del umbral δ
 3. **repite**
 4. calcula frente de pareto al que pertenece cada bicluster
 5. selecciona mejores biclusters
 6. cruza de biclusters seleccionados
 7. mutación de biclusters hijos
 8. combina población padre con población hija
 9. calcula frentes de pareto de la población combinada
 10. ordena los biclusters de la población combinada
 11. define nueva población de n biclusters
 12. actualiza umbral α
 13. **hasta** *que el número de generaciones sin mejora sea igual a ng*
 14. **retorna** *los n biclusters de la última generación*
-

Algoritmo 3.2 Cálculo de Frentes de Pareto

Entrada: conjunto de biclusters

Salida: conjunto de biclusters con frentes de Pareto calculados

1. establece como sin frente asignado a todos los biclusters
 2. $frente_actual = 1$
 3. **repite**
 4. $posibles_no_dominados = falso$
 5. **recorre** con i los biclusters sin frente asignado
 6. $no_dominado = verdadero$
 7. **recorre** con j los biclusters sin frente asignado o frente igual a $frente_actual$
 8. **si** el bicluster j domina al bicluster i
 9. $no_dominado = falso$
 10. **fin si**
 11. **fin recorre**
 12. **si** $no_dominado$ es verdadero
 13. **asigna** $frente_actual$ al Bicluster i
 14. $posibles_no_dominados = verdadero$
 15. **fin si**
 16. **fin recorre**
 17. $frente_actual = frente_actual + 1$
 18. **hasta** que $posibles_no_dominados$ sea falso
 19. **asigna** $frente_actual$ a biclusters sin frente asignado
-

Una vez que se tienen calculados los frentes de Paretos se lleva a cabo una selección de los mejores biclusters. La selección se realiza por torneo binario. Primero se reacomodan de forma aleatoria los biclusters dentro de la población, y se toman por pares para llevar a cabo el torneo. Un bicluster i se elige sobre un bicluster j si tiene un frente de Pareto menor. Este proceso de reacomodo aleatorio y selección por pares se realiza dos veces para obtener un número de biclusters seleccionados igual al tamaño de la población original.

Con los biclusters seleccionados se lleva a cabo el proceso de cruza. Se toman los biclusters




Figura 3.1.2: Ejemplo de la cruce de dos biclusters.

por pares, los cuales son considerados como padres, y se crean dos nuevos biclusters considerados como hijos por cada par. Para crear un bicluster hijo se seleccionan de forma aleatoria dos puntos de cruce en las cadenas binarias que representan a ambos biclusters padres. El primer punto de cruce se establece en una posición de bit que corresponde a un gen, y el segundo punto de cruce se establece en una posición que corresponde a una condición. El bicluster hijo toma de uno de los padres los genes que se encuentran al lado izquierdo del primer punto de cruce, y del otro padre los del lado derecho. De la misma forma se realiza con las condiciones. El padre del cual se toman los genes del lado izquierdo del primer punto de cruce se elige de forma aleatoria, lo mismo se hace con las condiciones. Este proceso se repite, desde la selección aleatoria de los puntos de cruce, para generar al hijo dos. En la Figura 3.1.2 se muestra un ejemplo de la cruce de dos biclusters. El hijo uno se crea tomando los genes del lado izquierdo del primer punto de cruce del padre uno, y los genes del lado derecho del primer punto de cruce del padre dos. Toma las condiciones del lado izquierdo del segundo punto de cruce del padre dos, y las condiciones del lado derecho del segundo punto de cruce del padre uno. En este ejemplo el hijo dos se crea con los mismos puntos de cruce, pero tomando los padres en orden contrario al seleccionar los genes y condiciones.

Posteriormente se lleva a cabo el proceso de mutación sobre un porcentaje de biclusters de la población hija. La mutación de un bicluster se realiza seleccionando de forma aleatoria un bit de la cadena, y modificando su valor. Con igual probabilidad se elige un bit que representa un gen o un bit que representa una condición. Si el bit tiene un valor cero se cambia a uno, lo cual representa que un gen o condición que no estaba considerado en el bicluster ahora se incluirá. Se tiene el caso contrario cuando se cambia un bit de uno a cero. En la Figura 3.1.3 se muestra un ejemplo de la mutación de un bicluster. En este ejemplo se seleccionó al azar, y se modificó, el décimo bit de la cadena, el cual corresponde a la posición de un gen. El valor de este bit se cambió de cero a uno, lo cual representa que los valores de expresión del décimo gen en la matriz de expresión para las




Figura 3.1.3: Ejemplo de mutación de un bicluster.

condiciones seleccionadas (valores sombreados en tono más oscuro), serán incluidos en el bicluster.

Después de la mutación se realiza un proceso donde se combinan los biclusters de la población hija y los de la población padre. Este proceso consiste únicamente en considerar como una sola población todos los biclusters de ambas generaciones. Para esta población combinada se vuelven a calcular los frentes de Pareto. Posteriormente se ordenan los biclusters de esta población combinada de acuerdo al siguiente criterio:

1. Primero se acomodan los biclusters con menor frente de Pareto
2. De los biclusters que tienen el mismo frente de Pareto, se acomodan primero los de mayor tamaño.

Posteriormente se revisa si existen biclusters idénticos, en caso de ser así se aplica una mutación a todos menos uno de estos biclusters. Una vez que se encuentra ordenada y sin repetición la población combinada, se seleccionan los primeros n biclusters, que serán considerados como la nueva población para la siguiente generación.

Finalmente se realiza una actualización del umbral α . En este proceso se revisa cada bicluster de la nueva población, y en el caso de que se cumplan las siguientes condiciones para un bicluster:

1. que su medida de variación sea menor o igual que el umbral δ de variación,
2. que su número de condiciones sea mayor que el umbral α de condiciones,

3. y que su número de condiciones sea menor o igual que el tope τ del umbral de condiciones, entonces se asigna el valor del número de condiciones del bicluster como nuevo umbral α .

El objetivo de este último proceso es ir aumentando poco a poco la presión del mínimo de condiciones que deben tener los biclusters resultantes. El umbral se va incrementando de acuerdo a como los biclusters van creciendo de forma natural mientras mantienen un buen nivel de coherencia del comportamiento de los genes que contienen. Cada vez que un bicluster induce al incremento de este umbral, aumenta la presión para los demás biclusters para poder colocarse en un buen frente de Pareto. El tope τ del umbral α , es introducido como parámetro del algoritmo, y corresponde al número mínimo de condiciones que se espera que tengan los biclusters resultantes al final de la ejecución del algoritmo.

Todos estos procesos de selección, cruza, mutación, combinar las poblaciones, calcular frentes y actualizar umbral; se realizan por varias generaciones, hasta que ocurran un número ng establecido de generaciones sin que se tenga un incremento en el tamaño del mejor bicluster de la población.

3.2. Fase de inicialización

Esta fase esta basada en el método de generación de diversificación[17]. Se considera un bicluster como una cadena binaria de longitud N compuesta por n genes y n condiciones. El proceso consiste en generar aleatoriamente un bicluster para inicializar el método MOGA posteriormente. Para iniciar se toma una semilla a partir de la cual se generaran las posibles soluciones en base a la ecuación 3.2.1.

$$X'_{1+kh} = 1 - X_{1+kh} \quad (3.2.1)$$

para $k = 0, 1, 2, 3, \dots, \lfloor \frac{n}{h} \rfloor$

donde:

n es el número de bits de la cadena binaria

h es un número aleatorio entero menor que $\frac{n}{5}$

$\lfloor \frac{n}{h} \rfloor$ entero más grande $\leq \frac{n}{h}$.

Pasos en la inicialización

1. Partimos de la semilla que es un arreglo lineal que tiene como longitud la suma del número de genes más el número de condiciones, inicializado sus bits en cero (Figura 3.2.1).
2. Calculamos el valor de h . Generamos un número aleatorio que tiene como condición que el valor sea diferente de 0.



- Figura 3.2.2: Salto que toma el valor de k

50

Para: $0 < k < 8$	
K	<i>genesCondiciones</i> [(1+k*h)-1]
0	<i>genesCondiciones</i> [0]=1
1	<i>genesCondiciones</i> [382]=1
2	<i>genesCondiciones</i> [764]=1
3	<i>genesCondiciones</i> [1146]=1
4	<i>genesCondiciones</i> [1528]=1
5	<i>genesCondiciones</i> [1910]=1
6	<i>genesCondiciones</i> [2292]=1
7	<i>genesCondiciones</i> [2674]=1

Figura 3.2.3: Valores para la inicialización en un rango de $k = 0$ hasta $k = 8$ ($0 < k < 8$).




Figura 3.3.1: Ejemplo de correlación. En el inciso A se muestra la correlación positiva y en el inciso B la correlación nula.

El cálculo se basa en la ecuación 3.3.1.

$$p(B) = \frac{1}{\frac{N}{2}} \sum_{i=1}^{N-1} \sum_{J=I+1}^N p(g_i, g_j) \quad (3.3.1)$$

donde:

$p(g_i, g_j)$ es el coeficiente de correlación entre el gen i y el gen j .

En nuestra implementación tuvimos que modificar el cálculo de la función combinatoria $\binom{n}{k}$, debido a que los resultados parciales eran muy grandes. Para $\binom{n}{k}$ en lugar de aplicar la función $\frac{n!}{(n-k)!*k!}$, se substituyó por $\frac{n*(n-1)}{2}$, aprovechando la particularidad de que en nuestro caso k siempre es igual a 2.

El Algoritmo3.3 presenta el cálculo de la función de correlación.

Algoritmo 3.3 Cálculo de Correlación promedio por bicluster

1. Extraer el bicluster de la matriz de datos y guardarlo en *datosCluster*
2. **recorre** con *g* los genes
3. **recorre** con *c* las condiciones
4. $suma += datosCluster[g, c]$
5. $cuadrado += datosCluster[g, c]^2$
6. **fin** **recorre**
7. $mGenes[g] = suma / numCondiciones$
8. $cuadradoGenes[g] = cuadrado$
9. **fin** **recorre**
10. **recorre** con *g* los genes
11. **recorre** con *j* los genes desde *g+1*
12. **recorre** con *c* las condiciones
13. $Productos[c] = datosCluster[g, c] * datosCluster[j, c]$
14. $sumaProductos += Productos[c]$
15. **fin** **recorre**
16. $covarianza = (sumaProductos / numCondiciones) - (mGenes[g] * mGenes[j])$
17. $desEstandarG1 = (cuadradoGenes[g] / numCondiciones) - mGenes[g]^2$
18. $desEstandarG2 = (cuadradoGenes[j] / numCondiciones) - mGenes[j]^2$
19. **si** *desEstandarG1* y *desEstandarG2* $\neq 0$
20. $correlacion = (covarianza / (desEstandarG1 * desEstandarG2))$
21. $sumaCorrelacion += correlacion$
22. **fin** **si**
23. $sumaProductos = 0$
24. **fin** **recorre**
25. **fin** **recorre**
26. $combinatoria = (numGenes * (numGenes - 1)) / 2$
27. $correlacionPromedio = sumaCorrelacion * (1 / combinatoria)$
28. retorna Valor absoluto de $correlacionPromedio * -100$

Cálculo del coeficiente de correlación. El coeficiente de correlación entre dos variables mide el grado de dependencia lineal entre ellas y es definido por:

$$p(X, Y) = \frac{cov(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum_i^n (X_i - \bar{x})(Y_i - \bar{y})}{n \sigma_X \sigma_Y} \quad (3.3.2)$$

donde:

$cov(X, Y)$ Es la covarianza de la variable X y Y

$\bar{x}$ y $\bar{y}$ Son la media de los valores de las variables X y Y

σ_X y σ_Y Es la desviación estandar de las variables X y Y .

Se pueden presentar tres casos para el valor de correlación, que sea correlación negativa, que no haya correlación o que sea positiva. Cuando la correlación es negativa se aproxima mas a -1 y cuando es positiva se aproxima al 1 por lo que nos deja un rango de -1 a 1. En la figura 3.3.2 se presenta un ejemplo de cada tipo de correlación ilustrado con su gráfica y los valores en la matriz.




Figure 3.3.2: Ejemplo de correlación negativa, correlación nula (aproximada a cero) y correlación positiva (aproximada a 1).

3.4. Función de aptitud modificada

La función de aptitud presentada no incluye en sus resultados patrones con comportamiento de espejo en sus genes, con el objetivo de identificar bicluster con patrones de comportamiento de espejo se modificó la función de correlación de Nepomuceno. La modificación consiste en tomar el valor absoluto de la correlación entre cada par de genes, antes de realizar la sumatoria para obtener la correlación media del bicluster. Este cambio se presenta en la Ecuación 3.4.1.

$$p(B) = \frac{1}{\frac{N}{2}} \sum_{i=1}^{N-1} \sum_{j=i+1}^N |p(g_i, g_j)| \quad (3.4.1)$$

Con esta modificación se pretende incluir en los biclusters los genes correlacionados inversamente, por lo que los rangos de correlación en el bicluster sean de -1 a 1. La figura 3.4.1 muestra este tipo de biclusters correlacionados inversamente.




Figura 3.4.1: Correlación negativa

Capítulo 4

Experimentos y Resultados

Para la evaluación de los métodos se utilizó la matriz de Gasch compuesta por 2993 genes y 173 condiciones. Los valores de entrada del algoritmo son un umbral de similaridad, el número de condiciones, el número de genes y el número de interacciones a realizar. Los experimentos se llevaron a cabo utilizando tanto la nueva función de correlación, así como el cálculo del MSR [8]. Los resultados se compararon con los métodos CC [9], ISA [11] y OPSM [4]. Las evaluaciones consistieron en medir el porcentaje de biclusters con significancia biológica que descubre cada algoritmo, de acuerdo a las anotaciones GO (Anotaciones del Consorcio Ontológico). Por cada evaluación se presentan las gráficas de significancia estadística, donde el eje de las y corresponde al porcentaje de enriquecimiento biológico y el eje de las x corresponde a los algoritmos con el respectivo $p - valor$ especificado en la tabla de la derecha.

4.1. Pruebas con MSR

Las pruebas del algoritmo con el MSR se realizaron con un umbral de similaridad del 75 y 100, con un mínimo de 10 genes, mínimo de 10 condiciones y 30 para el número de iteraciones. (Figura 4.1.1)

La comparación de los métodos se muestra en la Figura 4.1.2 para un MSR de 75 y en a Tabla 4.1 los valores obtenidos, y en la Figura 4.1.3 para un MSR de 100, ambos para un mínimo de 10 genes y 10 condiciones. La Figura 4.1.4 muestra los resultados aplicando un criterio más fuerte para la significancia estadística. Para que un bicluster sea significativo además de tener un $p - valor$ por debajo del umbral correspondiente, debe de tener un mínimo de 10 de sus genes, y por lo menos el 50 % de sus genes, perteneciendo a una categoría GO. Con un $MSR = 75$ MOGA obtuvo el 3.333 % de biclusters significativos, mientras que con un $MSR = 100$ obtuvo 0 %. Los valores para el resto de los algoritmos se muestran en la Tabla 4.2.




Figura 4.1.1: MOGA con MSR 75 y 100




Figura 4.1.2: Comparación del Algoritmo MOGA trabajando con MSR con umbral de 75

	p=0.001	p=0.005	p=0.01	p=0.05	p=0.1	p=0.5	p=1	p=5
Moga MSR=75	3.3333	3.3333	3.3333	3.3333	3.3333	3.3333	3.3333	3.3333
Moga MSR=100	0	0	0	0	0	0	0	0
CC	0	0	0	0	0	0	0	0
ISA	1.5873	1.5873	1.5873	1.5873	1.5873	1.5873	1.5873	1.5873
OPSM	31.5789	31.5789	31.5789	31.5789	31.5789	31.5789	31.5789	31.5789

Cuadro 4.2: Resultados de la prueba para MSR con la restricción fuerte.

	p=0.001	p=0.005	p=0.01	p=0.05	p=0.1	p=0.5	p=1	p=5
Moga	3.3333	3.3333	6.6667	23.3333	36.6667	60.0000	73.3333	93.3333
CC	20.0000	27.0000	32.0000	42.0000	48.0000	59.0000	62.0000	66.0000
ISA	61.9048	71.4286	71.4286	0.9524	80.9524	92.0635	98.4127	100.0000
OPSM	84.2105	84.2105	84.2105	84.2105	89.4737	94.7368	100.0000	100.0000

Cuadro 4.1: Resultados de la prueba para MSR con umbral de 75




Figura 4.1.3: Comparación del Algoritmo MOGA trabajando con MSR con umbral de 100

En la Figura 4.3 se muestran los valores para la variación (MSR), el número de genes, el número de condiciones, el tamaño y el CI por bicluster, los cuales fueron los mejores en cada iteración del algoritmo. Los cuatro primeros (filas sombreadas) son representados gráficamente en la figura 4.1.5.

Mejores bicluster				
Variación (MSR)	Genes	Condiciones	tamaño	CI
73.633	29	10	290	0.254
74.515	37	10	370	0.201
70.354	20	10	200	0.352
69.883	19	11	209	0.334
72.437	21	10	210	0.345
72.269	20	10	200	0.361
72.422	23	10	230	0.315
73.545	16	10	160	0.460
73.390	16	10	160	0.459
74.915	17	11	187	0.401
72.684	34	10	340	0.214
74.652	10	10	100	0.747
74.166	17	10	170	0.436
73.927	25	10	250	0.296
72.851	15	11	165	0.442
73.836	30	10	300	0.246
72.816	13	10	130	0.560
74.067	40	10	400	0.185
70.798	27	10	270	0.262
72.720	20	10	200	0.364
73.820	101	10	1010	0.073
73.644	30	10	300	0.245
72.095	17	10	170	0.424
73.095	19	10	190	0.385
73.739	18	10	180	0.410
73.787	26	10	260	0.284
70.803	18	10	180	0.393
71.063	21	10	210	0.338
73.253	21	10	210	0.349
74.917	19	10	190	0.394

Cuadro 4.3: Mejores bicluster del algoritmo con un MSR=75




Figura 4.1.4: Bicluster con mínimo 10 de sus genes, y por lo menos el 50 % de sus genes, relacionados con una función o proceso biológico.




Figura 4.1.5: Mejores 4 bicluster del algoritmo con un MSR=75 corresponden a los biclusters sombreados de la Figura 4.3

4.2. Pruebas con correlación

Las pruebas del algoritmo con la función de correlación se llevaron a cabo con valores de 0.90 y 0.95, aplicando un mínimo de 10 genes y mínimo 10 condiciones, para 30 iteraciones. Los resultados para ambos casos fueron similares, resultando MOGA con 100 % en todas las categorías (ver Figura 4.2.1). En la Tabla 4.2.1 se muestran los valores obtenidos. Para comparar los resultados con los dos parámetros del algoritmo se presenta la gráfica de la Figura 4.2.2. Para un valor de correlación de 0.90 se obtuvo 0 % contra un 38.4615 % para el 0.95. MOGA superó al algoritmo OPSM que tiene un valor de 31.5789 % en todas sus categorías, mientras que ISA tiene un valor de 1.5873 % y CC 0 %.




Figura 4.2.1: Comparación con la función de correlación.

	p=0.001	p=0.005	p=0.01	p=0.05	p=0.1	p=0.5	p=1	p=5
Moga	100.0000	100.0000	100.0000	100.0000	100.0000	100.0000	100.0000	100.0000
CC	20.0000	27.0000	32.0000	42.0000	48.0000	59.0000	62.0000	66.0000
ISA	61.9048	71.4286	71.4286	92.524	80.9524	92.0635	98.4127	100.0000
OPSM	84.2105	84.2105	84.2105	84.2105	89.4737	94.7368	100.0000	100.0000

Cuadro 4.4: Comparación con la función de correlación.




Figura 4.2.2: Comparación entre MOGA con variación del 0.90 y 0.95 bajo las restricciones fuertes.




Figura 4.2.3: Función de correlación para restricciones fuertes.

Las gráficas del comportamiento de los genes de los 4 mejores biclusters para correlación de 0.90 se muestran en la Figura 4.2.4, y en la Figura 4.2.5 se muestran los 4 mejores para el valor de 0.95.




Figura 4.2.4: Gráficas de comparación mejores bicluster con formula de correlación y variación de 0.90




Figura 4.2.5: Comparación mejores bicluster con formula de correlación y variación de 0.95

Variación	Genes	Condiciones	Tamaño	CI
976.806	148	70	10360	-0.009
833.757	328	21	6888	-0.014
1047.369	143	60	8580	-0.011
1094.405	165	60	9900	-0.010

Cuadro 4.5: Comparación mejores bicluster con formula de correlación y variación de 0.95

Por otra parte se probaron valores para correlación de 0.97 y 0.98 con el mínimo de 10 genes y 10 condiciones, el valor de 0.98 se probó con dos inicializaciones, la original del algoritmo MOGA y la propuesta en este trabajo de Nepomuceno et al [20]. Como ocurrió en las pruebas anteriores todos

los valores para significancia biológica son del 100 %, a diferencia con las restricciones fuertes en las que para que un bicluster sea significativo además de tener un p – *valor* por debajo del umbral correspondiente, debe de tener un mínimo de 10 de sus genes, y por lo menos el 50 % de sus genes, perteneciendo a una categoría GO.

En la Figura 4.2.6 se muestra el resultado para el valor de 0.97 el cual fue de 53.8462 % superando al resto de los métodos y rebasando a los resultados obtenidos con los valores anteriores de variación 0.90 y 0.95.




Figura 4.2.6: MOGA con variación de 0.97 bajo las restricciones fuertes.

La Figura 4.2.7 muestra los 4 mejores bicluster para correlación de 0.97




Figura 4.2.7: Gráfica de los Mejores bicluster para correlación de 0.97

La Figura 4.2.8 muestra los resultados para la variación de 0.98 con la inicialización de diversificación con las restricciones fuertes se obtuvo un 90 %. En la Figura 4.2.9 se muestran las gráficas de los 4 mejores bicluster para esta variación.




Figura 4.2.8: MOGA con variación de 0.98 bajo las restricciones fuertes.




Figura 4.2.9: Gráfica de los mejores bicluster para correlación de 0.98 con inicio de diversificación.

La otra prueba para la variación de .98 se realizó con la inicialización del método MOGA, la Figura 4.2.10 muestra los resultados para las restricciones fuertes con el valor obtenido de 70 %. En la Figura 4.2.11 se muestran las gráficas de los 4 mejores bicluster para esta prueba.




Figura 4.2.10: MOGA con variación de 0.98 con inicialización original del método.




Figura 4.2.11: Gráfica de los mejores bicluster para variación de 0.98.

A continuación se resenta la Tabla 4.6 comparativa entre las pruebas para las variaciones de correlación y en la Figura 4.2.12 la gráfica de comparación entre estos valores.

Pruebas para Correlación			
Variación	% significancia estadística	% significancia estadística fuerte	Modo de inicialización
.90	100	0	Diversificación
.95	100	38.4615	Diversificación
.97	100	53.8462	Diversificación
.98	100	90	Diversificación
.98	100	70	Inicio moga

Cuadro 4.6: Valores de correlación con diferentes niveles de variación.




Figura 4.2.12: Comparación gráfica de diferentes valores para variaciones con correlación.

4.3. Pruebas con la función de correlación modificada.

La función de aptitud modificada es capaz de identificar biclusters cuyos genes presentan patrones de comportamiento en espejo. La Figura 4.3.1 muestra la gráfica de un bicluster descubierto, cuyos genes presentan un patrón de comportamiento de espejo.

Se realizaron pruebas para evaluar si los genes que muestran este tipo de comportamiento están relacionados biológicamente, como resultado de estas pruebas se descubrieron biclusters que




Figura 4.3.1: Gráfica del comportamiento de los genes de un bicluster descubierto por el algoritmo, que presentan comportamiento de espejo.

contienen genes con patrón de comportamiento de espejo. En la Tabla 4.7 se presentan los *p*-valores y los procesos biológicos asociados a los biclusters descubiertos por el algoritmo.

Bicluster	Nombre del proceso	p-valor
Bicluster 2	Asamblea ribosoma y biogénesis	2.48e-062
Bicluster 2	Traslación	4.45e-030
Bicluster 10	Traslación	5.39e-034
Bicluster 11	Traslación	4.78e-022
Bicluster 13	Traslación	1.90e-092
Bicluster 15	Asamblea ribosoma y biogénesis	1.48e-071

Cuadro 4.7: Biclusters significativos biológicamente cuyos genes presentan comportamiento en espejo.

En las figuras 4.3.2, 4.3.3 y 4.3.4 se muestran las gráficas y los genes descubiertos con comportamiento de espejo, asociados a diferentes procesos biológicos, según las anotaciones ontológicas.


Nº Bicluster	Nombre	Ontología
3	Procesamiento de rRNA	Proceso biológico
Grafica		Genes
		YBR142W YBR247C YDR365C YER006W YGL030W YGL120C YLR002C YLR293C YMR229C YMR302C YPL043W

Figura 4.3.2: Genes con comportamiento de espejo descubiertos por el algoritmo, asociados al procesamiento de rRNA.


Nº Bicluster	Nombre	Ontología
3	Regulación de la transcripción del RNA polimerasa promotor II	Proceso biológico
Grafica		Genes
		YDR190C YFL039C YGL115W YGR200C YJL081C YJL089W YPL086C YPL235W YPR009W YPR023C YPR072W

Figura 4.3.3: Genes con comportamiento de espejo descubiertos por el algoritmo, asociados a la función de regulación de la transcripción del RNA polimerasa promotor II.


Nº Bicluster	Nombre	Ontología
7	Inicio traslacional	Proceso biológico
Grafica		Genes
		YAL035W YBR079C YER025W YGR054W YGR162W YJL138C YJR007W YKR059W YMR146C YMR260C YMR309C YNL062C YOR361C YPL119C YPL237W YPR163C

Figura 4.3.4: Genes con comportamiento de espejo, descubiertos por el algoritmo, asociados a la función de inicio traslacional.

Capítulo 5

Conclusiones y trabajo futuro.

5.1. Sumario

En este trabajo se estableció el marco teórico del problema del análisis de datos de expresión genética, se analizaron algunos de los métodos más reconocidos al respecto, y se desarrolló, evaluó y comparó una nueva propuesta basada en el método MOGA y en otros métodos biclustering actuales.

Se evaluó el desempeño del algoritmo MOGA al aplicarle cambios estructurales en dos de sus funciones centrales. Una función corresponde a la generación de las soluciones iniciales, las cuales se mejoran a partir de un proceso evolutivo. La segunda función corresponde al cálculo de la aptitud de cada solución generada, lo cual impacta fuertemente en los resultados finales. Se realizaron experimentos para evaluar estas propuestas, y se realizaron comparaciones con otros métodos encontrados en la literatura.

Se evaluaron los resultados de la nueva función de aptitud, basada en un cálculo de correlación, con respecto al cálculo del MSR. Los mejores resultados en cuanto a la significancia biológica obtenida fueron arrojados por la función de correlación, pero como desventaja se observó que el tiempo de procesamiento es mucho mayor con respecto al MSR.

Cada una de las funciones se evaluó con dos valores diferentes como umbral de similaridad, por su parte el MSR se comportó de manera muy similar con ambos umbrales de 75 y 100.

La función de correlación se probó con umbrales de 0.90 y 0.95, en ambos casos los resultados para todos los valores de p fueron de 100 %.

Otra prueba que se realizó utilizando los mismos parámetros anteriores para las dos funciones de aptitud, fue aplicar dos restricciones consideradas “fuertes” al momento de evaluar la significancia estadística de los biclusters descubiertos: la primera es que mínimo se tengan 10 genes del bicluster pertenecientes a una categoría GO, y la segunda es que mínimo el 50 % de los genes del bicluster pertenezcan a dicha categoría. En este caso los resultados para ambos valores del MSR fueron

bajos, mientras que la función de correlación con umbral de 0.95 arrojó buenos resultados, superando incluso al método OPSM que había obtenido de los mejores resultados para todos los valores de p .

La función de correlación fue modificada para obtener biclusters en los cuales hubiera genes con comportamiento en espejo, esta función modificada se probó con umbral de 0.95 y los resultados fueron verificados para probar que los biclusters obtenidos tienen significancia biológica, se clasificaron los biclusters de acuerdo a la anotación ontológica a la que pertenecen y se seleccionaron los genes en los que intervienen funciones en las que sus genes se comportan como espejo entre ellos.

5.2. Conclusiones

Los experimentos realizados muestran porcentajes muy altos de biclusters significativos descubiertos por el algoritmo modificado, superando significativamente a tres métodos reconocidos y citados ampliamente en la literatura.

Por otro lado, se modificó la función de aptitud con el objetivo de identificar genes que se correlacionan de forma inversa, esto es, grupos de genes que muestran gráficas de comportamiento en espejo. Las pruebas realizadas muestran que estos grupos de genes correlacionados inversamente, pueden estar interrelacionados dentro de alguna función o proceso biológico. Sobre esto último podemos concluir que el algoritmo propuesto aplicando la función modificada, es capaz de identificar genes relacionados biológicamente, que las funciones tradicionales para medir la coherencia de los biclusters, como el MSR, no pueden detectar sin invertir y duplicar los datos de expresión de entrada.

5.3. Trabajo futuro

Como trabajo a futuro se pueden realizar más pruebas con la función de correlación. Se pueden utilizar umbrales más altos para determinar hasta que límite es posible mejorar la significancia estadística de los biclusters descubiertos.

Un reto importante que queda por superar es disminuir el porcentaje de traslape entre los genes que presentan los diferentes biclusters. Esto se debe lograr sin disminuir sensiblemente el porcentaje de biclusters significativos generados.

Bibliografía

- [1] M. Ashburner, C. A. Ball, J. A. Blake, D. Botstein, H. Butler, J. M. Cherry, A. P. Davis, K. Dolinski, S. S. Dwight, J. T. Eppig, M. A. Harris, D. P. Hill, L. Issel-Tarver, A. Kasarskis, S. Lewis, J. C. Matese, J. E. Richardson, M. Ringwald, G. M. Rubin, and G. Sherlock. Gene ontology: tool for the unification of biology. *Nature Genetics*, 25(1):25–29, 2000.
- [2] W. Ayadi, M. Elloumi, and J.-K. Hao. Pattern-driven neighborhood search for biclustering of microarray data. *Bioinformatics*, 13:1471–2105, 2012.
- [3] B. P. Balanza. Tecnicas de evaluacion en algoritmos de biclustering sobre datos de expresion genomica. Technical report, Universidad de Sevilla, Departamento de Lenguajes y Sistemas Informaticos, 2007.
- [4] A. Ben-Dor, B. Chor, R. Karp, and Z. Yakhini. Discovering local structure in gene expression data: The order-preserving submatrix problem. In *Proceedings of the 6th International Conference on Computational Biology (RECOMB'02)*, pages 49–57, 2002.
- [5] G. F. Berriz, O. D. King, B. Bryant, C. Sander, and F. P. Roth. Characterizing gene sets with funcassociate. *Bioinformatics*, 19(18):2502–4, 2003.
- [6] E. I. Boyle, S. Weng, J. Gollub, H. Jin, D. Botstein, J. M. Cherry, and G. Sherlock. Go::termfinder-open source software for accessing gene ontology information and finding significantly enriched gene ontology terms associated with a list of genes. *Bioinformatics*, 20(18):3710–3715, 2004.
- [7] T. E. A. S. Centre. NASC's Bioinformatics Webservices (<http://nasc.nott.ac.uk>), <http://nasc.nott.ac.uk>.
- [8] I. N. Chamorro and J. A. N. Chamorro, editors. *Analisis de datos de expresion genica, de la informacion al conocimiento en la Biologia actual*. Facultad de Filosofia de la Universidad de Sevilla, Liber Amicorum Angel Nepomuceno, 2010.

- [9] Y. Cheng and G. M. Church. Biclustering of expression data. In *Proceedings of the 8th International Conference on Intelligent Systems for Molecular Biology (ISMB'00)*, pages 93–103, 2000.
- [10] S. Dharan and A. S. Nair. Biclustering of gene expression data using reactive greedy randomized adaptive search procedure. *BMC Bioinformatics*, 10(Suppl. 1):S27, 2009.
- [11] J. Ihmels, S. Bergmann, and N. Barkai. Iterative signature algorithm for the analysis of large-scale gene expression data. *Physical Review E*, 67:031902–1 – 031902–18.
- [12] J. Ihmels, S. Bergmann, and N. Barkai. Defining transcription modules using large-scale gene expression data. *Bioinformatics*, 20:1993–2003, 2004.
- [13] J. Ihmels, G. Friedlander, S. Bergmann, O. Sarig, Y. Ziv, and N. Barkai. Revealing modular organization in the yeast transcriptional network. *Nature Genetics*, 31:370–377, 2002.
- [14] Y. J. W. H, W. W, and P. S. Y. An improved biclustering method for analyzing gene expression profiles. *International Journal on Artificial Intelligence Tools - IJAIT*, 14(5):771–790, 2005.
- [15] J. Liu, J. Yang, and W. Wang. Biclustering in gene expression data by tendency. pages 182–193, 2004.
- [16] S. C. Madeira and A. L. Oliveira. Biclustering algorithms for biological data analysis: a survey. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 1(1):24–45, 2004.
- [17] R. Marti and M. Laguna. Scatter search. methodology and implementation in c. In *Kluwer Academic Publishers*, 2003.
- [18] S. Mitra and H. Banka. Multi-objective evolutionary biclustering of gene expression data. *Journal of the Pattern Recognition Society*, 39:2464–2477, 2006.
- [19] T. M. Murali and S. Kasif. Extracting conserved gene expression motifs from gene expression data. In *Proceedings of the Pacific Symposium on Biocomputing*, volume 8, pages 77–88, 2003.
- [20] Nepomuceno, A. Troncoso, and J-Aguilar-Ruiz. Biclustering of gene expression data by correlation-based scatter search. *BioData Mining*, 4:10.1186/1756–0381–4–3, 2011.
- [21] F. Ortega, editor. *Estrategias analiticas en la investigacion de nuevos biomarcadores*. Real Academia Nacional de Farmacia, MONOGRAFIA XXX. Biomarcadores. Analitica, diagnostico y terapeutica, 2010.
- [22] A. Prelic, S. Bleuler, P. Zimmermann, P. Buhlmann, W. Gruissem, L. Hennig, L. Thiele, and E. Zitzler. A systematic comparison and evaluation of biclustering methods for gene expression data. *Bioinformatics*, 22:1122–1129, 2006.

- [23] A. Prelic, S. Bleuler, P. Zimmermann, A. Wille, P. Buhlmann, W. Gruissem, L. Hennig, L. Thiele, and E. Zitzler. A systematic comparison and evaluation of biclustering methods for gene expression data. *Bioinformatics*, 22:1122–1129, 2006.
- [24] D. S. Rodriguez, J. C. Riquelme, and J. S. Aguilar. Analisis de datos de expresion genetica mediante tecnicas de biclustering. Technical report, Universidad de Sevilla, 2006.
- [25] L. Salwinski, C. Miller, A. J. Smith, F. Pettit, J. Bowie, and D. Eisenberg. The database of interacting proteins: 2004 update. *Nucl. Acids Res.*, 32:D449–451, 2004.
- [26] F. M. Sanchez, G. L. Campos, and N. I. de Andres. La convergencia de la informatica medica y la bioinformatica. *Servicios de Salud ¿estrategias o tecnologias?*. Madrid Editorial Medica Panamericana, 13:978–1402073762, 1999.
- [27] R. Sharan, R. Elkon, and R. Shamir. Cluster analysis and its applications to gene expression data. *Ernst Schering workshop on Bioinformatics and Genome Analysis*, pages 83–108, 2002.
- [28] A. Tanay, oded Sharan, and R. Shamir. Discovering statistically significant biclusters in gene expression data. *Bioinformatics*, 18(Suppl. 1):S136–S144, 2002.
- [29] the Gene Ontology. Gene Ontology Website (<http://www.geneontology.org>), <http://www.geneontology.org>.
- [30] P. H. Westfall and S. S. Young. Resampling-based multiple testing. *Wiley, New York*, page 340, 1993.
- [31] A. Wille, P. Zimmermann, E. Vranova, A. Furholz, O. Laule, S. Bleuler, L. Hennig, A. Prelic, P. von Rohr, L. Thiele, E. Zitzler, W. Gruissem, and P. Buhlmann. Sparse graphical gaussian modeling of the isoprenoid gene network in arabidopsis thaliana. *Genome Biology*, 5:R92, 2004.
- [32] L. X and W. L. Computing the maximum similary biclusters of gene expression data. *Bioinformatics*, 23:50–56, 2007.