



Subsecretaría de Educación Superior
Dirección General de Educación Superior Tecnológica
Instituto Tecnológico de La Paz

INSTITUTO TECNOLÓGICO DE LA PAZ
DIVISIÓN DE ESTUDIOS DE POSGRADO E INVESTIGACIÓN
MAESTRÍA EN SISTEMAS COMPUTACIONALES

**ALGORITMO GENÉTICO PARALELO PARA LA CLASIFICACIÓN DE SUBTIPOS DE
CÁNCER.**

T E S I S

QUE PARA OBTENER EL GRADO DE
MAESTRA EN SISTEMAS COMPUTACIONALES

PRESENTA:
CLAUDIA MARÍA LEÓN HIRALES

DIRECTOR DE TESIS:
M.C. JORGE ENRIQUE LUNA TAYLOR.

La paz Baja California Sur, Agosto 2015.





"2015, Año del Generalísimo José María Morelos y Pavón"

La Paz, B.C.S., **01/septiembre/2015**

DEPI/486/2015

Asunto: Autorización de impresión.

C.CLAUDIA MARÍA LEON HIRALES,
ESTUDIANTE DE LA MAESTRÍA EN
SISTEMAS COMPUTACIONALES,
P R E S E N T E.

Con base en el dictamen de aprobación emitido por el Comité Tutorial de la Tesis denominada: **"ALGORITMO GENÉTICO PARALELO PARA LA CLASIFICACIÓN DE SUBTIPOS DE CÁNCER"** mediante la opción de tesis (Proyectos de Investigación), entregado por usted para su análisis, le informamos que se **AUTORIZA** la impresión.

ATENTAMENTE
"Ciencia es Verdad, Técnica es Libertad"

M.A.T.I. LUÍS ARMANDO CÁRDENAS FLORIDO,
JEFE DE LA DIV. DE EST. DE POSGRADO E INV.



INSTITUTO TECNOLÓGICO DE LA PAZ
DIVISIÓN DE ESTUDIOS DE POSGRADO
E INVESTIGACIÓN

C.c.p. Coordinación de la Maestría.
C.c.p. Depto. de Servicios Escolares.

LACF/fkso*



DICTAMEN DEL COMITÉ TUTORIAL

SUBDIRECCIÓN ACADÉMICA DIVISIÓN DE ESTUDIOS DE POSGRADO E INVESTIGACIÓN.

La Paz, B.C.S., **01/septiembre/2015**

C. M.A.T.I. LUÍS ARMANDO CÁRDENAS FLORIDO,
JEFE DE LA DIVISIÓN DE ESTUDIOS DE
POSGRADO E INVESTIGACIÓN,
P R E S E N T E.

Por medio del presente, enviamos a usted dictamen del Comité Tutorial de tesis para la obtención del grado de Maestra, con los siguientes datos generales:


No. de Control M13310019	Nombre CLAUDIA MARÍA LEON HIRALES
Maestría en:	SISTEMAS COMPUTACIONALES
Título de la tesis: ALGORITMO GENÉTICO PARALELO PARA LA CLASIFICACIÓN DE SUBTIPOS DE CÁNCER	
DICTAMEN: Se autoriza el trabajo de investigación, en virtud de que realizó las correcciones correspondientes conforme a las observaciones planteadas por este Comité Tutorial.	

A t e n t a m e n t e.

El Comité Tutorial


MC. JESÚS ANTONIO CASTRO


MSC. ILIANA CASTRO LIERA


MC. JORGE ENRIQUE LUNA TAYLOR

c.c.p. Coordinador de la Maestría.
c.c.p. Departamento de Servicios Escolares.
c.c.p. Estudiante.

Resumen El cáncer es una de las principales causas de mortalidad en el mundo; en 2012 hubo más de 14 millones de nuevos casos y 8,2 millones de muertes relacionadas con el cáncer. Se prevé que el número de nuevos casos aumente en aproximadamente un 70 % en los próximos 20 años. Debido a la complejidad de esta enfermedad y, a que las estadísticas son alarmantes, ha llamado la atención de la comunidad científica. Dentro de los múltiples esfuerzos que se han realizado para abordar este problema se encuentra el desarrollo de algoritmos que tienen como objetivo clasificar y predecir los diferentes tipos de cáncer, a partir del análisis de expresión genética. Actualmente existe una gran variedad de algoritmos para dicho fin. Sin embargo, existe la necesidad de reducir significativamente el tiempo de ejecución de estos algoritmos y mejorar la tasa de éxito en el diagnóstico de un subtipo de cáncer y la tasa de éxito al pronosticar la respuesta a los tratamientos aplicados a los pacientes. Un correcto diagnóstico y pronóstico permite al médico elegir la mejor opción del tratamiento disponible para cada paciente en particular.

La presente investigación tuvo como objetivo el desarrollo de un algoritmo capaz de clasificar correctamente los subtipos del cáncer. El método propuesto se compone por:

- 1) Un algoritmo de filtrado, el cual tiene como objetivo seleccionar los genes cuyo nivel de expresión varía significativamente entre pacientes con diferentes subtipos de cáncer.

- 2) Un algoritmo genético que tiene como objetivo identificar un grupo de genes, entre los seleccionados previamente por el filtro que, con base a su nivel de expresión y apoyándose en una Máquina de Vectores de Soporte (MVS), permiten la clasificación correcta.

- 3) Una Máquina de Vectores de Soporte, la cual toma como características el nivel de expresión de los genes para calcular el hiperplano óptimo que divide dos clases de un subtipo de cáncer.

Una vez identificados los genes para la clasificación por medio del nivel

de expresión de pacientes cuyo subtipo de cáncer es conocido, se utiliza la MVS para clasificar y pronosticar nuevos casos. En éste trabajo se obtuvo el 100 % de clasificación correcta con la base de datos de Leucemia. Se logró una reducción del tiempo de ejecución del algoritmo de clasificación gracias a la paralelización de la función de aptitud del algoritmo genético, reduciendo su tiempo de ejecución alrededor de 27 veces con 1000 iteraciones en la fase del algoritmo genético en comparación con la versión secuencial.

Abstract Cancer is one of the main causes of mortality in the world; in 2012 there were over 14 million new cases and 8.2 million deaths related to cancer. It is expected that the number of new cases increased by approximately 70 % in the next 20 years. Due to the complexity of this disease and that the statistics are alarming, has called the attention of the scientific community. Within the many efforts that have been made to address this problem is the development of algorithms that have as objective sort and predict different types of cancer, on the basis of the analysis of gene expression. Currently there is a wide variety of algorithms for this purpose. However, there is a need to reduce significantly the time of implementation of these algorithms and improve the rate of exito in the diagnosis of a subtype of cancer and the rate of exito to predict the response to the treatments applied to the patients. A correct diagnosis and prognosis allows the doctor choose the best option of treatment available for each particular patient. The objective of this research was to the development of an algorithm able to correctly classify the subtypes of cancer. The proposed method is composed by:

- 1) A filtering algorithm, which has the purpose of selecting the genes whose expression level varies significantly between patients with different subtypes of cancer.

- 2) A genetic algorithm that has as objective to identify a group of genes, including the previously selected by the filter, which, based on its level of expression and by relying on a Support Vectors Machine (SVM), allow the

correct classification.

3) A Support Vector Machine, which takes as features the level of expression of the genes to calculate the optimal triangle that divides two classes of a subtype of cancer.

Once you have identified the genes for classification by means of the level of expression of patients whose cancer subtype is known, is used to classify the SVM and predict new cases. In this work, we obtained 100% correct classification with the database of leukemia. There was a reduction of the execution time of the ranking algorithm thanks to the parallelization of the role of fitness of the genetic algorithm, reducing its run time around 27 times with 1000 iterations in the phase of the genetic algorithm in comparison with the sequential version.

Índice general

Lista de figuras	7
Lista de tablas	9
Lista de algoritmos	10
1. Introducción	11
1.1. Antecedentes	11
1.2. Objetivos	13
1.2.1. General	13
1.2.2. Específicos	13
1.3. Organización de la tesis	13
2. Plantamiento del problema	15
2.1. Expresión genética	15
2.2. Microarreglos de ADN	17
2.3. Análisis de expresión genética	19
2.4. Algoritmo genético	21
2.4.1. Operadores Genéticos	22
2.5. Máquina de vectores de soporte(MVS)	26
2.6. CUDA	26
2.7. Planteamiento formal del problema	28
2.8. Trabajo previo relevante	29

2.8.1. Molecular Classification of Cancer: Class Discovery and Class Prediction by Gene Expression Monitoring (Golub <i>et al.</i> (1999))	29
2.8.2. Using Rank-1 Biclusters to Classify Microarray Data (Asgarian & Greiner (2007))	31
2.8.3. A multiple-filter-GA-SVM method for dimension reduction and classification of DNA-microarray data (Hernández-Montiel <i>et al.</i> (2011))	32
3. Metodología propuesta	35
3.1. Fitro BSS/WSS	35
3.2. Algoritmo Genético	37
3.2.1. Inicialización	37
3.2.2. Función de aptitud	38
3.2.3. Operadores genéticos	40
3.3. Clasificador	42
3.3.1. Método Dual de Descenso Coordinado de Larga Escala para MVS Lineales (Cho-Jui <i>et al.</i> (2008))	42
3.3.2. Implementación paralela de la MVS	43
4. Experimentos y Resultados	47
4.1. Distribución de los pacientes	48
4.2. Tiempo de ejecución	49
4.3. Tasa de éxito	50
5. Conclusiones y trabajo futuro	53
5.1. Sumario	53
5.2. Conclusiones	54
5.3. Trabajo futuro	54
A. Genes obtenidos en 30 ejecuciones	55

<i>ÍNDICE GENERAL</i>	6
B. 100 mejores genes obtenidos por el filtro BSS/WSS	58

Índice de figuras

2.1. Análisis por microarreglos de los niveles de expresión genética utilizando la técnica de "Spotted glass slide".	19
2.2. Técnicas de cuantificación de los niveles de expresión genética.	21
2.3. Operadores genéticos aplicados a una población.	23
2.4. Hiperplanos que genera la SVM. H1 y H2 podrían clasificar bien algunos elementos de entrada mientras que H3 no distingue bien entre las dos clases de elementos. De color verde los elementos de clase 1 y de color azul los elementos de clase 2.	27
2.5. Ilustración esquemática de la metodología de Golub <i>et al.</i> (1999)	30
2.6. Primera etapa del proceso general para clasificación y selección de genes con Multiple-filtro-AG-SVM.	34
2.7. Segunda etapa del proceso general para clasificación y selección de genes con Multiple-filtro-AG-SVM.	34
3.1. Esquema general del método propuesto.	36
3.2. Estructura de datos del AG.	38
3.3. Ejemplo de cruce de dos individuos.	42
3.4. Representación de la estructura de datos enviada al kernel.	44
3.5. Representación de la ejecución en paralelo de la función de aptitud de la GPU.	45
3.6. Hiperplano de separación óptimo.	46
4.1. Comparación del tiempo de ejecución	51

4.2. Comparación con otros métodos en porcentaje de éxito en clasificación correcta	52
---	----

Índice de tablas

4.1. Parámetros utilizados para medir el tiempo de ejecución del método propuesto.	49
4.2. Parámetros utilizados en Algoritmo 7.	50
4.3. Resultados obtenidos para medir el tiempo de ejecución. . . .	50
A.1. Resultado de las ejecuciones del método (Parte 1).	56
A.2. Resultado de las ejecuciones del método (Parte 2).	57

Lista de algoritmos

1.	RoBic (M,K, $h(\cdot)$): Bicluster_Membership	32
2.	$BIC(B(\cdot), A(\cdot), U_{Test}, L_{Train}) : L_{Test}$	33
3.	Inicialización	38
4.	Cálculo de la aptitud de un individuo	39
5.	Criterio de desempate	40
6.	Selección	41
7.	Método dual de descenso coordinado de larga escala para MVS lineales	43

Capítulo 1

Introducción

1.1. Antecedentes

Conforme pasan los años los científicos se van abriendo paso en las diferentes ramas del conocimiento. Un área de gran importancia para el desarrollo humano es sin duda la biología. Con el avance tecnológico han surgido nuevas soluciones a problemas de salud antes inimaginables. Estos avances han permitido desarrollar nuevas herramientas tanto para el diagnóstico como para el tratamiento de diferentes enfermedades.

Hoy en día la tecnología ha permitido obtener información muy relevante contenida dentro de las células, por ejemplo, se puede conocer la composición genética de los organismos e incluso identificar qué genes se expresan en un momento y condición dada. El análisis del comportamiento de los genes es una herramienta muy valiosa como parte del análisis clínico de un paciente.

Con el apoyo de la computación se ha logrado un importante impulso en diferentes áreas de la ciencia. Dentro de la biología, por ejemplo, ha permitido la obtención, almacenamiento y el análisis de grandes volúmenes de datos biológicos y generado información muy útil dentro del área médica (Sanchez *et al.* (1999)).

Como resultado de la combinación de las ciencias computacionales y

biológicas, surgió un área muy interesante: la Bioinformática. Según el NIH (Institutos Nacionales de Salud de los Estados Unidos), Bioinformática es la investigación, desarrollo y aplicación de herramientas computacionales y aproximaciones para la expansión del uso de datos biológicos, médicos, conductuales o de salud, incluyendo aquellas herramientas que sirvan para adquirir, almacenar, organizar, analizar o visualizar tales datos.

El reciente nacimiento de esta ciencia interdisciplinaria encargada de buscar soluciones informáticas a determinados problemas biológicos, surge como una solución ante la necesidad de búsqueda de conocimiento a través del análisis de grandes volúmenes de datos biológicos (Balanza (2007)).

Dentro de la biología experimental, los microarreglos de ADN se han consolidado como una tecnología que ha revolucionado el estudio de expresión de miles de genes de forma simultánea. Los microarreglos, también conocidos como biochip o DNA chip, se fundamentan en la hibridación molecular y obtienen como resultado una matriz de puntos en el que la lectura de presencia o ausencia de un color se identifica con el gen expresado o no, respectivamente. De este modo se puede obtener la huella genética o cuadro genómico de una muestra bajo estudio (Chamorro & Chamorro (2010)). Como resultado de los experimentos con microarreglos de ADN, se obtienen grandes matrices de datos con información sobre el nivel de expresión de miles de genes sobre decenas o cientos de condiciones experimentales.

Por su parte, dentro de los avances tecnológicos ha crecido en gran medida la rama de la programación paralela y junto con el desarrollo de nuevo hardware con grandes tecnologías innovadoras, se han desarrollado nuevos paquetes de software que revolucionan la manera en que los desarrolladores afrontan los problemas en cuanto al manejo de datos con gran cantidad de información.

Como un ejemplo de avance tecnológico, Cuda C es una herramienta de programación paralela que hace uso de la potencia de las tarjetas gráficas para realizar el manejo de mayor información en menor cantidad de tiempo.

1.2. Objetivos

1.2.1. General

Desarrollar un algoritmo genético paralelo, utilizando la GPU, para la clasificación de subtipos de cáncer.

1.2.2. Específicos

- Identificar fortalezas y debilidades de los métodos actuales de clasificación y pronóstico de subtipos de cáncer, que nos orienten en el diseño e implementación de un método propio basado en estrategias de cómputo evolutivo.

- Determinar los módulos por paralelizar del método propuesto e implementarlo en paralelo utilizando la tecnología CUDA sobre GPU.

- Identificar y adquirir las bases de datos biológicas más representativas, utilizadas como casos de prueba por la comunidad científica que atiende el problema de clasificación de subtipos de cáncer.

- Contribuir con el diseño de un método propio de clasificación con el objetivo de mejorar el porcentaje de éxito de correcta clasificación y/o el tiempo de procesamiento; generando además la posibilidad de identificar nuevos genes no relacionados hasta el momento con algún subtipo de cáncer.

1.3. Organización de la tesis

Este trabajo consta de cinco capítulos organizados de la siguiente manera.

En el capítulo 2 se establece el planteamiento del problema, introduciendo los conceptos relevantes: expresión genética, algoritmo genético, máquina de soporte vectorial, GPGPU y CUDA C. Posteriormente se presenta la definición formal del problema y se analiza el trabajo previo relevante.

En el capítulo 3 se presenta con detalle la propuesta propia, que consiste en la implementación en paralelo de un algoritmo para la clasificación de subtipos de cáncer usando GPGPU. El método de clasificación se basa en el análisis de datos de expresión genética de los pacientes, a través de máquinas de soporte vectorial en combinación con un algoritmo genético.

En el capítulo 4 se presenta el diseño de los experimentos realizados y los resultados obtenidos, y se muestran gráficas comparativas con otros métodos relevantes encontrados en la literatura.

En el capítulo 5 se exponen las conclusiones de este trabajo y se presenta una lista de actividades a realizar como trabajo futuro.

Capítulo 2

Plantamiento del problema

2.1. Expresión genética

Se llama Expresión Genética a la transcripción de la información almacenada en un gen para crear una molécula de ácido ribonucleico (ARN). Un gen es un segmento de la cadena ácido desoxirribonucleico (ADN) y el ARN es una especie de copia de ese segmento de ADN que se utiliza como guía para la creación de una proteína. Cada célula contiene miles o decenas de miles de genes que codifican proteínas pero, en un determinado instante, la célula sólo expresa un subconjunto de esos genes para llevar a cabo procesos celulares. Hay varias condicionantes que regulan cuales genes se expresan en un momento dado:

- Función de la célula en un tejido particular.
- Estado de desarrollo del organismo.
- Respuesta ante estímulos externos.
- Presencia de alguna enfermedad.
- Especificidad temporal según la etapa de vida del organismo.

El análisis del nivel de expresión de distintos genes frente a diferentes con-

diciones experimentales es una tarea fundamental que permite el estudio de una gran variedad de problemas biológicos que se plantean en diversos organismos (Balanza (2007)). Los niveles de expresión genética pueden determinarse para diferentes muestras tomadas en instantes de tiempo en múltiples procesos biológicos (diferentes fases de la división celular) o en condiciones diferentes (por ejemplo, muestras de tumores con diagnóstico histopatológico diferente). La información para cada gen corresponde a un vector de alta dimensión representando su perfil de expresión. Los valores de expresión de los genes individuales muestran la gran varianza biológica dentro de muestras de tejido de la misma clase (Mittra & Banka (2006)).

La comparación entre distintos perfiles de expresión genética es una herramienta básica para poder responder a un gran número de cuestiones biológicas. De estas cuestiones cabe destacar la identificación de los genes de un organismo que se activan durante un ciclo celular o una producción de proteínas para el exterior. Cobran también mucha importancia las investigaciones realizadas sobre el efecto de las enfermedades en las expresiones genéticas. En los últimos años el estudio basado en datos de expresión ha sido también de gran ayuda en las anotaciones realizadas sobre los genomas secuenciados hasta el momento. Cuando el ADN se secuencia, una de las tareas que cobra más importancia es la de detectar en qué tramos de dicha secuencia podemos encontrar los genes y cuál es la función de éstos.

A la fecha se han desarrollado distintas tecnologías con el fin de obtener, almacenar y analizar esta información. Muchas de estas tecnologías se basan en obtener los datos de expresión de un sólo gen en determinadas condiciones experimentales. Frente a estas técnicas han aparecido en los últimos años tecnologías que nos permiten obtener los datos de expresión de una gran cantidad de genes de forma simultánea. Esta generación masiva de datos ofrece las siguientes ventajas frente al estudio individual de los genes:

- Un estudio masivo de datos facilita la identificación de genes individua-

les que son expresados de manera desmesurada en algún estadio biológico concreto.

- El análisis simultáneo de un conjunto de genes permite revelar patrones similares de comportamiento en determinadas condiciones experimentales, al igual que encontrar grupos de genes que reaccionen de forma inversa ante determinados estímulos.

Una de las tecnologías de generación masiva de datos de expresión más utilizadas hoy en día es la creación de Microarreglos de ADN (Rodriguez *et al.* (2006)).

2.2. Microarreglos de ADN

El uso de Microarreglos (Figura 2.1), cuya tecnología surgió del trabajo pionero de un grupo de científicos de Stanford y el NIH, entre otros, ha emergido como una potente técnica para la medición de datos de expresión genética y la comparación de la abundancia relativa de ARN mensajero generado en distintas pruebas biológicas.

El Microarreglo, también llamado DNA chip o Biochip, es un soporte sólido construido normalmente en cristal o en membrana de nylon. Existen diversas técnicas para construir estos chips biológicos integrados: fotolitografía, robots piezoeléctricos, uso de haces de fibra óptica, entre otras. Para la creación de un Microarreglo, en primer lugar se colocan trozos de ADN conocidos, cuyos niveles de expresión pueden ser cuantificados en una micromatriz del biochip. Después se realizan experimentos bajo una serie de condiciones sobre células de distintos tejidos, extrayendo el ARN mensajero generado por los genes de dichas células. Estas moléculas de ARNm se marcan con fluidos fluorescentes o radiactividad y son transformadas a un tipo especial de ADN (ADNc o ADN complementario), colocándose poste-

riormente en las micromatrices para comenzar el proceso de hibridación.

La hibridación del ADN es el proceso más común para detectar un gen particular o un segmento de un ácido nucleico. El objetivo es crear cadenas dobles de ADN a partir de las cadenas simples que se van a sondear (las que fueron colocadas inicialmente en las matrices) y otras cadenas simples marcadas (las obtenidas a partir de los experimentos y que son llamadas sondas). Después del proceso de hibridación se eliminan todas las cadenas que no se han podido unir, mediante lavados (sólo las moléculas que hibridan permanecerán en el biochip) y se procede al revelado mediante un escáner óptico o con microscopía láser confocal.

El resultado final es una matriz en la que cada una de las celdas está marcada con un determinado color. Por lo regular las filas corresponden a los genes y las columnas a las condiciones experimentales. El color de cada celda de la matriz representa el grado de expresión genética de dicho gen frente a una determinada condición experimental (Rodriguez *et al.* (2006)).

El advenimiento de las tecnologías de microarreglos de ADN ha revolucionado el estudio experimental de la expresión genética. Miles de genes son probados rutinariamente en forma paralela, reportándose los niveles de expresión de su ARNm transcrito. Mediante la repetición de tales experimentos en diferentes condiciones (por ejemplo, pacientes diferentes, tejidos diferentes o diferentes entornos de células) pueden ser anotados los datos de decenas a cientos de experimentos simultáneamente (Yang & Wang (2004)).

Uno de los objetivos del análisis de expresión de genes es el descubrimiento de nuevos biomarcadores. La identificación y análisis de biomarcadores nos permite diagnosticar una enfermedad, la susceptibilidad de padecerla, detectar la exposición a un organismo patógeno o conocer la respuesta a un determinado tratamiento farmacológico.




Figura 2.1: Análisis por microarreglos de los niveles de expresión genética utilizando la técnica de "Spotted glass slide".

2.3. Análisis de expresión genética

La tecnología de microarreglos de ADN ha alcanzado recientemente un papel central en la investigación biológica y biomédica. Permiten el seguimiento de los niveles de transcripción de miles de genes simultáneamente, mientras que la célula se somete a un conjunto de condiciones o procesos específicos. La aplicación de esta tecnología tiene un impacto importante en trabajos como la anotación funcional de los genes, la reconstrucción de la red genética para el diagnóstico de condiciones de la enfermedad y los efectos característicos de tratamiento médico. Un paso clave en el análisis de datos de expresión genética es la identificación de grupos de genes que exhiben patrones de expresión similares. El agrupamiento de datos de expresión de genes en grupos homogéneos tiene un papel decisivo en la anotación funcional, clasificación de tejido y motivos de identificación (Sharan *et al.* (2002)).

Una de las técnicas importantes utilizadas para el análisis de expresión ha sido la de Clustering, que consiste en identificar grupos de genes que presentan patrones de comportamiento similar. Sin embargo, este proceso

presenta algunas limitaciones. En primer lugar, el Clustering se basa en la suposición de que los genes relacionados se comportan de manera similar bajo todas las condiciones experimentales. Este supuesto es razonable cuando el conjunto de datos contiene algunas condiciones de un experimento único enfocado, pero no se sostiene para grandes conjuntos de datos que contienen cientos de condiciones heterogéneas de muchos experimentos. En segundo lugar, una solución de clústeres es a menudo una partición de los genes en conjuntos disjuntos, lo que implica una asociación de cada gen con una sola función biológica o proceso que puede ser una simplificación excesiva del sistema biológico.

Para superar los inconvenientes del Clustering se pretende identificar grupos de genes que exhiben comportamientos similares bajo un subconjunto de condiciones. En términos de la matriz de expresión de datos, se busca una submatriz *homogénea* cuyas filas y columnas corresponden a subconjuntos de genes y condiciones, respectivamente. A estas submatrices se les denomina biclusters y al proceso de detección de éstas se le denomina biclustering (Tanay *et al.* (2002)).

Para poder analizar datos de expresión genética de forma automática con la ayuda de métodos computacionales, es necesario poder contar con dichos datos en formato electrónico. Existen diversas técnicas que cuantifican el nivel de expresión de los genes en estudio, permitiendo de esta manera el poder almacenarlos y tratarlos de forma automática. Entre ellas se encuentran técnicas basadas en secuenciamiento ESTs (marcadores de secuencia expresada), la técnica SAGE (análisis serial de expresión de genes) basada en el principio de que un segmento corto de ADN permite identificar un único gen transcrito; y la tecnología de microarreglo, la más utilizada actualmente para el análisis de datos de expresión genética. La Figura 2.2 presenta cómo es posible la utilización de éstas tres técnicas, a partir de un solo experimento biológico (Balanza (2007)).




Figura 2.2: Técnicas de cuantificación de los niveles de expresión genética.

2.4. Algoritmo genético

Los Algoritmos genéticos (AG) son métodos adaptativos que pueden ser usados para resolver problemas de optimización basados en el proceso natural de selección. Se parte de una población compuesta por un conjunto de individuos, donde cada uno es una solución potencial del problema tratado. A dicha población se le aplica una serie de operadores genéticos: selección, cruce y mutación, utilizados para mantener y generar a los individuos más aptos en las generaciones futuras, con el objetivo de converger, después de un cierto número de generaciones, en un resultado óptimo del problema.

Los algoritmos genéticos (AG) fueron propuestos originalmente por Holland (Kim-Fung *et al.* (2012)). En su primera versión, conocida como “Algoritmo Genético Simple”, los individuos se representan como cadenas binarias conocidas como cromosomas, en las que cada bit al que se denomina gen,

representa una respuesta a una proposición lógica sobre una de las características de la solución candidata del problema.

El concepto central de los algoritmos genéticos es el de población, que se define como un conjunto de individuos C_i donde $i = 1, \dots, n$. Donde n es el tamaño de la población.

En la versión con representación real del AG, cada individuo es un vector de números reales que representan un punto en el espacio de búsqueda R^n .

$$C = [x_1, x_2, \dots, x_{n-1}, x_n] \quad \forall J | J \in [1, n], x_J \in R \quad (2.1)$$

Los algoritmos genéticos inician con una población P_g , donde g es el número de generaciones que se han ejecutado, que puede ser generada de forma aleatoria. Posteriormente se calcula la aptitud de sus individuos y se aplican los operadores genéticos para determinar a los individuos que formarán la siguiente generación P_{g+1} de manera iterativa. Generalmente, existe diversos criterios de parada que pueden ser el arribo a una generación g_{max} , fijada antes de iniciar el algoritmo, la ejecución de un cierto número de iteraciones sin mejorar los resultados obtenidos, o haber alcanzado el resultado óptimo buscado.

La aptitud de los individuos se evalúa por medio de una función de aptitud $f(C)$ que permite medir el grado en que el individuo cumple con el objetivo del problema de optimización. Antes de iniciar el algoritmo, el diseñador puede establecer valores mínimo, f_{min} , y máximo, f_{max} para $f(C)$, que definirán los límites de rechazo para soluciones candidatas con desempeño eficiente (Castro-Liera (2011)).

2.4.1. Operadores Genéticos

Para el paso de una generación a la siguiente se aplican una serie de operadores genéticos. Los más empleados son los operadores de selección, cruce y mutación. (Figura 2.3).




Figura 2.3: Operadores genéticos aplicados a una población.

Selección

Los algoritmos de selección son los encargados de escoger cuáles individuos van a disponer de oportunidades de reproducirse y cuáles no. Puesto que se trata de imitar lo que ocurre en la naturaleza, se otorga una mayor oportunidad de reproducción a los individuos más aptos. Por lo tanto, la selección de un individuo está relacionada con su valor de aptitud. Sin embargo, no se elimina por completo la posibilidad de reproducción de los individuos menos aptos, lo cual permite mantener cierto nivel de diversidad dentro de la población.

Los algoritmos de selección pueden ser divididos en dos grandes grupos: probabilísticos y determinísticos. Ambos tipos de algoritmos basan su funcionamiento en el principio indicado anteriormente, sin embargo, como su nombre indica, el primer tipo adjudica las posibilidades de selección del individuo más apto con un importante componente basado en el azar. Es en este grupo donde se encuentran los algoritmos de selección como los de ruleta o por torneo. El segundo grupo engloba una serie de algoritmos que, dada la aptitud conocida de cada individuo, asignan a cada uno el número de veces que será escogido para reproducirse. Esto puede evitar problemas

de predominancia de ciertos individuos. Cada uno de estos algoritmos presentan variaciones respecto al número de veces que se seleccionan los mejores individuos, definiendo así el nivel de presión en la búsqueda dentro del espacio probable donde se encuentran las mejores soluciones (en el caso de seleccionar con mayor probabilidad los mejores individuos) o bien repartir la búsqueda por el espacio de estados, sin dejar de establecer preferencia por la mejor zona. Algunos de estos algoritmos son: sobrante estocástico, universal estocástica o muestreo determinístico.

Cruce

Una vez seleccionados los individuos, éstos son recombinados para producir la descendencia que se insertará en la siguiente generación. Su importancia en la transición entre generaciones es elevada puesto que las tasas de cruce con las que se suele trabajar rondan el 90 %.

Los diferentes métodos de cruce pueden operar de dos formas diferentes. Si se opta por una estrategia de reemplazo generacional los descendientes sustituyen a sus padres, independientemente de que estos últimos pueden tener una mejor aptitud. Por el contrario, en una estrategia sin reemplazo generacional la descendencia pasará a la siguiente generación únicamente si supera la aptitud de los padres.

La idea principal del cruce se basa en que, si se seleccionan dos individuos correctamente adaptados al medio y se obtiene una descendencia que comparta genes de ambos, existe la posibilidad de que los genes heredados sean precisamente los causantes de la bondad de los padres. Al compartir las mejores características de dos individuos, la descendencia (o al menos parte de ella) debería tener una mayor aptitud que cada uno de los padres por separado. Optando por una estrategia de cruce sin reemplazo generacional garantizamos que pasen a la siguiente generación los mejores individuos. Si, aún con una aptitud peor, se opta por insertar a la descendencia, en posteriores cruces se podrán volver a obtener estos padres, recuperando así una

buena aptitud previamente perdida.

Existen una gran variedad de algoritmos de cruce. Sin embargo los más empleados son: cruce de 1 punto, cruce de 2 puntos, cruce uniforme.

Mutación

La mutación de un individuo implica que alguno de sus genes, generalmente uno sólo, varíe su valor de forma aleatoria.

Aunque se pueden seleccionar los individuos directamente de la población actual y mutarlos antes de introducirlos en la nueva población, la mutación se suele utilizar después del operador de cruce. Primero se seleccionan dos individuos de la población para realizar el cruce. Si el cruce tiene éxito entonces uno de los descendientes (o ambos) se muta con cierta probabilidad P_m . Se trata de imitar de esta manera el comportamiento que se da en la naturaleza, ya que en la creación de un nuevo organismo no se está exento de algún tipo de error, por lo general sin mayor trascendencia, en el paso de la carga genética de padres a hijos.

La probabilidad de mutación normalmente se mantiene baja, generalmente menor al 1 %. Esto se debe, principalmente, a que los individuos suelen tener una aptitud menor después de mutados. Sin embargo la mutación es necesaria para garantizar que ningún punto del espacio de búsqueda tenga una probabilidad nula de ser examinado.

La mutación más usual es el reemplazo aleatorio. Este consiste en variar aleatoriamente un gen de un cromosoma. Si se trabaja con codificaciones binarias, consistirá simplemente en negar un bit.

También es posible realizar la mutación intercambiando los valores de dos alelos del cromosoma. Con otro tipo de codificaciones no binarias existen otras opciones:

- Incrementar o decrementar al valor de un gen, una pequeña cantidad generada aleatoriamente.
- Multiplicar un gen por un valor aleatorio próximo a 1.

Existen implementaciones de Algoritmos Genéticos en las que no todos los individuos tienen los cromosomas de la misma longitud. Esto implica que no todos ellos codifican el mismo conjunto de variables. En este caso existen mutaciones adicionales, como puede ser añadir un nuevo gen o eliminar uno ya existente (Gestal *et al.* (2010)).

2.5. Máquina de vectores de soporte(MVS)

Las máquinas de vectores de soporte (Support Vector Machines, SVMs), son un conjunto de algoritmos de aprendizaje supervisado desarrollados por Vladimir Vapnik y su equipo en los laboratorios de AT&T. Estos métodos están propiamente relacionados con problemas de clasificación y regresión. Dado un conjunto de ejemplos de entrenamiento (de muestras), podemos etiquetar las clases y entrenar una MVS para construir un modelo que prediga la clase de una nueva muestra. Intuitivamente, una MVS es un modelo que representa a los puntos de muestra en el espacio, separando las clases por un espacio lo más amplio posible. Cuando las nuevas muestras se ponen en correspondencia con dicho modelo (en función de su proximidad) pueden ser clasificadas a una u otra clase.

En la figura 2.4 se muestra de forma gráfica un ejemplo de la representación de datos de entrenamiento. En este ejemplo el algoritmo MVS trata de encontrar un hiperplano unidimensional que une a las variables predictoras y constituye el límite que define si un elemento de entrada pertenece a una clase o a la otra.

2.6. CUDA

La demanda excesiva de procesamiento de datos de una gran variedad de aplicaciones actuales puede implicar que correr un algoritmo y esperar por los




Figura 2.4: Hiperplanos que genera la SVM. H_1 y H_2 podrían clasificar bien algunos elementos de entrada mientras que H_3 no distingue bien entre las dos clases de elementos. De color verde los elementos de clase 1 y de color azul los elementos de clase 2.

resultados sea una tarea muy tardada, aún considerando la potencia de los procesadores actuales. Este tipo de aplicaciones requieren del análisis complejo de grandes volúmenes de datos, como en problemas de reconocimiento de patrones, visión computacional, inteligencia artificial, análisis molecular, entre varios más.

Si bien adquirir un procesador moderno es muy costoso, crear un cluster de procesadores para reducir los tiempos de procesamiento es aún más costoso además de considerar los gastos para mantener los equipos a una temperatura adecuada, su mantenimiento y el espacio que ocupan.

CUDA son las siglas de Compute Unified Device Architecture (Arquitectura Unificada de Dispositivos de Cómputo), una arquitectura de cálculo

paralelo creada por NVIDIA para sus tarjetas gráficas que aprovecha la gran potencia de la GPU (unidad de procesamiento gráfico) para proporcionar un gran incremento del rendimiento del sistema. A la fecha existe un incremento exponencial del uso de dicha arquitectura, a tal grado que las últimas versiones de un gran abanico de aplicaciones incluyen soporte para acelerar sus procesos con el uso de CUDA.

2.7. Planteamiento formal del problema

Como datos de entrada se tiene una matriz de n por m , donde el elemento a_{ij} representa el nivel de expresión del gen de la fila i del paciente de la columna j . Generalizando, se considera la matriz de datos A , como un conjunto de filas X y un conjunto de columnas Y , donde X_i corresponde al vector renglón con los niveles de expresión del gen i para todos los pacientes; y Y_j corresponde al vector columna con los niveles de expresión de todos los genes del paciente j .

Considerando a $A_{IJ} = (I, J)$ como un subconjunto de filas y un subconjunto de columnas donde $I \subseteq X$ y $J \subseteq Y$. El problema específico tratado por el algoritmo es:

Dada una matriz de datos A , se requiere identificar el subconjunto de subíndices de renglones G del tamaño I , donde $I = [1, n]$, de tal manera que el entrenamiento de una máquina de vectores de soporte con el subconjunto de datos $A(I, JE)$ permita clasificar correctamente a un subconjunto de pacientes de prueba en base al subconjunto de datos $A(I, JP)$

Donde:

I : incluye únicamente los renglones con subíndices del subconjunto,

G y JE : subconjunto de columnas de pacientes de entrenamiento,

JP : subconjunto de columnas de los pacientes de prueba.

2.8. Trabajo previo relevante


A continuación se presenta el análisis de tres trabajos relevantes presentados en la literatura, relacionados con la clasificación y pronóstico de subtipos de cáncer.

2.8.1. Molecular Classification of Cancer: Class Discovery and Class Prediction by Gene Expression Monitoring (Golub *et al.* (1999))

Los autores presentan un método de análisis de vecindario para la distinción de clases, agrupando los genes con patrones similares en su expresión que utiliza el nivel de expresión y el grado de correlación de los genes. Aplican un cálculo para cada gen asignando un puntaje asociado con cada una de las clases. Con la suma de los puntajes, se determina la clase a la que se asigna.

El resultado de este método es validado a través de la técnica de cross-fold. Para los experimentos de clasificación usaron 50 genes informativos del conjunto de datos de cáncer de leucemia obtenidos previamente, logrando un total de 36 predicciones correctas de 38 pacientes.

En la Figura 2.5 se muestra un diagrama de la metodología de Golub *et al.* (1999). En el inciso A se muestra un esquema del método de Análisis de Vecindario. La distinción de clases se representa por un patrón de expresión idealizado c , en el cual el nivel de expresión es uniformemente alto en la clase 1 y uniformemente bajo en la clase 2. Cada gen se representa por un vector, de acuerdo a su nivel de expresión en las muestras tumorales. El conjunto de datos se compone de 6 muestras de AML y 6 muestras de ALL. El gen g_1 está bien correlacionado con la clase distinción, mientras que g_2 es bajamente correlacionado. El análisis de vecindario implica contar el número de genes con diferentes niveles de correlación con c . El resultado se compara con la correspondiente distribución obtenida aleatoriamente de la expresión de patrones idealizada c^* , obtenida por permutación aleatoria de

Figura 2.5: Ilustración esquemática de la metodología de Golub *et al.* (1999)

las coordenadas de c . Una alta densidad inusual de genes indica que hay muchos más genes relacionados con el patrón de lo esperado por azar.

En el inciso B se muestra la clase predictor. La predicción de una nueva muestra se basa en el "voto ponderado" de un conjunto de genes informativos. Cada uno de estos genes g_i vota por AML o ALL, dependiendo de si su nivel de expresión x_i en la muestra está mas cerca de la media de AML o la media de ALL.

Con este procedimiento lograron obtener una clase predictora que detec-

ta automáticamente el tipo de leucemia y hace una distinción entre el tipo de leucemias mieloide aguda (AML) y linfoblastica aguda (ALL) sin conocimiento previo de estas clases. Se obtuvo una clase predictora, que fue capaz de determinar la clase de los nuevos casos de leucemia.

2.8.2. Using Rank-1 Biclusters to Classify Microarray Data (Asgarian & Greiner (2007))

En este trabajo utilizan un algoritmo para identificar biclusters basados en un método matemático llamado "Matriz de aproximación rank-1", el cual es aplicado para reducir el tamaño del conjunto de datos. Cada bicluster es un subconjunto de genes y un subconjunto de pacientes. Los genes en un blicluster tienen valores de expresión que están correlacionados. Basado en los biclusters descubiertos, se usa una máquina de soporte vectorial para realizar la clasificación. Los conjuntos de datos de leucemia, colon, próstata y cáncer de pulmón se usan para los diagnosticos experimentales, obteniendo una tasa de éxito del 84.72 % para el conjunto de datos de cáncer de leucemia. El tiempo de ejecución del método fue aproximadamente de 1 minuto para obtener cada bicluster, de una matriz de datos de alrededor de 20 mil genes de 100 pacientes. El sistema de computo que se utilizo fue una máquina Pentium 4 con 1.3G de memoria.

Las dos principales contribuciones que se presentan en este trabajo son:

- Un algoritmo ROBIC con el que encuentran los bicluster de los datos de los microarreglos, basado en la mejor matriz de aproximación rank-1 (Algoritmo 1).
- Un método BIC que utiliza un algoritmo de biclustering para entrenar un clasificador simple. (Algoritmo 2)

Este método obtuvo por lo menos un 80 % de precisión en los 8 conjuntos de datos que se evaluaron, y más del 90 % en 3 de ellos. Se considera por lo menos tan bueno como muchos de los otros algoritmos con los que se comparó, y obtuvo mejores resultados en conjuntos de difícil pronóstico.

Algoritmo 1 RoBic (M,K, h(.)): Biclust_Membership

Entrada: M es la matriz de datos, K es el numero de bicluster, $h(\cdot)$ es función hinge, $M^{(1)} = M$

Salida: K biblusters $R = \{B_k\}$.

- 1: **para** $K = 1..K$ **hacer**
- 2: Cálcular la descomposición mayor del valor of $M_{(k)}$,
- 3: $[\alpha, v, \beta] = SVD(M^{(k)}, 1)$
- 4: $\bullet \alpha \times v \times \beta^T = \text{Mejor aproximación rank} - 1 \text{ para } M^{(k)}$
- 5: $\bullet \alpha(\text{resp.}, \beta)$ Representa los genes(*resp.*, *pacientes*)
- 6: $\alpha^{(s)} = \text{Sort}(\alpha); \beta^{(s)} = \text{Sort}(\beta)$
- 7: $M_{sorted}^{(k)} := BiSort[M^{(k)}, \alpha/\alpha^{(s)}, \beta/\beta^{(s)}]$
 $M_{sorted}^{(k)}$ las filas se reordenan para que coincida con $\alpha^{(s)}$
 Y las columnas se reordenan para que coincidan con $\beta^{(s)}$
- 8: $[i, j] = h(M_{sorted}^{(k)}, \alpha^{(s)}, \beta^{(s)})$
 $i(\text{resp.}, j)$ es hinge el valor para los genes(*resp.*, *pacientes*)
 $\alpha^{(s,i)} := \langle \alpha_1^{(s)}, \alpha_2^{(s)}, \dots, \alpha_i^{(s)}, 0, 0, \dots, 0 \rangle$
 $\beta^{(s,i)} := \langle \beta_1^{(s)}, \beta_2^{(s)}, \dots, \beta_i^{(s)}, 0, 0, \dots, 0 \rangle$
- 9: $M^{(k+1)} = M_{Sorted}^{(k)} - \alpha^{(s,i)} \cdot v \cdot \beta^{(s,i)T}$

$$B_k(j) = \begin{cases} 1 & \text{Si paciente } j \text{ es un bicluster } k \\ 0 & \text{en caso contrario} \end{cases}$$
- 10: **fin para**
- 11: **devolver** K biblusters $R = \{B_k\}$.

2.8.3. A multiple-filter-GA-SVM method for dimension reduction and classification of DNA-microarray data (Hernández-Montiel *et al.* (2011))

Hernández-Montiel *et al.* (2011) proponen un múltiple-filtro, y utilizan un algoritmo genético(AG) combinado con una máquina de soporte vectorial (MVS) para la selección de genes y la clasificación de datos obtenidos de microarreglos de ADN. Este método selecciona un subconjunto de genes que clasifiquen los datos más eficientemente.

Primero utiliza tres métodos estadísticos como filtro para reducir el núme-

Algoritmo 2 $BIC(B(\cdot), A(\cdot), U_{Test}, L_{Train}) : L_{Test}$

Entrada: $B(\cdot)$: Algoritmo de biclustering (RoBic Algoritmo 2 o Plaid);
 $A(\cdot)$: Algoritmo de aprendizaje (MVS o NaiveBayes);
 U_{Test} : Datos de prueba sin etiquetar; U_{Train} Son las características asociadas con los datos de entrenamiento;
 L_{Train} Clases etiquetadas asociadas con los datos de entrenamiento;

Salida: L_{Test} : Las etiquetas previstas para los datos de prueba.

- 1: $R = B(U_{Train} \cup U_{Test}, \dots)$
 Produce biclusters basado en la etiqueta del conjunto de entrenamiento y el conjunto de prueba. (Esto puede implicar selección de características).
 - 2: $C = A(R|_{Train} + L_{Train})$
 Es el clasificador producido por la porción del conjunto de entrenamiento de R junto con las etiquetas asociadas al conjunto de entrenamiento.
 - 3: **para** $i = 1; i < u; i++$ **hacer**
 - 4: $L_{Test}[i] = C(R_{Test}[i])$
 Usa el clasificador C para predecir la etiqueta de la clase de cada muestra en el conjunto de prueba. $R_{Test}[i]$ es la $q + i^{th}$ fila de R .
 - 5: **fin para**
 - 6: **devolver** L_{Test}
-

ro de genes usados en la clasificación. Los filtros son: BSS/WSS, T-Statistic y Wilconxon. Después de aplicar los filtros, el subconjunto de genes obtenidos se pasa a un algoritmo genético el cual, con la ayuda de una máquina de soporte vectorial, obtiene la selección final de genes para ser usados en la clasificación. Fueron usados los conjuntos de datos de leucemia y colon para los experimentos. Con el conjunto de datos de leucemia se obtuvo una tasa de éxito del 98.61 %. No está claro si en el último experimento se han utilizado los datos de los pacientes que también fueron usados en la fase de filtrado.

La primera etapa del método propuesto se presenta en la Figura 2.6 y la etapa dos se representa en la Figura 2.7.




Figura 2.6: Primera etapa del proceso general para clasificación y selección de genes con Multiple-filtro-AG-SVM.




Figura 2.7: Segunda etapa del proceso general para clasificación y selección de genes con Multiple-filtro-AG-SVM.

Capítulo 3

Metodología propuesta

En la Figura 3.1 se muestra el esquema general del método propuesto, el cual consiste principalmente de tres fases: Un filtro, un algoritmo genético (AG) y un clasificador. En la primera fase se hace un análisis estadístico de los datos de expresión genética por cada gen, con el fin de filtrar genes más significativos que pasarán a la siguiente fase. En la segunda fase, el algoritmo genético tiene como objetivo identificar la mejor combinación de genes cuyos niveles de expresión permitan clasificar de forma correcta el subtipo de cáncer que padece un paciente. En la fase tres, el algoritmo genético se apoya en una máquina de soporte vectorial (MVS) utilizada para evaluar que tan bien clasifica un subconjunto de genes, y es la base para el cálculo de la aptitud de las soluciones potenciales del AG(individuos). La MVS se implementó de acuerdo al método propuesto por Cho-Jui *et al.* (2008).

3.1. Filtro BSS/WSS

La primera fase del método consiste en aplicar un filtro para la reducción de datos de la matriz de expresión original. Partimos de una matriz de $M \times N$, donde M corresponde a las columnas, las cuales representan a los genes y N que corresponde a las filas que representan a los pacientes. El objetivo




Figura 3.1: Esquema general del método propuesto.

del filtro es seleccionar el subconjunto de genes que presentan, de acuerdo a sus niveles de expresión, un comportamiento más diferenciado entre grupos de pacientes de diferentes clases.

El filtro trabaja con las columnas de la matriz original, es decir con los niveles de expresión de cada gen, de los cuales se reduce la cantidad para lograr un mejor procesamiento por el algoritmo genético. El filtro para la selección de los genes que se utilizó es el BSS/WSS, que se basa en la relación de la suma de cuadrados entre grupos(BSS) y dentro de los grupos (WSS),

propuesto por Dudoit *et al.* (2002). Esta relación evalúa la distancia de la media del nivel de expresión de cada clase con la media del nivel de expresión de cada gen y de cada gen dentro de su clase. En 3.1 se muestra el cálculo que realiza el filtro BSS/WSS para cada gen j .

$$\frac{BSS(j)}{WSS(j)} = \frac{\sum_i \sum_k I(y_i = k)(\bar{x}_{kj} - \bar{x}_j)^2}{\sum_i \sum_k I(y_i = k)(\bar{x}_{ij} - \bar{x}_{kj})^2} \quad (3.1)$$

Donde y_i denota la subclase del gen i , $\bar{x}_j$ denota el promedio del nivel de expresión del gen j para todos los pacientes y $\bar{x}_{kj}$ denota el promedio del nivel de expresión del gen j perteneciente a los pacientes de las subclases $k = 1$ y $k = 2$.

3.2. Algoritmo Genético

La segunda fase del método consiste en un algoritmo genético cuya función de aptitud se basa en el uso de una máquina de soporte vectorial (MVS), la cual se programó en paralelo con CUDA C.

3.2.1. Inicialización

La entrada para el algoritmo genético es una matriz de datos de expresión genética, con un subconjunto de pacientes y un subconjunto de genes que resultan después de aplicar el filtro estadístico BSS/WSS.

Cada individuo de la población se crea seleccionando de forma aleatoria un máximo de 10 genes diferentes (Algoritmo 3). Los datos de expresión de los genes de cada paciente, así como la clase del subtipo de cáncer a la que pertenece, se almacenan en la estructura de datos presentada en la Figura 3.2, en donde el inciso A muestra la definición de la estructura para almacenar los datos de un paciente. En el inciso B muestra la definición del arreglo con los datos de los pacientes de entrenamiento y el inciso C el arreglo con los datos de los pacientes de prueba.




Figura 3.2: Estructura de datos del AG.

Algoritmo 3 Inicialización

Entrada: subíndice de los genes y lista de genes filtrados.**Salida:** arreglo de n genes de un individuo.

- 1: genera número aleatorio menor que número máximo de genes permitidos (num_genes)
 - 2: **para** j menor que num_genes **hacer**
 - 3: **mientras** gen no sea repetido **hacer**
 - 4: $gen = random() \% NUM_GENES_FILTRADOS$
 - 5: **fin mientras**
 - 6: $genes[j] = gen$
 - 7: **devolver** $genes[n]$
 - 8: **fin para**
-

3.2.2. Función de aptitud

Una vez creada la población inicial se realiza el cálculo de la aptitud de cada individuo. Este cálculo consiste en contabilizar el número de errores al clasificar con la MVS el subtipo de cáncer de los pacientes. La MVS se entrena con los valores de expresión de los genes que corresponden a un subconjunto de pacientes seleccionados aleatoriamente para entrenar la máquina.

En el Algoritmo 4 se muestra el pseudocódigo de la función de aptitud. Como se puede observar, este método se apoya en el Algoritmo 7 que imple-

menta la MVS. Una vez que se reciben por parte de la MVS los resultados de la clasificación de los pacientes de prueba (Línea 4), se ejecuta un ciclo (Línea 5 a 12), donde se comparan los resultados de la clasificación con las clases reales a las que pertenecen los pacientes. Con cada paciente mal clasificado el valor de la aptitud se incrementa, es decir, el valor de la aptitud óptima es igual a cero, ya que buscamos la combinación de genes que clasifique correctamente a todos los pacientes de prueba.

Algoritmo 4 Cálculo de la aptitud de un individuo

Entrada: subíndice de los genes y pacientes de los individuos, matriz de expresión de genes.

Salida: valor de aptitud de cada individuo.

```

1: se extraen los valores de expresión del individuo a partir de la matriz de
   datos.
2: copia los datos del individuo del host al device
3: llama al Algoritmo 7 (Cho-Jui et al. (2008))
4: copia los resultados de la clasificación del device al host
5: para todos los individuos de la población hacer
6:   individuo[i]  $\Rightarrow$  aptitud=0
7:   para  $j \leq pruebas$  hacer
8:     si  $pruebasResultado \neq pruebas\_metodo$  entonces
9:        $individuo[i] \Rightarrow aptitud++$ 
10:    fin si
11:  fin para
12: fin para

```

Debido a que el AG obtiene rápidamente una aptitud cero, implementamos un criterio de desempate para establecer cuál individuo es mejor, entre dos o más individuos con la misma aptitud. La técnica consiste en ejecutar n veces el cálculo de la aptitud para cada individuo con diferente cantidad de pacientes de entrenamiento y de prueba. Esto se muestra en el pseudocódigo del algoritmo 5.

Por ejemplo, si tenemos 72 pacientes en la BD y utilizamos 57 para el AG

Algoritmo 5 Criterio de desempate

Entrada: número de pacientes para entrenar el AG ($num_pacs_genetico$)
 número de pacientes totales para el AG (num_pacs), valores de expresión
 de los genes.

Salida: número de pruebas ($num_pruebas$), aptitud de $individuo[i] - >$
 $atitud_veces[vuelta]$.

- 1: $num_vuelta = 0$
- 2: $num_pacs_genetico = \text{limite inferior}$
- 3: $num_pruebas = num_pacs - num_pacs_genetico$
- 4: Calcula aptitud (algoritmo 4)
- 5: $individuo[i] - > aptitud_veces[num_vuelta] = aptitud$
- 6: $num_vuelta + +$

tenemos:

$num_pacs = 57$

$limite_inferior = 5$

$limite_superior = 42$

$num_pacs_genetico = \text{de } 5 \text{ a } 42$

$num_pruebas = \text{de } 52 \text{ a } 15$

$num_veces = 38$

De esta manera calculamos la aptitud num_veces para cada individuo y realizamos la suma de la aptitud en cada vuelta. Así, el individuo que tiene menor aptitud en las 38 vueltas es el que se considera como mejor.

3.2.3. Operadores genéticos

Selección

Para el proceso de selección se utiliza el método de torneo binario, el cual consiste en comparar dos individuos y seleccionar el que tiene mejor aptitud. Al inicio de este proceso se revuelve la población aleatoriamente y se seleccionan para competir: el individuo que se encuentra en la posición i -ésima dentro

de la población y el individuo que encuentra en la i -ésima posición después de la mitad de la población. En el Algoritmo 6 se muestra el pseudocódigo de este método.

Algoritmo 6 Selección

Entrada: población actual.

Salida: población modificada con los individuos de mejor aptitud

```

1: se revuelven los individuos de la población
2: para  $i=0$ ;  $i \leq mitadDeIndividuos$ ;  $i++$  hacer
3:   si  $individuo[i].aptitud < individuo[i + mitad].aptitud$  entonces
4:      $nuevaPoblacion.individuo[i] = individuo[i].copia$ 
5:   si no
6:      $nuevaPoblacion.individuo[i] = individuo[i+mitad].copia$ 
7:   fin si
8: fin para
9: se repite de 1 a 8 para llenar la segunda mitad de la población nueva
10: se asume la nueva población como la población actual

```

Cruza

Para realizar la craza se seleccionan dos individuos considerados como padres, de los cuales se generan dos individuos nuevos considerados como hijos. Para formar al hijo 1 se recorre la mitad de los genes del padre 1 y se copian al hijo, después se recorren los genes del padre 2 y se agregan al hijo aquellos genes que no se pasaron previamente del padre 1, hasta llegar al número de genes totales que debe tener dicho hijo. Este proceso se repite para formar el hijo 2, iniciando ahora con el padre 2. En la Figura 3.3 se muestra un ejemplo de la craza de dos individuos.

Mutación

El operador de mutación se implementó recorriendo toda la población y, para cada individuo se elige, con cierto porcentaje de probabilidad, si será mutado o no. Para mutar un individuo se elige de forma aleatoria uno de sus

1	2	3	4	7	9	Padre 1
5	3	7	8	11	6	Padre 2
1	2	3	5	7	8	Hijo 1
5	3	7	1	2	4	Hijo 2

Figura 3.3: Ejemplo de cruce de dos individuos.

genes y se sustituye por otro gen de la matriz de expresión filtrada, elegido también de forma aleatoria. Según su probabilidad de mutación, también se puede agregar o quitar aleatoriamente un gen del individuo.

Este proceso de seleccionar los mejores individuos, cruzarlos y mutarlos se repite un cierto número predefinido de generaciones, esperando que cada nueva generación mejore en promedio su aptitud con respecto a las generaciones anteriores. La salida del AG es un arreglo con los datos de cada individuo, incluyendo los genes seleccionados, el valor de su aptitud y el promedio de la aptitud de toda la población.

3.3. Clasificador

3.3.1. Método Dual de Descenso Coordinado de Larga Escala para MVS Lineales (Cho-Jui *et al.* (2008))

La MVS es la parte central del cálculo de la función de aptitud del AG. El método seleccionado para implementar la MVS es el presentado por Cho-Jui *et al.* (2008), el cual es un algoritmo sencillo y de rápida convergencia, nombrado como *Método dual de descenso coordinado de larga escala para MVS lineales*.

El Algoritmo 7 muestra el pseudocódigo de la MVS, dónde α representa los vectores de soporte, w es el vector normal al hiperplano, y es la clase a la que pertenece cada paciente, x es un vector con los valores de expresión de los genes del paciente.

Algoritmo 7 Método dual de descenso coordinado de larga escala para MVS lineales

Entrada: individuos para entrenamiento.

Salida: vector w .

```

1: dado  $\alpha$  y el correspondiente  $w = \sum_i y_i \alpha_i x_i$ 
2: mientras  $\alpha$  no sea óptimo hacer
3:   para  $i=0; i \leq \text{pacientes}; i++$  hacer
4:      $G = y_i w^T x_i - 1 + D_{ii} \alpha_i$ 
5:      $PG = \begin{cases} \min(G, 0), & \text{si } : \alpha_i = 0 \\ \max(G, 0), & \text{si } : \alpha_i = U \\ G, & \text{si } : 0 < \alpha_i < U \end{cases}$ 
6:     si  $|PG| \neq 0$  entonces
7:        $\alpha'_i \leftarrow \alpha_i$ 
8:        $\alpha_i \leftarrow \min\left(\max\left(\alpha_i - \frac{G}{Q_{ii}}, 0\right), U\right)$ 
9:        $w \leftarrow w + (\alpha_i - \alpha'_i) y_i x_i$ 
10:    fin si
11:  fin para
12: fin mientras
```

3.3.2. Implementación paralela de la MVS

En CUDA, una función llamada desde la CPU (Host) y que se ejecuta en la GPU (device) es llamada kernel. Cada kernel se ejecuta mediante un arreglo de hilos (threads), donde todos los hilos ejecutan el mismo código y cada uno tiene un identificador (ID) que se utiliza para direccionar la memoria asociada a su proceso. La unidad básica de operación en CUDA es el hilo. Los hilos están organizados en bloques (Blocks).

Para llamar a un kernel se utiliza la siguiente sintáxis:

nombre <<< *bloques*, *hilos* >>> ();




Figura 3.4: Representación de la estructura de datos enviada al kernel.

Para implementar la función de aptitud del AG utilizamos un kernel nombrado *entrenamiento_mvs*, basado en el Algoritmo 7. Los datos de los pacientes de entrenamiento se almacenaron en una estructura de datos lineal para poder ser enviados al kernel. Esta estructura, como se muestra en la Figura 3.4, contiene la clase a la que pertenece cada paciente y el valor de expresión de los genes seleccionados. Para el caso de los pacientes de prueba solo cambia el parámetro *NUM_MUESTRAS* por *NUM_PRUEBAS*, que determina la cantidad de pacientes para probar la MVS. La Figura 3.5 muestra una representación de la ejecución simultánea de la función de aptitud en la GPU.

El kernel *entrenamiento_mvs* se divide en dos partes: Primero se ejecuta el Algoritmo 7 que se utiliza para entrenar la MVS, posteriormente se evalúa que tan eficaz resulta la clasificación. El proceso de entrenamiento encuentra el hiperplano óptimo que separa a ambas clases con el máximo margen m (Figura 3.6). Encontrar el hiperplano óptimo es equivalente a minimizar la norma del vector normal al hiperplano. En cada iteración del Algoritmo 7 se




Figura 3.5: Representación de la ejecución en paralelo de la función de aptitud de la GPU.

disminuye el valor de la norma de w . La condición de parada del algoritmo es que la diferencia del valor de la norma de la iteración actual con respecto a la iteración anterior sea menor que un valor épsilon preestablecido. El cálculo de la norma de un vector v se muestra en 3.2.

$$\| v \| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2} \quad (3.2)$$

Donde v es un vector $v = (v_1, v_2, \dots, v_n)$.

Las muestras (pacientes) de cada clase que resultan en los límites del margen se denominan vectores de soporte y cumplen con la característica de que tienen un valor α asociado diferente de cero.

Una vez que concluye el algoritmo de entrenamiento se clasifican los pacientes de prueba utilizando 3.3, que corresponde al hiperplano óptimo calculado como parte de la función de entrenamiento.

$$w^T \cdot x + b = 0 \quad (3.3)$$

Donde x representa los valores de expresión de los genes de los pacientes de




Figura 3.6: Hiperplano de separación óptimo.

prueba, y el parámetro b se calcula con 3.4.

$$b = \frac{1}{N_{vs}} \sum_{i=1}^{N_{vs}} (y_{vs} - w * x_{vs}) \quad (3.4)$$

Dónde vs representa al conjunto de las muestras que resultaron ser vectores de soporte, N_{vs} es el número total de vectores de soporte, y_{vs} es la clase de los pacientes (-1 o 1) que resultaron ser vectores de soporte, y x_{vs} son vectores con los valores de expresión de los genes de dichos pacientes.

El resultado de esta clasificación de los pacientes de prueba se almacena en un arreglo lineal y se copia del device al host.

Capítulo 4

Experimentos y Resultados

Para la evaluación del método se utilizó una matriz de expresión genética de pacientes diagnosticados con leucemia, que consta de 72 pacientes y 7129 genes, obtenida de Li & Liu (2003). Los parámetros del algoritmo son el número de generaciones, probabilidad de mutación, probabilidad de inserción, probabilidad de delección, probabilidad de cruza, número de bloques, número de hilos, número de individuos, número de genes, número de pacientes totales, número de pacientes para el AG, número máximo de genes para un individuo, número de genes filtrados, número de veces para el cálculo de la aptitud. Dentro del algoritmo 4, que corresponde a la implementación de la MVS de Cho-Jui *et al.* (2008) se tiene c , ϵ y u .

Donde: $c > 0$ es un parámetro de penalización, u toma el valor de $u = c$ en el algoritmo 7, ϵ es un parámetro de parada.

Las evaluaciones consistieron en medir la cantidad de errores al clasificar pacientes nuevos con los n genes encontrados en el AG. Los resultados se compararon con los métodos Hernández-Montiel *et al.* (2011), Meléndrez-Carballo (2015), Wang & Gotoh (2009).

A continuación se presentan los datos de los parámetros para los experimentos así como los resultados obtenidos. En el apéndice A se muestra la lista de genes que se obtuvieron en los experimentos.

4.1. Distribución de los pacientes

Primero se hizo una selección de los pacientes. De los 72 de la base de datos se tomaron 57 para la fase 1 y 2 y se dejaron 15 para la tercera fase.

La base de datos de leucemia consta de 25 pacientes con tipo Leucemia mieloide aguda (AML) y 47 con tipo Leucemia linfoblástica aguda (ALL), por lo que se repartió el número de cada tipo para el entrenamiento y las pruebas del método.

Los subíndices 0 al 24 en la base de datos corresponden a pacientes con el tipo AML y los pacientes con subíndice del 25 al 71 corresponden al tipo ALL.

A continuación se presenta la lista de subíndices de los pacientes que se utilizaron para cada fase.

Fase 1 y 2:

0,1,2,3,4,5,6,7,8,9,10,11,12,13,14,25,26,27,28,29,30,31,32,33,34,35,36,37,38,39,40,
41,42,43,44,45,46,47,48,49,50,51,15,16,17,18,19,52,53,54,55,56,57,58,59,60,61

Fase 3:

20,21,22,23,24,62,63,64,65,66,67,68,69,70,71

La lista de los 100 genes mejor evaluados por el filtro BSS/WSS se presentan en el apéndice B con la posición, el número del gen en la base de datos de leucemia y el valor estadístico obtenido por el filtro.

4.2. Tiempo de ejecución

Para medir el tiempo de ejecución del método se realizaron dos experimentos, comparando la versión secuencial del método con la versión paralela del mismo.

En las pruebas se utilizaron 400 y 1000 generaciones del AG, respectivamente. En la Tabla 4.1 se muestran los parámetros para las pruebas realizadas con el AG. La Tabla 4.2 muestra los parámetros utilizados en el Algoritmo 7.

Los experimentos se desarrollaron en un equipo de cómputo con las siguientes características:

- Tarjeta gráfica: GeForce GTX670
- Procesador: i5 3.0 GHz
- Memoria RAM: 4 GB
- Sistema Operativo: Linux Mint 17
- Versión de Cuda: 5.5

En la Tabla 4.3 y la Figura 4.1 se muestran los resultados de la comparación de los tiempos de ejecución.

Parámetro	Prueba 1	Prueba 2
Generaciones	400	1000
Bloques	100	100
Hilos	10	10
Individuos	1000	1000
Número de genes por individuos	10	10
Pacientes para el AG	57	57
Pacientes de entrenamiento	20	20
Pacientes de prueba	37	37

Tabla 4.1: Parámetros utilizados para medir el tiempo de ejecución del método propuesto.

Parámetro	Valor
C (Parámetro de penalización)	1000
Épsilon	0.0001
U	C

Tabla 4.2: Parámetros utilizados en Algoritmo 7.

4.3. Tasa de éxito

Los resultados obtenidos en la clasificación muestran una tasa de éxito del 99.78 % al 100 %, clasificando en promedio correctamente 14.97 de 15 pacientes por cada iteración.

El experimento consistió en ejecutar 30 veces el método. En cada ejecución se obtuvo un conjunto de genes evaluados como mejores, los cuales se utilizaron para la clasificación de los pacientes en la fase 3. Con los resultados de la clasificación de la MVS en la fase 3, medimos la efectividad del método para clasificar pacientes nuevos, obteniendo una tasa de éxito del 100 %.

Método	Tiempo	
	<i>Segundos</i>	<i>Minutos</i>
Secuencial-400	113.2303	1.88
Secuencial-1000	280.0745	4.66
CUDA-400	4.2006	0.07
CUDA-1000	10.1030	0.16

Tabla 4.3: Resultados obtenidos para medir el tiempo de ejecución.

En la Figura 4.2 se muestra la gráfica para la comparación de los resultados con el método propuesto (Inciso 5) respecto a algunos métodos reportados




Figura 4.1: Comparación del tiempo de ejecución

en la literatura.

En el Apéndice A se muestran las 30 ejecuciones del método, con el grupo de genes que obtuvo y el número de errores en la clasificación final.

En los resultados obtenidos, en 27 de las 30 ejecuciones aparecieron los tres mismos genes: 4846, 803 y 4950, por lo que llegamos a la conclusión de que estos genes son relevantes para esta base de datos.

4846 : *X95735_at* zyxin, ZYX (Macalma *et al.* (1996))

4950 : *D42043KIAA0084* gene, partial cds (YU *et al.* (1997))

803 : *HG1612 – HT1612_at* Macmarcks (Chen *et al.* (1996))




Figura 4.2: Comparación con otros métodos en porcentaje de éxito en clasificación correcta

Capítulo 5

Conclusiones y trabajo futuro

5.1. Sumario

En este trabajo se estableció el marco teórico del problema de clasificación, se analizaron algunos de los métodos más reconocidos al respecto, y se desarrolló, evaluó y comparó una nueva propuesta basada en la combinación de un filtro estadístico, un algoritmo genético y una máquina de soporte vectorial.

Se evaluó el desempeño del algoritmo al aplicarle cambios estructurales para la paralelización de una función basada en el método de Cho-Jui *et al.* (2008). La función corresponde al cálculo de la aptitud del algoritmo genético la cual consiste en una máquina de soporte vectorial, que al programarla en paralelo impactó fuertemente en los resultados finales. Se realizaron experimentos para evaluar esta propuesta, y se realizaron comparaciones con otros métodos encontrados en la literatura.

Se evaluaron los resultados en cuanto a tiempo de ejecución de la versión secuencial del método con respecto a la versión paralela. Los mejores resultados en cuanto a tiempo de ejecución obtenidos por la versión paralela nos permitieron realizar una mayor cantidad de pruebas permitiendo mejorar la tasa de éxito en el algoritmo de clasificación.

Cada una de las versiones se evaluó con 400 y 1000 individuos en el algoritmo genético, lo que nos dio como resultado una reducción del tiempo de alrededor de 27 veces en la versión paralela respecto a la secuencial sin reducir la eficacia del método.

Una vez reducido el tiempo de procesamiento se trabajó en mejorar la tasa de éxito en la clasificación, logrando obtener una técnica para encontrar una buena combinación de genes que ayudaron a clasificar con menor cantidad de errores en la etapa de pruebas.

5.2. Conclusiones

El método propuesto disminuyó 96 % el tiempo de ejecución del método secuencial, lo cual permitió realizar más experimentos con la base de datos de cáncer de leucemia, incluso utilizando parámetros de mayor tamaño, en tiempos mucho más bajos.

Los experimentos realizados muestran porcentajes muy altos en la tasa de éxito en cuanto a clasificación con pacientes nuevos, logrando el 100 % y superando a otros métodos de la literatura.

Se logró identificar un conjunto de tres genes significativos para la base de datos de leucemia, lo cual no ha sido reportado en otros trabajos en la literatura.

5.3. Trabajo futuro

Se propone evaluar la eficiencia del algoritmo en cuanto al porcentaje de éxito en la clasificación con diferentes bases de datos de cáncer.

Apéndice A

Genes obtenidos en 30 ejecuciones

Lista de los subíndices de los genes obtenidos en las 30 ejecuciones, así como la cantidad de errores al clasificar en la fase 3 del método.

	Nº de genes	Genes	Error
1	3	4846,803,4950	0
2	5	4950,4846,2641,1614,803	0
3	5	6701,1778,4913,2353,4950	1
4	4	4846,1238,4950,803	0
5	3	803,4950,4846	0
6	5	5376,4950,172,4846,803	0
7	6	4327,1143,803,6701,4950,4846	0
8	4	6256,4846,4950,803	0
9	4	4972,2353,2019,2275	0
10	3	803,4950,4846	0
11	3	4950,4846,803	0
12	3	4950,803,4846	0
13	3	4950,803,4846	0
14	3	4846,4950,803	0
15	5	4376,4846,6224,803,4950	0

Tabla A.1: Resultado de las ejecuciones del método (Parte 1).

	Nº de genes	Genes	Error
16	4	803,4846,4950,1238	0
17	4	2019,3846,4972,2353	0
18	3	4950,4846,803	0
19	3	4846,803,4950	0
20	3	4846,803,4950	0
21	3	803,4846,4950	0
22	3	4846,4950,803	0
23	3	4846,4950,803	0
24	3	803,4846,4950	0
25	3	4846,803,4950	0
26	4	4846,172,803,4950	0
27	3	803,4846,4950	0
28	3	4846,4950,803	0
29	3	4846,4950,803	0
30	3	4846,4950,803	0

Tabla A.2: Resultado de las ejecuciones del método (Parte 2).

Apéndice B

100 mejores genes obtenidos por el filtro BSS/WSS

A continuación se muestra la posición del gen, el número del gen de la base de datos y el puntaje que le asignó el filtro.

Posición: 1	Gen: 4846	Valor: 1.516153
Posición: 2	Gen: 2287	Valor: 1.005524
Posición: 3	Gen: 1833	Valor: 0.993261
Posición: 4	Gen: 4195	Valor: 0.951292
Posición: 5	Gen: 1828	Valor: 0.946749
Posición: 6	Gen: 3251	Valor: 0.871661
Posición: 7	Gen: 6040	Valor: 0.864748
Posición: 8	Gen: 2120	Valor: 0.846364
Posición: 9	Gen: 1881	Valor: 0.836367
Posición: 10	Gen: 6854	Valor: 0.824697
Posición: 11	Gen: 6280	Valor: 0.817748
Posición: 12	Gen: 1744	Valor: 0.806249
Posición: 13	Gen: 2110	Valor: 0.788128
Posición: 14	Gen: 4327	Valor: 0.758958

APÉNDICE B. 100 MEJORES GENES OBTENIDOS POR EL FILTRO BSS/WSS59

Posición: 15 Gen: 1614 Valor: 0.757189
Posición: 16 Gen: 1778 Valor: 0.734546
Posición: 17 Gen: 2353 Valor: 0.725437
Posición: 18 Gen: 4376 Valor: 0.679854
Posición: 19 Gen: 1673 Valor: 0.675740
Posición: 20 Gen: 803 Valor: 0.674732
Posición: 21 Gen: 4365 Valor: 0.667397
Posición: 22 Gen: 2019 Valor: 0.666085
Posición: 23 Gen: 2140 Valor: 0.657880
Posición: 24 Gen: 1259 Valor: 0.636111
Posición: 25 Gen: 4228 Valor: 0.633079
Posición: 26 Gen: 3319 Valor: 0.626405
Posición: 27 Gen: 1143 Valor: 0.622498
Posición: 28 Gen: 3421 Valor: 0.621885
Posición: 29 Gen: 460 Valor: 0.619482
Posición: 30 Gen: 2440 Valor: 0.619143
Posición: 31 Gen: 6918 Valor: 0.613717
Posición: 32 Gen: 6004 Valor: 0.602138
Posición: 33 Gen: 4950 Valor: 0.600780
Posición: 34 Gen: 1684 Valor: 0.588335
Posición: 35 Gen: 759 Valor: 0.580907
Posición: 36 Gen: 6200 Valor: 0.577795
Posición: 37 Gen: 1290 Valor: 0.577699
Posición: 38 Gen: 7118 Valor: 0.574633
Posición: 39 Gen: 6372 Valor: 0.570615
Posición: 40 Gen: 5106 Valor: 0.556403
Posición: 41 Gen: 1961 Valor: 0.555420
Posición: 42 Gen: 1238 Valor: 0.545779
Posición: 43 Gen: 6701 Valor: 0.542323
Posición: 44 Gen: 320 Valor: 0.539599

APÉNDICE B. 100 MEJORES GENES OBTENIDOS POR EL FILTRO BSS/WSS60

Posición: 45 Gen: 2401 Valor: 0.534397
Posición: 46 Gen: 2275 Valor: 0.533160
Posición: 47 Gen: 2334 Valor: 0.530854
Posición: 48 Gen: 5832 Valor: 0.524681
Posición: 49 Gen: 5376 Valor: 0.522876
Posición: 50 Gen: 6224 Valor: 0.521609
Posición: 51 Gen: 3162 Valor: 0.517810
Posición: 52 Gen: 6282 Valor: 0.514693
Posición: 53 Gen: 6375 Valor: 0.503527
Posición: 54 Gen: 1927 Valor: 0.493175
Posición: 55 Gen: 4210 Valor: 0.488460
Posición: 56 Gen: 3721 Valor: 0.485030
Posición: 57 Gen: 3257 Valor: 0.479809
Posición: 58 Gen: 4498 Valor: 0.478787
Posición: 59 Gen: 4115 Valor: 0.473257
Posición: 60 Gen: 4972 Valor: 0.471386
Posición: 61 Gen: 6805 Valor: 0.469917
Posición: 62 Gen: 769 Valor: 0.465010
Posición: 63 Gen: 4166 Valor: 0.462928
Posición: 64 Gen: 4437 Valor: 0.462668
Posición: 65 Gen: 1597 Valor: 0.459844
Posición: 66 Gen: 148 Valor: 0.459799
Posición: 67 Gen: 2641 Valor: 0.458270
Posición: 68 Gen: 2062 Valor: 0.455047
Posición: 69 Gen: 6256 Valor: 0.451263
Posición: 70 Gen: 172 Valor: 0.450150
Posición: 71 Gen: 2000 Valor: 0.448456
Posición: 72 Gen: 6346 Valor: 0.447323
Posición: 73 Gen: 3777 Valor: 0.446645
Posición: 74 Gen: 6796 Valor: 0.446569

APÉNDICE B. 100 MEJORES GENES OBTENIDOS POR EL FILTRO BSS/WSS61

Posición: 75 Gen: 6168 Valor: 0.441501
Posición: 76 Gen: 234 Valor: 0.441368
Posición: 77 Gen: 2738 Valor: 0.440619
Posición: 78 Gen: 5771 Valor: 0.437761
Posición: 79 Gen: 87 Valor: 0.434607
Posición: 80 Gen: 5500 Valor: 0.434579
Posición: 81 Gen: 6184 Valor: 0.430033
Posición: 82 Gen: 1156 Valor: 0.427603
Posición: 83 Gen: 6802 Valor: 0.427152
Posición: 84 Gen: 3983 Valor: 0.425622
Posición: 85 Gen: 6054 Valor: 0.423303
Posición: 86 Gen: 4462 Valor: 0.421456
Posición: 87 Gen: 4779 Valor: 0.419581
Posición: 88 Gen: 3846 Valor: 0.419309
Posición: 89 Gen: 4913 Valor: 0.417963
Posición: 90 Gen: 4290 Valor: 0.416355
Posición: 91 Gen: 757 Valor: 0.413365
Posición: 92 Gen: 6515 Valor: 0.409118
Posición: 93 Gen: 2130 Valor: 0.406710
Posición: 94 Gen: 921 Valor: 0.405201
Posición: 95 Gen: 5793 Valor: 0.404666
Posición: 96 Gen: 1399 Valor: 0.401969
Posición: 97 Gen: 331 Valor: 0.401566
Posición: 98 Gen: 4372 Valor: 0.401456
Posición: 99 Gen: 5279 Valor: 0.400855
Posición: 100 Gen: 4893 Valor: 0.399270

Bibliografía

- ASGARIAN, N. & GREINER, R. (2007). Using rank-1 biclusters to classify microarray data. *Bioinformatics* , 1–10.
- BALANZA, B. P. (2007). *Técnicas de evaluación en algoritmos de biclustering sobre datos de expresión genómica*. Technical report, Universidad de Sevilla, Departamento de Lenaguajes y Sistemas Informaticos.
- CASTRO-LIERA, I. (2011). Paralelización de algoritmos de optimización basados en poblaciones usando gpgpu , 48–60.
- CHAMORRO, I. N. & CHAMORRO, J. A. N. (2010). *Análisis de datos de expresión genica, de la información al conocimiento en la biología actual*. Facultad de filosofía de la universidad de sevilla.
- CHEN, J., CHANG, S., DUNCAN, S. A., OKANO, H. J., FISHELL, G. & ADEREM, A. (1996). Disruption of the macmarcks gene prevents cranial neural tube closure and results in anencephaly. *PNAS* **93**, 6275–6279.
- CHO-JUI, H., CHANG, K.-W., LIN, C.-J., KEERTHI, S. S. & SUNDARAJAN., S. (2008). A dual coordinate descent method for large-scale linear svm. *ACM Proceeding of the 25 international conference on Machine learning* , 408–415.
- DUDOIT, S., FRIDLYAND, J. & SPEED, T. (2002). Comparison of discrimination methods for the classification of tumors using gene expression data. *Of the Americ an Statistical* **97**, 77–87.

- GESTAL, M., RIVERO, D., RABUÑAL, J. R., DORADO, J. & PAZOS, A. (2010). Introducción a los algoritmos genéticos y la programación genética. *Universidad de Coruña Monografías n° 140*, 76.
- GOLUB, T. R., SLONIM, D. K., TAMAYO, P., HUARD, C., GAASENBEEK, M., MESIROV, J. P., COLLIER, H., LOH, M. L., DOWNING, J. R., CALIGIURI, M. A., BLOOMFIELD, C. D. & LANDER, E. S. (1999). Molecular classification of cancer: Class discovery and class prediction by gene expression monitoring. *Science* **286**, 531–537.
- HERNÁNDEZ-MONTIEL, L. A., HUERTA, E. B. & CAPORAL, R. M. (2011). A multiple-filter-ga-svm method for dimension reduction and classification of dna-microarray data. *Revista Mexicana de Ingeniería Biomédica* **32**, 32–39.
- KIM-FUNG, M., TANG, K. S. & KWONG, S. (2012). *Genetic algorithms: Concepts and designs*. Heidelberg: Springer Science and Business Media.
- LI, J. & LIU, H. (2003). Kent ridge bio-medical dataset. <http://datam.i2r.a-star.edu.sg/datasets/krbd/index.html>.
- MACALMA, T., OTTE, J., HENSLE, M. E., BOCKHOLT, S. M., ANDD MARTHA KALFF-SUSKE, H. A. L., GRZESCHIK, K.-H., VON DER AHE, D. & BECKERLE, M. C. (1996). Molecular characterization of human zyxin. *Biological Chemistry* **271**, 31470–31478.
- MELÉNDREZ-CARBALLO, G. (2015). *Algoritmo clasificador de subtipos de cáncer*. Residencias.
- MITRA, S. & BANKA, H. (2006). Multi-objective evolutionary biclustering of gene expression data. *Journal of the Pattern Recognition Society* **39**, 2464–2477.

- RODRIGUEZ, D. S., RIQUELME, J. C. & AGUILAR, J. S. (2006). *Análisis de datos de expresión genética mediante técnicas de biclustering*. Technical report, Universidad de Sevilla.
- SANCHEZ, F. M., CAMPOS, G. L. & DE ANDRES, N. I. (1999). *La convergencia de la informática médica panamericana*, vol. 13:978-1402073762. Servicios de salud ¿estrategias o tecnologías.
- SHARAN, R., ELKON, R. & SHAMIR, R. (2002). Cluster analysis and its applications to gene expression data. *Ernst Schering workshop on Bioinformatics and Genome Analysis* , 83–108.
- TANAY, A., SHARAN, O. & SHIMIR, R. (2002). Discovering statistically significant biclusters in gene expression data. *Bionformatics* , S136–S144.
- WANG, X. & GOTOH, O. (2009). Cancer classification using single genes. *Genome Informatics* **23**, 179–188.
- YANG, J. L. J. & WANG, W. (2004). *Biclustering in gene expression data by tendency*.
- YU, J., NAGARAJAN, S., KNEZ, J. J., UDENFRIEND, S., CHEN, R. & MEDOF, M. E. (1997). The affected gene underlying the class k glycosylphosphatidylinositol (gpi) surface protein defect codes for the gpi transamidase. *Medical Sciences* **94**, 12580–12585.